

SMART +
SUSTAINABLE

Liderar la construcción **de un mundo sostenible**

Aprendizaje No-Supervisado

Clustering

Bastián Galasso

Data Analytics Lead – Coca-Cola Embonor

Julio 2025

Aprendizaje No-Supervisado

01 K-Means y K-Modes

02 K-Prototype

03 Fuzzy C-Means


04 DBSCAN

05 Ejercicio

00 Introducción

- Los modelos que revisaremos en esta sección se encuadran en la categoría de modelo no supervisados, que corresponden a aquellos que son utilizados cuando solo se conoce predictores o co-variables pero no una variable target o respuesta.
- En este sentido, el objetivo es modelar la estructura o distribución subyacente en los datos para obtener más información sobre los datos.

Los problemas de aprendizaje no supervisado se pueden agrupar en dos




00 Introducción

→ Los algoritmos de agrupación consisten en agrupar los datos basados en su **similitud**




00 Introducción

→ Existen diferentes tipos:




Exclusive Cluster

- K-Means
- K-Modes



Overlapping Cluster

- Fuzzy C-Means




Hierarchical Cluster

K-Means y K-Modes

01

01 | K-Means


- **K-Means** es una técnica de clasificación no supervisada que se basa su agrupación en la consolidación de K grupos homogéneos, a través de sus características.
- Este algoritmo está basado en distancias, donde dichas distancias son calculadas para asignar un punto a un grupo, y cada grupo tiene asociado un **centroide**.
- El agrupamiento se realiza minimizando la suma de las distancias entre cada objeto, y el centroide de su grupo. Típicamente para el K-means se utiliza la distancia Euclidiana.



Conceptos Claves

- **Distancia Euclidiana:** Indica la distancia entre dos puntos en un espacio multidimensional
- **Criterio de la Inercia:** Indica que el agrupamiento será óptimo, cuando los grupos formados tengan una distancia **intra-cluster** mínima y una **inter-cluster** máxima.

$$d(x, y)^2 = \sum_{j=1}^m (x_j - y_j)^2 = ||x - y||^2$$



01 | K-Means

- **Distancia inter-cluster:** Indica qué tan lejos están los grupos entre sí. Es una buena señal cuando están distantes entre sí, porque muestran una mayor mayor diferenciación entre ellos y probablemente, una clasificación más precisa.
- **Distancia intra-cluster:** Indica qué tan separados están los elementos del mismo grupo, y qué tan lejos están de su centroide. Los grupos más densos con elementos más cercanos tienen mayor similitud, son más probables de compartir características y serán mejor representados por el centroide.



Algoritmo

Se repite este paso hasta que ninguna observación cambie de grupo



Se escogen K centroides de manera aleatoria


Se agrupan las observaciones según la distancia a los distintos centroides, buscan el más cercano.

Se cambia el centroide por el promedio entre las observaciones de cada grupo, generando K nuevos centroides

Se agrupan las observaciones minimizando la distancia a los centroides, formando K grupos.

01 K-Means

Lo anterior se ve de la siguiente forma



01 | K-Modes

- **K-Modes** es un algoritmo diseñado para agrupar grandes conjuntos de **datos categóricos**, y que tiene como objetivo tener las **K** modas que representan al conjunto.
- Define grupos basados en el número de categorías coincidentes entre puntos de datos (esto contrasta con el algoritmo K-Means que agrupa datos numéricos basado en distancia)
- Básicamente, K-Modes es una versión de K-Means para datos categóricos, con las siguientes modificaciones:

Diferentes medidas de disimilaridad

Sustitución de K medias por K modas para formar centroides

Actualiza las modas a partir de las frecuencias de los datos

01 | K-Modes

- La medida de disimilaridad utilizada por defecto en el K-modes es la simple-matching distance, que se define de la siguiente forma

$$d(X, Y) = \sum_{j=1}^m \delta(x_j, y_j),$$

donde

$$\delta(x, y) = \begin{cases} 0 & \text{si } x = y \\ 1 & \text{si } x \neq y \end{cases}$$

01 | K-Modes

- La medida anterior no utiliza la frecuencia en que ocurre cada categoría en cada variable. En este sentido, se puede generar otra medida de disimilaridad, llamada *chi-square distance* (Greenacre 1984), definida por

$$d_{\chi^2}(X, Y) = \sum_{j=1}^m \left(\frac{n_{x_j} + n_{y_j}}{n_{x_j} n_{y_j}} \right) \delta(x_j, y_j),$$

donde n_{x_j} , n_{y_j} son el número de observaciones en el data set que tienen las categorías x_j e y_j , para el atributo j .

K-Prototype

02

02 K-Prototypes

- Hasta ahora, los métodos de clustering que hemos revisado son de los más clásicos y todos comparten la misma limitación, que es solo poder utilizar un tipo de variable, ya sea numérico (K-means o Fuzzy C-means) o categórica (K-modes).
- **K-Prototype** es una técnica que busca romper esa limitante ampliando los modelos anteriores, mediante la creación de una nueva distancia capaz de medir ambos tipos de variables a la vez. Esta distancia es la siguiente:


Sea X e Y dos vectores de modo que las primeras I -ésimas coordenadas corresponde a datos numéricos y las restantes a datos categóricos, entonces la distancia se define por

$$d(X, Y) = \sum_{i=1}^I (x_i - y_i)^2 + \lambda \sum_{i=I+1}^n \delta(x_i, y_i),$$

donde λ es un parámetro de control del “peso” que tiene cada tipo de variable.

02 K-Prototypes

- El algoritmo es igual que K-means o K-modes, solo se modifica la distancia que se está utilizando para calcular los centroides.
- Es más, se puede ver simplemente que si aplicamos K-prototypes solo para variables numéricas K-prototypes se transforma en K-means, y por otro lado, si solo son categóricas entonces se transforma en K-modes.




Fuzzy C-Means

03

03 Fuzzy C-Means

- **C-Means clustering** o **Fuzzy C-Means clustering** es una técnica de *soft clustering* en machine learning en la cual los puntos son separados en diferentes grupos y luego, se les asigna una probabilidad de pertenecer a cada grupo.
- Este tipo de técnicas tiene mejores resultados cuando pensamos en clustering con overlapped data, comparado con otras técnicas más convencionales como K-means.



03 Fuzzy C-Means

- El algoritmo **fuzzy C-Means** es un poco más complicado que los descritos antes, dado que se trata de un problema de optimización a resolver que implica cálculos de probabilidades. En este sentido, y para no complicar el algoritmo con matemática, describiremos los pasos del algoritmo omitiendo algunas formulas.

$$J(U, V) = \sum_{i=1}^n \sum_{j=1}^c (\mu_{ij})^m \|x_j - v_j\|^2$$

Si no ha convergido,
se vuelve ejecutar
desde el paso 2



Se escogen C centroides de manera aleatoria

Se calcula el fuzzy membership o probabilidad de pertenencia a los clusters (Esto se hace mediante distancia Euclidiana)

Se actualizan los fuzzy centers o centroides con las nuevas probabilidades de pertenencia.

Se corrobora si el algoritmo converge

DBSCAN

04

04 DBSCAN

DBSCAN (Density-based spatial clustering of applications with noise) es un modelo que utiliza la densidad espacial de los puntos, identificando regiones altamente pobladas, separadas por regiones escasamente pobladas.

Ventajas:

- No requiere especificar el número de clusters
- Identifica clústers de forma arbitraria (no tan rígido como K-Means)
- Detecta ruido y outliers de manera natural

Parámetros:

- Eps: radio máximo para considerar vecinos
- Min_sample: número mínimo de puntos para formar un cluster

HDBSCAN es una mejora respecto a **DBSCAN**

Ejercicio

05

05 Ejercicio

Esta parte tiene el objetivo poner en práctica todo lo visto durante esta sección, con un ejercicio práctico, que describiremos a continuación:

Los datos para esta actividad consisten en ciertos indicadores de características de 140 famosos, obtenidos a partir de sus post en Twitter. Dejo aquí algunos datos de interés:

- Usuario (nombre e Twitter)
- Op = grado de apertura mental a nuevas experiencias
- Co = grado de orden, prolijidad y organización
- Ex = grado de timidez, solitario o participación ante el grupo social
- Ag = grado de empatía con los demás
- Ne = grado de neutoricismo, nervioso, irritabilidad.
- Wordcount = cantidad promedio de palabras por post
- Categoría = Actividad laboral del usuario, dentro de las siguientes:
 1. Actor/Actriz
 2. Cantante
 3. Modelo
 4. TV, Series
 5. Radio
 6. Tecnología
 7. Deportes
 8. Política
 9. Escritor

06 Ejercicio

Usted debe hacer lo siguiente:

1. Hacer una exploración de los datos y decidir qué modelo va a utilizar. Fundamentar su elección.
2. En base a su elección anterior, procese sus datos para dejarlos como input para el modelo.
3. Utilice alguna(s) de las técnicas vistas para calcular el número óptimo de clusters. ¿Hace sentido lo que recomiendan las técnicas? Comente.
4. Entregue descripciones generales de los clusters, sus principales diferencias y gráficos relacionados.

SMART +
SUSTAINABLE

Liderar la construcción **de un mundo sostenible**

Aprendizaje No-Supervisado

Clustering

Bastián Galasso

Data Analytics Lead – Coca-Cola Embonor

Julio 2025