

Visión Artificial

Clase 2

Esta presentación cubre técnicas fundamentales de procesamiento de imágenes que forman la base de las aplicaciones de visión por computadora, desde transformaciones básicas hasta operaciones de filtrado complejas.

De-noising



Salt and pepper noise


Super-resolution



In-painting




Áreas de Visión Computacional



Procesamiento de Imágenes

Una exploración exhaustiva de las técnicas de transformación de imágenes en visión por computadora, centrándose en el procesamiento de puntos, el filtrado lineal, la convolución y los métodos de detección de gradientes.



Tipos de Transformaciones de Imagen

Manipular imágenes digitales

Las imágenes como estructuras de datos

Estructura de una imagen a color


Una imagen a color es un tensor 3D de números:

- Ancho $\times$ Alto $\times$ 3 canales (RGB)
- Cada píxel contiene tres valores
- Rango típico: 0-255 (8 bits por canal)



Las imágenes a color almacenan valores de intensidad separados para los canales rojo, verde y azul en cada ubicación de píxel.

Imagen en escala de grises



Comprendiendo las Transformaciones de Imagen

Las transformaciones de imagen se dividen en dos categorías principales:

Cambios en el Valor del Píxel

Operaciones que modifican la intensidad o el color de los píxeles sin cambiar sus posiciones

Cambios en la Ubicación del Píxel


Operaciones que reordenan los píxeles en la imagen, como traslación, rotación, scaling o deformación

Estas operaciones fundamentales forman la base de todas las técnicas de procesamiento de imágenes.




Visualización de Datos de Imagen

Las imágenes se almacenan como matrices de valores numéricos. La visualización que vemos es una representación de estos valores como colores en una pantalla.




Parche de imagen a color


red






green



blue




colorized for visualization



actual intensity values per channel


Separación de Canales



Original Image




Pixels



Color Channels

Separación de Canales



Cada canal es una matriz 2D de números que representan los valores de intensidad para un solo componente de color.




Valores de intensidad reales por canal mostrados como imágenes en escala de grises. El brillo de cada píxel representa su valor numérico.

Imágenes en Escala de Grises

Una imagen en escala de grises es una función 2D $f(x,y)$ donde:

- x e y son coordenadas espaciales
- f es el valor de intensidad en esa ubicación
- Normalmente varía de 0 (negro) a 255 (blanco)

Las imágenes en escala de grises contienen solo información de intensidad, sin datos de color.




Una imagen en escala de grises representada como una matriz 2D de valores de intensidad.

Fundamentos de Imágenes Digitales

Una imagen digital se define matemáticamente como una función bidimensional:

$$F(x,y) = \text{intensidad en } (x,y)$$

- El **dominio** corresponde a las coordenadas espaciales (x,y)
- El **rango** representa los valores de intensidad
- (típicamente 0–255 para 8 bits)



Mientras que el procesamiento **básico** se enfoca en manipulaciones simples (brillo, contraste, filtros), el procesamiento **intermedio** extrae información estructural significativa.

Jerarquía del Procesamiento de Imágenes

Bajo nivel

Operaciones sobre píxeles individuales: ajustes de brillo, contraste y aplicación de filtros simples para mejorar la calidad de la imagen.

Nivel intermedio

Identificación de estructuras y regiones: detección de bordes, segmentación de áreas y operaciones morfológicas para aislar componentes.

Nivel avanzado

Extracción de patrones y descriptores como SIFT, HOG y técnicas de OCR que permiten el reconocimiento clásico de objetos y texto.

Alto nivel

Interpretación semántica: Comprensión de qué representa la imagen y cuál es su significado en el contexto de aplicación.

Esta jerarquía representa niveles crecientes de abstracción y complejidad computacional, culminando en la interpretación semántica que constituye el verdadero procesamiento de alto nivel.

Procesamiento de Bajo Nivel : Categorías de Transformaciones de Imagen



Cambios en el Valor del Píxel

- Ajuste de brillo y contraste
- Corrección y balance de color
- Umbralización y binarización
- Ecualización del histograma



Cambios en la Ubicación del Píxel

- Rotación y escalado
- Traslación y recorte
- Deformación y cambios de perspectiva
- Transformaciones geométricas

F



Filtering



$$G(\mathbf{x}) = h\{F(\mathbf{x})\}$$

G



changes *range* of image function

F



Warping



$$G(\mathbf{x}) = F(h\{\mathbf{x}\})$$

G




changes *domain* of image function

Tipos de Transformacion que podemos hacer


Tipos de Filtrado de Imagen

Operación Puntual



Cada píxel de salida depende solo del píxel de entrada correspondiente en la misma ubicación.

Operación de Vecindad



Cada píxel de salida depende de un vecindario de píxeles en la imagen de entrada.

Procesamiento de Imagen por Puntos

Transformando píxeles de forma independiente basándose en sus valores

Ejemplos de Procesamiento Puntual

original



darken



lower contrast




non-linear lower contrast




invert



lighten



raise contrast



non-linear raise contrast



Más ejemplos de procesamiento de puntos

Original Image



Grayscale Image



Global Thresholding (T=128)



Umbralización: Conversión de escala de grises a binario estableciendo los píxeles por encima de un umbral en blanco y por debajo en negro

Inversión de Imagen

La inversión de imagen crea un efecto negativo al restar cada valor de píxel del valor máximo posible (típicamente 255 para imágenes de 8 bits).




Imagen invertida: $f(x,y) = 255 - \text{original}(x,y)$

Procesamiento de Puntos



Mapeo de Tono Estilístico


Las operaciones de puntos complejas pueden crear efectos artísticos mapeando los valores de intensidad a través de funciones no lineales.

Ecualización de Histograma

Redistribuye los valores de intensidad para mejorar el contraste utilizando el rango completo de valores disponibles.

- Calidad de Imagen
- Efectos de estilos
- siguen operando en píxeles individuales de forma independiente.



Hay multiples procesamiento de punto en imágenes



Hay multiples procesamiento de punto en imágenes

El efecto de la **corrección gamma** en

una imagen: la imagen original se modificó a diferentes potencias, lo que demuestra que las potencias superiores a 1 oscurecen las sombras, mientras que las inferiores aclaran las zonas oscuras.



Filtrado Lineal Invariante al Desplazamiento

Combinación Lineal

Cada píxel de salida es una suma ponderada de los píxeles de entrada en su vecindad

Basado en Kernel

Los pesos son determinados por el kernel del filtro (también llamado máscara o ventana)

Invariante al Desplazamiento

El mismo kernel se aplica en cada ubicación de píxel en toda la imagen

Este enfoque forma la base de muchas operaciones de procesamiento de imágenes, incluyendo desenfoque, nitidez y detección de bordes.


kernel $g[\cdot, \cdot] = \frac{1}{9}$

1	1	1
1	1	1
1	1	1

Propiedades

- Reemplaza cada píxel con el promedio de su vecindario de 3×3
- Todos los pesos son iguales (uniformes)
- Crea un efecto de desenfoque/suavizado
- Reduce el ruido pero también reduce el detalle

Visualización del Proceso de Filtrado



El proceso de filtrado implica:

1. Centrar el kernel en cada posición de píxel.
2. Multiplicar cada valor del kernel por el píxel de imagen correspondiente.
3. Sumar estos productos para producir el valor del píxel de salida.
4. Moverse al siguiente píxel y repetir.

Esta operación se expresa matemáticamente como: $h[m,n] = \sum_{k,l} g[k,l] f[m+k,n+l]$

Otras aplicaciones de procesamiento espacial






Imagen Original

Antes de filtrar



Filtro de Caja Pequeño

Kernel 3×3 - desenfoque suave



Filtro de Caja Grande

Kernel 7×7 - desenfoque más fuerte

Los kernels más grandes producen efectos de desenfoque más pronunciados, ya que promedian los píxeles en un área más amplia.

Procesamiento Intermedio

Realizando bordes y detalles

Objetivos del Procesamiento Intermedio

Resaltar Estructuras Relevantes

Identificar y extraer componentes significativos de la imagen que corresponden a elementos del mundo real, separándolos del ruido y fondo.

Preparar para Etapas Avanzadas

Transformar la información visual en representaciones que faciliten algoritmos de alto nivel como clasificación o reconocimiento de objetos.

Extraer Información Geométrica

Obtener datos sobre bordes, regiones y formas que representan la estructura espacial de los objetos en la escena capturada.

Estas operaciones intermedias funcionan como un puente crítico entre la representación bruta de píxeles y la interpretación semántica de alto nivel.


Segmentación Tradicional

La segmentación divide una imagen en regiones significativas, facilitando el análisis por separado de objetos o áreas de interés.

Métodos Clásicos:

- **Umbralización global (Otsu):** Determina automáticamente un umbral óptimo basado en la distribución bimodal del histograma
- **Umbralización adaptativa:** Aplica umbrales locales que se adaptan a diferentes regiones de la imagen
- **Clustering (K-means):** Agrupa píxeles según su similitud en el espacio de características

La segmentación es fundamental para aislar objetos antes de su análisis detallado, como en esta separación objeto-fondo.




Detección de Bordos: Localizando Transiciones

Los bordes representan cambios significativos en la intensidad de la imagen y suelen corresponder a límites entre objetos o características importantes.



grayscale image



Estas técnicas proporcionan información crucial sobre la estructura geométrica para reconocimiento de formas, segmentación avanzada y análisis de contornos.

Detección de Bordes: Localizando Transiciones

Los bordes representan cambios significativos en la intensidad de la imagen y suelen corresponder a límites entre objetos o características importantes.


Filtro Sobel

Calcula los gradientes horizontal y vertical mediante la convolución con dos máscaras de 3×3 , estimando tanto la magnitud como la dirección del borde.

Algoritmo Canny

Proceso multi-etapa que incluye suavizado gaussiano, cálculo de gradientes, supresión de no-máximos y umbralización con histéresis.

intensity plot



Laplaciano

Detecta bordes buscando cruces por cero en la segunda derivada de la imagen, identificando cambios rápidos en el gradiente.

Ejemplos del Filtro Sobel






Imagen Original

Antes de la detección de bordes



Sobel Horizontal

Detecta bordes verticales




Sobel Vertical

Detecta bordes horizontales


La magnitud del gradiente completa se puede calcular tomando la raíz cuadrada de la suma de los cuadrados de los gradientes horizontal y vertical.

Ejemplos del Filtro Canny


noisy image



Canny filter, $\sigma = 1$



Canny filter, $\sigma = 3$



Morfología Matemática: Manipulando Formas



La morfología matemática aplica operaciones basadas en teoría de conjuntos a imágenes binarias o en escala de grises, utilizando elementos estructurantes que definen la geometría de la transformación.

1

Operaciones Fundamentales

- **Erosión:** Elimina píxeles del borde, reduciendo objetos y eliminando estructuras pequeñas
- **Dilatación:** Agrega píxeles al borde, expandiendo objetos y rellenando pequeños huecos
- **Apertura:** Erosión seguida de dilatación; elimina elementos pequeños manteniendo tamaño
- **Cierre:** Dilatación seguida de erosión; rellena pequeños huecos manteniendo tamaño

Estas técnicas son esenciales para limpiar imágenes segmentadas, extraer características específicas y preparar imágenes para análisis avanzado.

Transformadas: Cambiando de Dominio

Transformada de Fourier

Descompone la imagen en sus componentes de frecuencia, permitiendo:

- Filtrado pasa-bajo: elimina ruido y detalles finos
- Filtrado pasa-alto: resalta bordes y transiciones rápidas
- Análisis espectral de texturas y patrones periódicos

Transformada de Hough

Convierte la detección de formas paramétricas en búsqueda de máximos en el espacio de parámetros:

- Detección robusta de líneas incluso con oclusiones
- Identificación precisa de círculos y elipses
- Tolerancia al ruido y discontinuidades


Transformada Wavelet

Análisis multi-resolución que preserva información espacial y frecuencial:

- Compresión de imágenes (JPEG2000)
- Análisis de texturas a diferentes escalas
- Detección de características localizadas

Detección de Circunferencias

Ejemplo: Búsqueda de la circunferencia que pasa por tres puntos.



Visión Artificial Industrial. Univ. Valladolid

El Filtro Gaussiano

Un filtro de suavizado fundamental con propiedades deseables

El Filtro Gaussiano


Definición

El kernel del filtro Gaussiano se basa en la función Gaussiana 2D:

$$f(i, j) = \frac{1}{2\pi\sigma^2} e^{-\frac{i^2+j^2}{2\sigma^2}}$$

Donde σ (sigma) controla el ancho de la Gaussiana.

- El peso disminuye con la distancia desde el centro
- Teóricamente infinito, pero truncado en la práctica
- Usualmente truncado a $2-3\sigma$ del centro



La función Gaussiana crea una curva en forma de campana que da más peso a los píxeles centrales y menos a los distantes.

Propiedades del Filtro Gaussiano



Separable

El Gaussiano 2D es separable en dos Gaussianos 1D, lo que lo hace computacionalmente eficiente



Isotrópico

Simétrico rotacionalmente, aplicando un suavizado uniforme en todas las direcciones



Promedio Ponderado

Da más importancia a los píxeles centrales y gradualmente menos a los periféricos




Controlable

El parámetro σ permite un control preciso sobre la cantidad de suavizado

Estas propiedades hacen del filtro Gaussiano la elección preferida para muchas aplicaciones de procesamiento de imágenes.

Ejemplo de Filtro Gaussiano



Kernel Gaussiano de 5×5 ($\sigma=1$)

Valores normalizados dividiendo por 256

El filtro gaussiano produce un desenfoque suave y de aspecto natural que preserva los bordes mejor que el filtro de caja.

Filtro Gaussiano vs. Filtro de Caja





Imagen Original

Antes del filtrado



Filtro Gaussiano (7×7)

Desenfoque suave y de aspecto natural



Filtro de Caja (7×7)

Artefactos "pixelados" visibles

El filtro gaussiano produce resultados visualmente más agradables que el filtro de caja, con menos artefactos y una mejor preservación de la estructura de la imagen.

Aplicaciones Prácticas

El procesamiento intermedio de imágenes forma la columna vertebral de numerosas aplicaciones industriales y científicas.




Inspección Industrial

Sistemas automatizados que detectan defectos microscópicos en componentes electrónicos, superficies metálicas y productos textiles utilizando detección de bordes y análisis morfológico.




Medicina Diagnóstica

Segmentación de órganos y tejidos en imágenes de resonancia magnética y tomografía computarizada, facilitando diagnósticos precisos y planificación quirúrgica asistida.



Defensa y Vigilancia

Análisis de imágenes satelitales y radar para detectar vehículos, estructuras y cambios en terreno mediante transformadas especializadas y técnicas de segmentación robustas.



Visión Robótica


Algoritmos de detección de obstáculos en tiempo real para vehículos autónomos y robots industriales, combinando segmentación y detección de bordes con restricciones temporales.

Concepto de Mejora de Imagen

Principio Básico

La mejora funciona realzando los bordes mientras deja las áreas planas sin cambios. Esto se logra mediante:

1. Identificación de bordes (áreas de cambio rápido de intensidad)
2. Aumento del contraste en estos bordes
3. Preservación de los valores originales en regiones planas



La mejora realza los bordes aumentando el contraste entre píxeles adyacentes en las regiones límite.

Máscara de Enfoque (Unsharp Masking)

Crear Versión Borrosa

Aplicar desenfoque gaussiano a la imagen original

Calcular Máscara

Restar la imagen borrosa de la original para obtener la "máscara" (detalles de alta frecuencia)

Mejorar Original

Añadir una versión escalada de la máscara de vuelta a la imagen original

$$\textit{Sharpened} = \textit{Original} + \alpha \times (\textit{Original} - \textit{Blurred})$$

Donde α controla la cantidad de nitidez

A pesar de su nombre, la máscara de enfoque (unsharp masking) en realidad aumenta la nitidez al realzar los componentes de alta frecuencia.

Ejemplos de Nitidez





Imagen Original

Antes del enfoque



Nitidez Moderada

Detalles mejorados con artefactos mínimos



Nitidez Excesiva


Demasiado enfocado con halos visibles y
amplificación de ruido



Precauciones al Afinar la Imagen

Artefactos Comunes

- Halos alrededor de los bordes
- Amplificación de ruido
- Bordes de aspecto antinatural
- Pérdida de detalles sutiles




original

sharpened

oversharpened

El afinado excesivo crea halos antinaturales alrededor de los bordes de alto contraste y amplifica el ruido en áreas que deberían ser suaves.

El afinado es una herramienta potente, pero debe aplicarse con moderación. El objetivo es mejorar la nitidez percibida sin crear artefactos digitales obvios.



Procesamiento Avanzado

Desde la simple detección de patrones , extraer características

SIFT



Extracción de características

Los descriptores de características son representaciones matemáticas que condensan información relevante de la imagen, permitiendo comparaciones eficientes y reconocimiento de patrones.

SIFT (Scale-Invariant Feature Transform)

Detecta puntos clave invariantes a cambios de escala, rotación e iluminación. Excelente para reconocimiento de objetos.

SURF (Speeded-Up Robust Features)

Similar a SIFT pero computacionalmente más eficiente. Utiliza aproximaciones de filtros Gaussianos y representaciones integrales.

ORB (Oriented FAST and Rotated BRIEF)

Alternativa de código abierto a SIFT/SURF, optimizada para aplicaciones en tiempo real y dispositivos con recursos limitados.

HOG (Histograms of Oriented Gradients)

Captura distribuciones de gradientes direccionales, especialmente efectivo para detectar formas humanas y objetos con estructura definida.



Reconocimiento de patrones

Una vez extraídas las características, los algoritmos de aprendizaje automático clasifican o agrupan estas representaciones para identificar objetos, escenas o situaciones específicas.

SVM (Support Vector Machines)


Busca el hiperplano óptimo que separa clases en el espacio de características. Efectivo con datos de alta dimensionalidad.

KNN (K-Nearest Neighbors)

Clasifica objetos según la mayoría de sus k vecinos más cercanos. Simple pero sorprendentemente efectivo.

Random Forests

Conjunto de árboles de decisión que mejora la precisión y reduce el sobreajuste mediante votación mayoritaria.



Análisis de texturas

Las texturas proporcionan información crucial sobre la composición y naturaleza de las superficies, permitiendo discriminar entre materiales o identificar anomalías no detectables mediante otras técnicas.

LBP (Local Binary Patterns)


Codifica relaciones locales entre píxeles, generando descriptores robustos a cambios de iluminación. Altamente eficaz para clasificación de texturas.

Haralick Features

Utiliza matrices de co-ocurrencia para cuantificar propiedades como contraste, homogeneidad y correlación entre píxeles adyacentes.

Aplicaciones principales:

- Detección de defectos en superficies industriales
- Caracterización de tejidos biológicos en imágenes médicas
- Clasificación de terrenos en teledetección



Matching de imágenes



Extracción de puntos clave

Detección de características distintivas (SIFT, ORB, SURF) en ambas imágenes



Comparación de descriptores

Búsqueda de correspondencias mediante distancia euclidiana o hamming



Filtrado de correspondencias

Eliminación de falsas coincidencias mediante RANSAC u otros métodos



Transformación geométrica

Cálculo de la matriz de transformación entre imágenes

Registro médico

Alineación de imágenes de diferentes modalidades (CT, MRI) o temporales

Stitching panorámico

Unión de múltiples imágenes para crear vistas panorámicas completas

Localización robótica

Comparación de vistas actuales con mapas previos para navegación




Unión de Imágenes (Image Stitching)

La unión de imágenes combina múltiples fotografías con campos de visión superpuestos para producir una imagen panorámica o de alta resolución.

El proceso implica:

1. Detección y coincidencia de características entre imágenes
2. Estimación de transformaciones entre imágenes
3. Deformación de imágenes para alinearlas
4. Mezcla de regiones superpuestas

Esta tecnología permite la fotografía panorámica en smartphones y crea recorridos virtuales inmersivos.




Photosynth

Photosynth fue una tecnología de Microsoft que analizaba colecciones de fotos para crear modelos 3D de ubicaciones y permitir la navegación virtual.

El sistema podía:

- Emparejar características en cientos de fotos
- Determinar las posiciones y orientaciones de las cámaras
- Crear nubes de puntos que representaban la estructura 3D
- Permitir transiciones suaves entre diferentes puntos de vista


Esta tecnología demostró cómo la visión por computadora podía crear experiencias inmersivas a partir de colecciones de fotos no estructuradas.



Geometría

Transformaciones y geometría:


- Homografías y alineación de imágenes
- Modelos de cámara
- Matriz fundamental
- Geometría epipolar y estéreo
- Estructura a partir del movimiento




Visión basada en la física:

- Reflectancia y formación de imágenes
- Radiometría
- Forma a partir del sombreado
- Estéreo fotométrico
- Color







Procesamiento de Alto Nivel

Comprension semántica completa de imágenes.

Objetivos del Procesamiento de Alto Nivel



Análisis de Conceptos

Superar la detección de formas básicas para identificar **conceptos abstractos** como "peligro", "abandono" o "celebración" a partir del contenido visual.



Integración Contextual

Situar los objetos detectados dentro de un **marco contextual** que proporcione significado a la escena completa, como "accidente de tráfico" o "reunión empresarial".




Aplicación Práctica

Vincular el análisis de imágenes con **decisiones operativas** en tiempo real que resuelvan problemas concretos en entornos industriales, médicos o de seguridad.




Reconocimiento de Objetos Clásico



Detección de peatones mediante HOG+SVM

Métodos previos al Deep Learning



Haar Cascades (Viola-Jones)

Clasificadores en cascada utilizando características Haar para detección rápida de rostros. Funciona bien con caras frontales en condiciones controladas de iluminación.



HOG + SVM

Histogramas de Gradientes Orientados combinados con Máquinas de Vectores de Soporte. Robusto para detectar formas humanas en sistemas de seguridad vial.

Ventajas: Computacionalmente eficientes, requieren menos datos de entrenamiento y funcionan bien en hardware limitado como sistemas embebidos.

Análisis de Escenas


El análisis de escenas representa un nivel superior de comprensión visual donde no solo se detectan objetos individuales, sino que se establece la relación espacial y funcional entre ellos.

Componentes clave

- Detección múltiple de objetos en una misma imagen
- Análisis de relaciones espaciales (cerca/lejos, dentro/fuera)
- Interpretación de acciones (cruzando, esperando, conduciendo)

Aplicaciones principales

- Sistemas de monitorización de tráfico urbano
- Vigilancia en espacios públicos y detección de comportamientos anómalos
- Navegación autónoma de robots en entornos dinámicos y complejos



Reconocimiento Facial Clásico

Métodos tradicionales sin Deep Learning

Eigenfaces

Basado en Análisis de Componentes Principales (PCA). Representa rostros como combinaciones lineales de "rostros propios" derivados estadísticamente del conjunto de entrenamiento.

Fisherfaces

Utiliza Análisis Discriminante Lineal (LDA) para maximizar la separación entre clases de identidades. Más robusto ante cambios de iluminación que Eigenfaces.

LBPH

Local Binary Patterns Histograms captura patrones de textura facial mediante descriptores locales, ofreciendo mejor rendimiento con variaciones de pose y expresión.



Estos métodos sentaron las bases para aplicaciones de control de acceso físico, sistemas de identificación y verificación de identidad en dispositivos electrónicos antes de la era del aprendizaje profundo.



SLAM y Visión Robótica

Localización y Mapeo Simultáneos

SLAM representa uno de los desafíos fundamentales en robótica móvil: construir un mapa del entorno mientras simultáneamente se determina la posición del robot dentro de ese mapa.

Extracción de características

Detección de puntos clave en imágenes mediante algoritmos como FAST (Features from Accelerated Segment Test) para identificar puntos de interés de forma eficiente.

Emparejamiento y seguimiento

Descriptores como BRIEF (Binary Robust Independent Elementary Features) permiten asociar puntos entre frames consecutivos con bajo coste computacional.

Reconstrucción 3D

Sistemas como ORB-SLAM integran detección, descripción y optimización para crear mapas tridimensionales precisos en tiempo real.

Inpainting y Restauración Clásica

Recuperación de Áreas Dañadas

El inpainting o restauración digital permite reconstruir partes faltantes o dañadas en imágenes utilizando la información circundante, sin necesidad de técnicas de aprendizaje profundo.



Difusión de Píxeles

Propaga información de color y textura desde los bordes hacia el interior de la región dañada mediante ecuaciones diferenciales.



Métodos basados en PDEs

Técnicas inspiradas en ecuaciones de Navier-Stokes que tratan la información de color como un fluido que se propaga de forma natural.



Aplicaciones Prácticas del Procesamiento de Alto Nivel



Industria

Sistemas de inspección automática de calidad que detectan defectos microscópicos en líneas de producción a alta velocidad, sustituyendo la inspección manual y reduciendo costes.



Medicina

Diagnóstico asistido por ordenador que identifica patrones anómalos en radiografías, resonancias magnéticas y tomografías, ayudando a detectar enfermedades en etapas tempranas.



Defensa

Análisis de imágenes satelitales para detectar cambios en infraestructuras, movimientos de vehículos o alteraciones en terrenos que pueden indicar actividades relevantes para la seguridad.



Seguridad

Sistemas de reconocimiento automático de matrículas (ANPR) y detección facial en tiempo real para control de acceso y videovigilancia en entornos urbanos.

Procesamiento de Alto Nivel: Interpretación Semántica

El procesamiento de alto nivel representa la culminación de la visión por ordenador, donde la máquina no solo *ve*, sino que **comprende** lo que está observando.

01

Identificación de objetos

Reconocer y clasificar los elementos presentes en la imagen (personas, vehículos, edificios, etc.)

02

Análisis de relaciones

Establecer conexiones espaciales y funcionales entre los objetos detectados



03


Aplicación contextual

Interpretar el significado de la escena completa dentro del dominio específico de aplicación

La interpretación semántica completa cierra la brecha entre ver y comprender, permitiendo que los sistemas automatizados tomen decisiones basadas en un entendimiento contextual similar al humano.

Deep Learning Based Computer Vision





traffic light



traffic light



sign



sign



sign



person



person



car



cat




cat



dog




When to Deploy Traditional Machine Vision vs. Deep Learning-Based Image Analysis



Visión en Automóviles

Para 2015, la visión por computadora se había convertido en una parte integral de los sistemas avanzados de asistencia al conductor (ADAS), habilitando funciones como:

- Advertencia de salida de carril
- Advertencia de colisión frontal
- Detección de peatones
- Reconocimiento de señales de tráfico
- Control de crucero adaptativo



Estos sistemas utilizan cámaras y algoritmos de visión por computadora para interpretar el entorno de conducción y mejorar la seguridad.


Project Tango

Project Tango de Google fue una plataforma que utilizaba la visión por computadora para dotar a los dispositivos móviles de la capacidad de comprender su posición y orientación en el mundo físico.

Sus capacidades clave incluían:

- Seguimiento de movimiento mediante odometría visual-inercial
- Aprendizaje y mapeo de áreas
- Percepción de profundidad utilizando sensores especializados

Estas tecnologías permitieron experiencias de realidad aumentada, navegación interior y aplicaciones de escaneo 3D en dispositivos móviles.




Probador Virtual

Los probadores virtuales utilizan la visión por computadora para permitir a los clientes "probarse" ropa y accesorios sin tener que usarlos físicamente.

Estos sistemas típicamente:

- Detectan la posición y medidas del cuerpo del usuario
- Crean un modelo virtual del usuario
- Superponen las prendas de ropa de forma realista
- Rastrear el movimiento para actualizar la visualización

Esta tecnología ayuda a los compradores en línea a tomar decisiones de compra más seguras y reduce las tasas de devolución para los minoristas.



Visión por Computadora para VR

La visión por computadora juega un papel crucial en los sistemas de realidad virtual, permitiendo experiencias más inmersivas y responsivas.

Las aplicaciones clave incluyen:

- Seguimiento "inside-out" para el posicionamiento del casco
- Reconocimiento de manos y gestos para interacción sin controlador
- Mapeo del entorno para experiencias de realidad mixta
- Seguimiento ocular para renderizado foveado e interacción natural

Estas tecnologías ayudan a cerrar la brecha entre los movimientos físicos y las experiencias virtuales, creando interacciones de VR más naturales e intuitivas.




DeepFace

DeepFace fue un sistema de reconocimiento facial de aprendizaje profundo desarrollado por Facebook (ahora Meta) que logró una precisión casi humana en tareas de verificación facial.

Innovaciones clave:

- Alineación 3D de caras a una pose canónica
- Arquitectura de red neuronal profunda para la extracción de características
- Entrenamiento a gran escala con millones de imágenes faciales
- Logró un 97.35% de precisión en el benchmark Labeled Faces in the Wild

Esta tecnología demostró cómo el aprendizaje profundo podía mejorar drásticamente el rendimiento de los sistemas de visión por computadora para tareas específicas.









Deep Dream



Deep Dream es un programa de visión por computadora creado por Google que utiliza redes neuronales para encontrar y mejorar patrones en imágenes, creando apariencias oníricas y alucinógenas.


La técnica funciona amplificando los patrones que las redes neuronales han aprendido a reconocer, revelando las "representaciones internas" de las redes neuronales profundas. Esta aplicación artística demuestra cómo las redes neuronales procesan e interpretan la información visual.

GAN



Face2Face: Captura y Recreación Facial en Tiempo Real

De la Universidad de Erlangen-Nuremberg, el Instituto Max-Planck de Informática y la Universidad de Stanford




Presentado en CVPR

Por Justus Thies, Michael Zollhöfer, Marc Stamminger, Christian Theobalt, Matthias Nießner




Label




Train Model

1 training job

Your model is training and is estimated to complete in less than a minute.



Deploy





Ejemplo de Proyecto donde se utilizan
estos algoritmos - Deteccion de Cracks
con concreto

- **Typical & Obvious Cracks**

Original




Pre-Processed



- **Typical & Obvious Cracks**

Original




Pre-Processed



- **Blurry Cracks**

Original



Pre-Processed



- **Blurry Cracks**

Original

Pre-Processed



Should we label these pixels?

- **Blurry Cracks**

Original



Pre-Processed




85

Should we label these pixels?

- **Discontinuous Short Cracks**

Original

Pre-Processed



Should we label these pixels?

- **Scratch-like Cracks**

Original



Pre-Processed



Should we label these pixels?

Cracks on Smooth Surface

- **Scratch-like Cracks**

Original

Pre-Processed




Should we label these pixels?

- Cracks next to/on Stains

Original



Pre-Processed



89


Should we label these pixels?

- Cracks next to/on Stains

Original



Pre-Processed




90

Should we label these pixels?

- **When labeling, we encountered a special case: pictures containing spider webs.**

We couldn't tell the difference between webs and cracks.



91

There are some photos in folder SpiderWebCases, they are unlabeled. **If there are any cracks need to be labeled, please mark them.**