

Visión Artificial

Clase 4

Jorge Vasquez, PhD


Universidad Adolfo Ibañez

Redes Neuronales para el Reconocimiento de Objetos


La evolución de las redes neuronales y sus aplicaciones en la visión por computadora moderna.



Neuronas: De Biológicas a Artificiales



Estructura de la neurona biológica



Modelo de neurona artificial (perceptrón)


Las neuronas artificiales imitan a las neuronas biológicas al:

- Recibir entradas ponderadas (como las dendritas)
- Aplicar una función de activación (como el procesamiento del soma)
- Producir una señal de salida (como la transmisión del axón)

Inspiración en el Cerebro Humano


Las redes neuronales se inspiran en cómo el cerebro humano procesa la información visual:

- La corteza visual procesa la información jerárquicamente
- Los niveles inferiores detectan características simples (bordes, esquinas)
- Los niveles superiores combinan características para reconocer objetos complejos
- Este procesamiento jerárquico es la base de las redes neuronales modernas




Conectisismo (1873)

- Diferentes Combinaciones de Input puede crear diferentes outputs




Conectisismo (1875)

- Diferentes intensidades de activacion de A genera diferencias cuando X e Y estan activadas




Modelo Sináptico (1920 app)

- Modelo de una neurona
- **Sinapsis de excitación:** transmite un input de peso a la neurona
- **Sinapsis de inhibición:** cualquier señal de inhibición previene que la neurona se encienda.




Modelo Sináptico (1940 app)

- Mculloch and Pitts transformaron esos modelos de sinapsis en puertas booleanas.
- Simples redes de neuronas puede generar operaciones booleanas



Modelo Sináptico (1940 app)

- Mcullock and Pitts transformaron esos modelos de sinapsis en puertas booleanas.
- Simples redes de neuronas puede generar operaciones booleanas



Modelo Sináptico (1940 app)

- Operaciones booleanas pueden explicar en forma simple percepciones muy complejas




Figure 2. Net explaining the heat illusion. Neuron 3 (heat sensation) fires if and only if it receives two inputs, represented by the lines terminating on its body. This happens when either neuron 1 (heat reception) fires or neuron 2 (cold reception) fires once and then immediately stops firing. When neuron 2 fires twice in a row, the intermediate (unnumbered) neurons excite neuron 4 rather than neuron 3, generating

Mecanismo de Aprendizaje (1950 app)


- Donald Hebb
- La organización del comportamiento, 1949
 - Neuronas que se activan entre ellas, están conectadas.
 - Si la neurona X repetidamente activa neurona Y, la sinapsis que las conecta es mayor

- In a mathematical model:


$$w_{xy} = w_{xy} + \eta xy$$

- Weight of the connection from input neuron x to output neuron y

Perceptron de Rosenblatt (1950 app)



Perceptron: La creación de todo!



Algoritmo de Aprendizaje de Rosenblatt

- Se actualizan los pesos cada vez que el resultado del perceptron esta errado

$$\mathbf{w} = \mathbf{w} + \eta(d(\mathbf{x}) - y(\mathbf{x}))\mathbf{x}$$

Sequential Learning:

$d(x)$ is the desired output in response to input $\mathbf{x}$

$y(x)$ is the actual output in response to $\mathbf{x}$

El Perceptrón:


Bloque Fundamental de las Redes Neuronales

El perceptrón es la unidad fundamental de las redes neuronales:


- Toma múltiples entradas ($x_1, x_2, \dots, x_n$)
- Asigna pesos a cada entrada ($w_1, w_2, \dots, w_n$)
- Calcula la suma ponderada más el sesgo
- Aplica una función de activación para producir la salida

Matemáticamente: $\text{salida} = f(\sum(w_i x_i) + b)$

Donde f es una función de activación como sigmoide, ReLU o tanh



Múltiples de parametros por aprender



Paso 1: Capa oculta (hidden layer)

- La entrada es una imagen de $224 \times 224 \times 3$ (alto $\times$ ancho $\times$ canales RGB).
- El número total de nodos (o características planas) es:

$$224 \times 224 \times 3 = 150,528$$

Paso 2: Capa de salida (output layer)

- Se definen **5 nodos de salida** (por ejemplo, 5 clases de clasificación).

$$\text{Output nodes} = 5$$

Paso 3: Pesos entre hidden $\rightarrow$ output

Cada nodo de la capa oculta se conecta con cada nodo de la salida.


Por lo tanto, el número de pesos entrenables es:

$$150,528 \times 5 = 752,640$$

Estos son los **parámetros entrenables** de la red.

Perceptrón Multicapa (MLP)

Los MLP extienden el concepto de perceptrón a redes con:



Capa de Entrada

Recibe los datos brutos (p. ej., valores de píxeles de una imagen)

Capas Ocultas


Procesan y transforman los datos a través de conexiones ponderadas y funciones de activación

Capa de Salida

Produce las predicciones finales (p. ej., probabilidades de clase de objeto)


Los MLP pueden aprender patrones complejos, pero son ineficientes para el procesamiento de imágenes debido a su estructura completamente conectada.

Inserción de la función de pérdida



Las redes neuronales son máquinas conexionistas

- La maquina tiene multiples unidades de procesamiento
- El programa es al final, las conexiones entre unidades
- Las conexiones son como la memoria




Redes Neuronales Convolucionales (CNNs)


Las CNNs revolucionaron la visión por computadora al introducir:

- Capas convolucionales que detectan patrones locales
- Compartición de parámetros que reduce el tamaño del modelo
- Jerarquía espacial que captura características cada vez más complejas

Ventaja clave: Las CNNs mantienen las relaciones espaciales en las imágenes, a diferencia de las MLPs que aplanan la entrada.



Trabajo pionero: LeNet-5 de Yann LeCun (1998) para el reconocimiento de dígitos escritos a mano



Arquitectura CNN: De LeNet a AlexNet

LeNet-5 (1998)

Primera arquitectura de CNN exitosa para el reconocimiento de dígitos, desarrollada por Yann LeCun

1

2

AlexNet (2012)

Ganó la competición ImageNet, redujo la tasa de error del 26% al 15,3%, y desencadenó la revolución del aprendizaje profundo.

Características innovadoras de AlexNet:


- Arquitectura más profunda (8 capas frente a las 5 de LeNet)
- Funciones de activación ReLU en lugar de tanh
- Regularización Dropout para prevenir el sobreajuste
- Técnicas de aumento de datos para expandir los datos de entrenamiento

Componentes de CNN: Convolución y Agrupación

Convolución

Los filtros se deslizan por la imagen para detectar patrones:


- Las primeras capas detectan bordes y texturas
- Las capas más profundas detectan formas complejas
- Las capas finales detectan objetos completos



Agrupación (Pooling)

Reduce las dimensiones espaciales conservando características importantes:

- Max pooling: toma el valor máximo en la región
- Average pooling: toma el valor promedio
- Reduce el cálculo y previene el sobreajuste




CNN para Reconocimiento de Caracteres

El reconocimiento de caracteres fue una de las primeras aplicaciones exitosas de las CNN:


- Conjunto de datos MNIST: 60,000 dígitos escritos a mano para entrenamiento y 10,000 para prueba
- LeNet-5 logró una precisión superior al 99%
- Las CNN modernas logran una precisión casi perfecta

Los mismos principios se aplican a tareas de reconocimiento más complejas, solo con redes más profundas.



Flujo de procesamiento de CNN para reconocimiento de dígitos

Cronología de Detección de Objetos



R-CNN (2014)

CNN basada en regiones: propone regiones y luego clasifica cada región por separado



Fast R-CNN (2015)

Procesa la imagen completa una vez, luego clasifica las regiones usando características compartidas



Faster R-CNN (2015)

Agrega una Red de Propuesta de Regiones (RPN) para generar propuestas de región




YOLO (2016)

"You Only Look Once": detección de una sola pasada para aplicaciones en tiempo real

R-CNN (2014)


CNN basada en regiones: propone regiones y luego clasifica cada región por separado

R-CNN: *Regions with CNN features*



Fast R-CNN (2015)

Procesa la imagen completa una vez, luego clasifica las regiones usando características compartidas




R-CNN rápido

Mask R-CNN: Segmentación de Instancias

Mask R-CNN extiende Faster R-CNN para realizar segmentación de instancias:

- Detecta objetos con cuadros delimitadores
- Añade una rama para predecir máscaras de segmentación
- Produce límites de objetos perfectos a nivel de píxel
- Permite aplicaciones como la conducción autónoma, la imagen médica y la robótica




Arquitectura de Mask R-CNN y ejemplo de salida


YOLO: Solo miras una vez

YOLO revolucionó la detección de objetos con un enfoque de una sola pasada:


- Divide la imagen en celdas de cuadrícula
- Cada celda predice cajas delimitadoras y probabilidades de clase
- Mucho más rápido que los enfoques basados en regiones
- Evolucionó de YOLOv1 (2016) a YOLO v13 creo que vamos!



Unet





MobileNet



Transformers para Vision (2020)

Los ViT funcionan dividiendo las imágenes en parches más pequeños, cada uno de los cuales se procesa a través de capas de autoatención para capturar las relaciones entre ellos.






Conjuntos de Datos Comunes para Visión Artificial



ImageNet


14M imágenes en 20K clases; un punto de referencia estándar para la clasificación de imágenes

Estos conjuntos de datos proporcionan puntos de referencia estandarizados para comparar el rendimiento de los modelos y avanzar en el campo.



CIFAR-10/100


60K imágenes pequeñas (32x32) a color en 10 o 100 clases; utilizado para modelos más pequeños



MS COCO


328K imágenes con 2.5M instancias en 91 clases; para detección y segmentación

Conjuntos de Datos Especializados para Visión por Computadora




MegaFace

4.7M imágenes de 672K identidades para investigación en reconocimiento facial



MPII Human Pose

25K imágenes con 40K personas en 410 actividades para estimación de pose



Berkeley DeepDrive

100K videos para investigación y desarrollo de vehículos autónomos


Los conjuntos de datos específicos de dominio permiten aplicaciones especializadas en campos como la conducción autónoma, la biometría y la interacción persona-computadora.

Técnicas de Aumento de Datos

El aumento de datos expande artificialmente los conjuntos de datos de entrenamiento al crear variaciones:

- Transformaciones geométricas: rotación, volteo, escalado
- Ajustes de color: brillo, contraste, saturación
- Borrado aleatorio: simula oclusión
- Adelgazamiento y engrosamiento: operaciones morfológicas
- Recorte y relleno

Beneficios: Reduce el sobreajuste, mejora la generalización y aumenta la robustez del modelo



Ejemplos de técnicas de aumento de datos aplicadas a imágenes de entrenamiento

Agenda

1

Problemas de Visión por Computadora

Comprendiendo los desafíos fundamentales en visión por computadora, incluyendo el reconocimiento de imágenes, la detección de objetos y la segmentación

2

Fundamentos de Redes Neuronales

Explorando cómo el cerebro humano inspiró las redes neuronales artificiales y su evolución

3

Arquitecturas de Red Avanzadas

Examinando CNNs, R-CNN, YOLO y otras arquitecturas para el reconocimiento de objetos

4

Conjuntos de Datos y Aumento de Datos


Revisando conjuntos de datos comunes y técnicas para mejorar los datos de entrenamiento

Problemas de Visión por Computadora

Challenges and Limitations of Computer Vision




Problemas de escalabilidad



Problemas de implementacion y soporte

FASE DE ENTRENAMIENTO


1 Carga de imágenes




2 Caracterizar



3 Capacitar




4 Obtención de resultados



5 Validar




6 Refinar




Integrar en la máquina

FASE DE IMPLEMENTACIÓN


1 Adquirir imágenes



2 Analizar e interpretar



3 Obtener resultado de aprobado/ no aprobado



APROBADO NO APROBADO

Tareas en escenarios complejos

La visión por computadora abarca varios problemas distintos con complejidad creciente:

- Reconocimiento de Imágenes: Clasificación de imágenes completas
- Detección de Objetos: Localización y clasificación de objetos
- Segmentación Semántica: Clasificación de cada píxel
- Segmentación de Instancias: Identificación de instancias de objetos individuales

Cada problema requiere diferentes enfoques y arquitecturas de red para ser resuelto eficazmente.



Input Image



Detección de Objetos vs. Segmentación




Detección de Objetos

Localiza objetos en una imagen y los clasifica con cuadros delimitadores



Segmentación de Instancias

Identifica instancias individuales de objetos a nivel de píxel



Segmentación Semántica

Clasifica cada píxel sin distinguir instancias de objetos

Conclusiones Clave

Redes Neuronales Reflejan la Biología

Las arquitecturas de visión por computadora se inspiran en el sistema visual humano, con procesamiento jerárquico desde características simples hasta complejas.

CNNs Revolucionaron la Visión por Computadora

Las Redes Neuronales Convolucionales (CNNs) preservan las relaciones espaciales en las imágenes, permitiendo mejoras dramáticas en las tareas de reconocimiento.

La Detección de Objetos Ha Evolucionado Rápidamente Rápidamente

Desde R-CNN hasta YOLO, las arquitecturas se han vuelto más rápidas y precisas, permitiendo aplicaciones en tiempo real.

Los Datos Son Críticos

Los conjuntos de datos grandes y diversos y las técnicas de aumento de datos son esenciales para entrenar modelos robustos que generalicen bien.