

2025

SMART +
SUSTAINABLE

Liderar la construcción
de un mundo sostenible

Tópicos Emergentes de la IA

FACULTAD DE
INGENIERÍA Y CIENCIAS



SMART + *SUSTAINABLE*

Liderar la construcción **de un mundo sostenible**

Fundamentos de IA, contextualización de modelos y estrategias de prompting

Johan Piña – Reinel Tabares Soto

Docentes

Noviembre 2025



Reinel Tabares Soto

- Ingeniero Electrónico - Universidad Nacional de Colombia (UN)
- Ingeniero de Sistemas - Universidad de Caldas
- Magister en Automatización Industrial - UN
- Especialista en Deep Learning - DeepLearning.AI
- Doctor en Ingeniería - Universidad Autónoma de Manizales



Johan Sebastian Piña


- Ingeniero Electrónico y Biomédico - Universidad Autónoma de Manizales (UAM)
- Estudiante de maestría en Bioinformática - UAM
- AI developer - GobLab Universidad Adolfo Ibáñez (Chile)
- Especialista en Deep Learning - DeepLearning.AI

Agenda

- Introducción a la Inteligencia Artificial
- Inteligencia Artificial tradicional
- Deep Learning
- Machine y Deep Learning en la práctica
- Inteligencia Artificial Generativa
- Modelos grandes del lenguaje (LLMs)
- Algunas herramientas de IA Generativa
- Contextualización de Modelos
- Técnica de prompting
- Retrieval Augmented Generation

Introducción a la Inteligencia Artificial

Artificial Intelligence (AI), Machine Learning (ML) and Deep Learning (DL)




Línea temporal de la Inteligencia Artificial



1950's

INTELIGENCIA ARTIFICIAL


Cualquier técnica que permite a los ordenadores imitar el comportamiento humano.



1980's

MACHINE LEARNING


Técnicas de IA que otorgan a los ordenadores la habilidad de aprender sin ser explícitamente programados para hacerlo.



2010's

DEEP LEARNING

Un subconjunto del ML que hace viable el cálculo de redes neuronales multicapa.




2020's

IA GENERATIVA MODELOS FUNDACIONALES

Modelos altamente adaptables que proporcionan una estructura base para múltiples aplicaciones.

¿Qué se necesita para hacer IA?





Inteligencia Artificial tradicional

Diagrama de flujo de un sistema con IA

Problema a resolver
+
Datos

Software con IA






PREPROCESAMIENTO

PROCESAMIENTO

DESARROLLO

POST-PROCESAMIENTO



Durante el desarrollo del proyecto

Después del desarrollo del proyecto

De observaciones a predicciones mediante modelos

Observaciones → predicciones

Imagen del paciente → tiene patología


Fragmento de texto → sentimiento

Series temporales de finanzas → tendencia del valor


Descripción de la casa → valor de mercado

Perfil del cliente → producto a comprar


Se trata de crear modelos



Modelos Análíticos




De observaciones a predicciones mediante modelos



$$\begin{aligned}\frac{1}{2}Mv^2 + \frac{1}{2}mv^2 - Mgh + mgh \sin \theta &= 0 \\ \frac{1}{2}(m + M)v^2 &= gh(M - m \sin \theta) \\ v &= \sqrt{\frac{2gh(M - m \sin \theta)}{m + M}}\end{aligned}$$

De observaciones a predicciones mediante modelos



~~$$\begin{aligned}
 \frac{1}{2}Mv^2 + \frac{1}{2}mv^2 - Mgh + mgh \sin \theta &= 0 \\
 \frac{1}{2}(m+M)v^2 &= Mh - mh \sin \theta \\
 v &= \sqrt{\frac{2gh(M - m \sin \theta)}{m+M}}
 \end{aligned}$$~~

De observaciones a predicciones mediante modelos

DATOS DE ENTRENAMIENTO

DATOS DE VALIDACIÓN

Datos separados para la calibración del modelo

X, y no visto durante el entrenamiento → medir la capacidad de generalización

Datos disponibles → (X, y) pares

$X \rightarrow y$

Datos de ejemplo

Modelo de
plantilla

Calibración del
modelo

Modelo

Rendimiento en entrenamiento (calibración) BIEN BIEN MAL

Rendimiento en validación (Generalización) BIEN MAL MAL

OBJETIVO: crear pruebas que respalden las decisiones sobre los datos

X nuevos

y predicciones

$$\begin{aligned} \frac{1}{2}Mv^2 + \frac{1}{2}mv^2 - Mgh + mgh \sin \theta &= 0 \\ \frac{1}{2}(m+M)v^2 &= (M-m)\sin \theta \\ v &= \sqrt{\frac{2gh(M-m)\sin \theta}{m+M}} \end{aligned}$$

De observaciones a predicciones mediante modelos

DATOS DE ENTRENAMIENTO

DATOS DE VALIDACIÓN

Datos separados para la calibración del modelo

X, y no visto durante el entrenamiento → medir la capacidad de generalización

D

DEBE ENFRENTARSE A PROBLEMAS MAL DEFINIDOS

plantilla

modelo

Rendimiento en entrenamiento (calibración) BIEN BIEN MAL





Rendimiento en validación (Generalización) BIEN MAL MAL

OBJETIVO: crear pruebas que respalden las decisiones sobre los datos


y predicciones

$$= \sqrt{\frac{2gh(M + m \sin \theta)}{m + M}}$$

ML: Técnicas y Oportunidades




Comparando el aprendizaje supervisado, semisupervisado y no supervisado



Deep Learning


¿Por qué y cuándo usar deep learning?



<https://www.coursera.org/specializations/deep-learning>

Algunas tareas resueltas con DL


- Clasificación de imágenes a un nivel casi humano (Steganalysis)
<https://peerj.com/articles/cs-616/>
- Traducción automática mejorada (<https://www.deepl.com/es/translator>).
- Conversión de texto a voz mejorada.
- Asistentes digitales como Alexa - Amazon.
- Conducción autónoma a nivel humano.
- Orientación de anuncios mejorada como la utilizada por Google y Bing.
- Responder preguntas en lenguaje natural.



Contexto


- Modela la relación entre señales de entrada y señales de salida derivado de nuestro entendimiento de cómo funciona el cerebro ante un estímulo.
- Tal como nuestro cerebro utiliza una red de neuronas, las redes neuronales artificiales utilizan neuronas artificiales o nodos para resolver problemas complejos.
- Cantidad de **neuronas** por especies:
 - Humano: 85,000 millones de neuronas
 - Gato: 1,000 millones de neuronas
 - Ratón: 75 millones de neuronas

Perceptrón





$$y(x) = f\left(\sum_{i=1}^n w_i x_i\right)$$

Perceptrón multicapa



Sistema bioinspirado



Una neurona artificial o un perceptrón modela una neurona que tiene un conjunto de entradas, a cada una de las cuales se le asigna un peso específico. Luego, la neurona calcula alguna función en estas entradas ponderadas y da la salida.

Ventajas y desventajas

Ventajas

- Se pueden usar para clasificación o regresión
- Modelan patrones más complejos que casi cualquier algoritmo
- No asume nada sobre las relaciones subyacentes del dominio

Desventajas


- El entrenamiento es extremadamente intensivo en computación
- Es necesario estar monitoreando el sobreajuste
- Resulta en una *caja negra* que es difícil de interpretar

DL: Progreso y Avance

Neurona

Perceptrón

1957 - Frank Rosenblatt




Red Neuronal

Capas ocultas

1986, Rumelhart, Hinton & Williams


Retropropagación



Red Neuronal Convolucional (CNN)

LeNet-5

1998, Yann LeCun et al.



Boom de las CNNs

AlexNet

2012 - Krizhevsky, Sutskever, Hinton

Multicapa

Avances Post-2012


- **GANs**: 2014, Ian Goodfellow et al.
- **ResNet**: 2015, Kaiming He et al.

IA Generativa Modelos Fundacionales

Transformers 2017, Vaswani et al.

- **ChatGPT**: Noviembre 2022, GPT-3.5, Boom.
- **Gemini**: 2023, LLM multimodal.
- **Mixtral**: 2023, local, sin restricciones.
- **SAM, SORA, LLAMA3, ChatGPT 4o...**



Proyección




- **Lanzamiento:** un potencial avance tecnológico pone en marcha las cosas.
- **Pico de expectativas sobredimensionadas:** la publicidad temprana produce una serie de historias de éxito, a menudo acompañadas de decenas de fracasos.
- **Abismo de desilusión:** el interés se desvanece a medida que los experimentos y las implementaciones no se cumplen.
- **Rampa de consolidación:** más ejemplos de cómo la tecnología puede beneficiar a la empresa comienzan a materializarse y a entenderse mejor.
- **Meseta de productividad:** la adopción generalizada comienza a despegar y los criterios para evaluar la viabilidad del proveedor están definidos con mayor claridad.

Proyección

Hype Cycle for Artificial Intelligence, 2025



Hype Cycle for Emerging Technologies, 2025




Gartner.

<https://www.gartner.com/en/articles/hype-cycle-for-artificial-intelligence>

Hype Cycle of Emerging Technologies, 2025

Plateau will be reached: ○ < 2 years ● 2 – 5 years ● 5 – 10 years ▲ >10 years ✗ obsolete before plateau




Source: Gartner
© Gartner, Inc. and/or its affiliates. All rights reserved. CTMKT_3957950

Gartner.

Hype Cycle for Generative AI, 2025

Plateau will be reached: ○ < 2 yrs. ● 2-5 yrs. ● 5-10 yrs. ▲ >10 yrs.



Source: Gartner
© 2025 Gartner, Inc. and/or its affiliates. All rights reserved. CTMKT_3881100

Gartner.

CORRELACIÓN VS. CAUSALIDAD

CAUSALIDAD

Cuando una cosa (una causa) es responsable de que ocurra otra cosa (un efecto)



CORRELACIÓN

Cuando dos o más cosas parecen estar relacionadas

EN VERANO



Aumentan las ventas de helados



Aumentan las quemaduras solares

Las ventas de helados y las tasas de quemaduras solares están correlacionadas



¿Significa esto que comer helado aumenta el riesgo de sufrir una quemadura solar?

¡La correlación no siempre significa causalidad!



En días soleados, es más probable que la gente:



coma helados



se queme con el sol




¡Una correlación no siempre significa que una cosa causa otra!

Basada en infografía de Eufic



Machine y Deep Learning en la práctica

Métricas



How many selected items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

How many relevant items are selected?

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

$$\text{Precision} = \frac{tp}{tp + fp}$$

$$\text{Recall} = \frac{tp}{tp + fn}$$

$$\text{Accuracy} = \frac{tp + tn}{tp + tn + fp + fn}$$

Precision: cuantas casas con plomo acerté de las que predije como casas con plomo (calidad de la respuesta)

Recall (True Positive Rate): Es cuantas casas con plomo acerté de todas las casas con plomo que había(cantidad de las respuestas).

Accuracy: Es cuantas casas con plomo y sin plomo predijo correctamente del total

Métricas

Predicción Realidad	Tiene plomo	No tiene plomo
Tiene plomo	2	0
No tiene plomo	1	1

Precision = $2/3 = 66.6\%$
Recall = $2/2 = 100\%$
Accuracy = $3/4 = 75\%$

Métricas

Predicción	Tiene plomo	No tiene plomo
Realidad		
Tiene plomo	500 (TP)	1000 (FN)
No tiene plomo	500 (FP)	10000 (TN)

Precision = 500/1000 = 50%

Recall = 500/1500 = 33.3%

Accuracy = 10500/12000 = 87.5%

$$\text{Precision} = \frac{tp}{tp + fp}$$

$$\text{Recall} = \frac{tp}{tp + fn}$$


$$\text{Accuracy} = \frac{tp + tn}{tp + tn + fp + fn}$$

Predicción	Tiene Covid	No tiene Covid
Realidad		
Tiene Covid	2000 (TP)	10 (FN)
No tiene Covid	500 (FP)	2000 (TN)

Precision = 2000/2500 = 80%

Recall = 2000/2010 = 99.5%

Accuracy = 4000/4510 = 88.7%



Accuracy: Es cuantas casas con plomo y sin plomo predije correctamente del total

Precision: Es cuantas casas que yo dije que tenían plomo que realmente tienen plomo con respecto las que yo dije que tenían plomo

Recall: Es cuantas casas con plomo acerté de todas las casas con plomo que había.

$$\text{Precision} = \frac{tp}{tp + fp}$$

$$\text{Recall} = \frac{tp}{tp + fn}$$

$$\text{Accuracy} = \frac{tp + tn}{tp + tn + fp + fn}$$

Métricas

- Media armónica de precision y recall
- Precision y recall son igual de importantes

$$\begin{aligned} \text{F1 Score} &= \frac{2}{\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}} \\ &= \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \end{aligned}$$

Práctica de ML

Bibliografía: [link de acceso](#)

Notebook 1: [link de acceso](#)

Dataset: [link de acceso](#)

- Carga de la base de datos
- Eliminación de características por conocimiento experto
- Análisis exploratorio de datos (Exploratory data analysis - EDA)
- Proceso de división de datos de entrenamiento y testing
- Método K-Nearest Neighbors (KNN)
- Métricas
- Métricas gráficas
- KNN con preprocesamiento de las features
- Balance de clases

- Carga de la base de datos
- División en datos de entrenamiento y testing
- Aprendizaje supervisado: Clasificación
- Aprendizaje supervisado: Regresión
- Importancia de características

Notebook 2: [link de acceso](#)

```

8 import { ErrorResponse }
9 import { Routes } from "@
10 import { publicLocalizatio
11
12 const RESEND_TIME = 90;
13
14 function Auth() {
15   const [phoneNumber, setPhone
16   const [otp, setOtp] = useStat
17   const [step, setStep] = useSta
18   const [time, setTime] = useSta
19   const router = useRouter();
20   const {
21     data: otpResponse,
22     isPending,
23     mutateAsync: mutateGetOtp,
24   } = useMutation({
25     mutationFn: getOtp,
26   });
27
28   const { mutateAsync: mutateCheckOtp,
29
30   const phoneNumberHandler = (e)

```

[Link](#)

- Librerías
- Carga de la base de datos
- Red Neuronal Convolutacional - CNN 2D
- Red Neuronal Artificial - ANN
- Transfer Learning
- Despliegue de modelos de DL

Inteligencia Artificial Generativa

¿Qué quiere decir el término IA generativa?

La inteligencia artificial generativa (IA generativa) crea **nuevo contenido**, como texto, imágenes, música y código, **a partir de datos existentes**.



shutterstock.com • 2283125803

Que puede hacer la IA generativa



La inteligencia artificial generativa (IA generativa) es un tipo de inteligencia artificial (IA) que utiliza modelos de aprendizaje automático y algoritmos para crear contenido nuevo, como texto, imágenes, música, audio y vídeos.

Familias de IA generativas según los medios de entrada y de salida

Texto a texto  Traducir, resumir, buscar información, aprendizaje en general, corregir textos. ChatGPT, Peer, Perplexity, Bard, Copilot, Copymatic, Jasper, TutorAI, Bing.	Texto a imagen  Generar imágenes, inspirarse, crear arte, crear avatares, crear logos. Midjourney, DALL-E, Bing Image Creator, Stable Diffusion, Adobe Firefly, Fotor, Craiyon.	Texto a audio  Generar ficheros de audio, audiolibros, podcast, crear locuciones con voces de otras personas o la propia, traducir videos, crear temas musicales con parámetros seleccionados, modificar otros temas musicales. AudioLM, Whisper, Jukebox, Murf, Mubert, AudioStrip (per separar música i veu), Boomy.
Text a vídeo  Generar videos con características específicas seleccionadas, editar videos, traducir videos. Phenaki, Sundify, Synthesia	Texto a código  Generar o mejorar el propio código, documentarlo. Alphacode, Codex, GitHub, Copilot, Ghostwriter, Tabnine, SourceAI.	Texto a ciencia  Obtener respuestas con base científica, hacer una lluvia de ideas con la investigación existente, encontrar artículos científicos relacionados con las respuestas de la IA. Elicit, Consensus, Scite.
Texto a 3D  Generar imágenes para utilizar en videojuegos, obtener una imagen más completa y profunda de un objeto, mejorar las simulaciones o el diseño de elementos de realidad virtual. Dreamfusion, Magic3d.	Imagen a texto  Proveer descripciones más precisas o resumidas de imágenes, mejorar la accesibilidad en el caso de discapacidades visuales. Flamingo, VisualGPT.	Otras  Descubrir nuevos algoritmos, realizar multitud de tareas de IA más allá del nivel de especialización que ahora mismo tienen las herramientas de IA. También el caso de las IA multimodales que pueden procesar diferentes tipos de datos Alphetensor, GATO, CoDI.

* El panorama en cuanto a herramientas soportadas con inteligencia artificial cambia deprisa, con algunas que se posicionan y después quedan obsoletas. Los ejemplos proporcionados pueden variar y casi todas tienen versión gratuita o periodo de prueba


Modelos en tiempo real - Omni




AI studio

Redes neuronales para IA generativa

GANs: Redes Generativas adversariales



Transformers pre-entrenados



Autoencoders




Figura 1. Arquitectura funcional del Transformador, base de LLMs como el de ChatGPT

<https://poloclub.github.io/transformer-explainer/>

IA para crear imágenes

DALL-E

[Dall-e](#)



[Leonardo.ai](#)



Midjourney

[Mid Journey](#)



[Gemini](#)

IA para audio y videos

IIElevenLabs

[ElevenLabs](#)

 OpenAI
Sora

[SORA](#)

Veo 3


[Veo3](#)

Inteligencia Artificial General (AGI)



Investigación pionera en el camino hacia la AGI

“Creemos que nuestra investigación eventualmente conducirá a la inteligencia artificial general, un sistema que puede resolver problemas a nivel humano. Construir AGI segura y beneficiosa es nuestra misión.”



<https://marketing4all.es/inteligencia-artificial/que-es-la-asi-la-super-inteligencia-artificial/>



¿Inteligencia Artificial General? AGI

- Un sueño que aún sigue en progreso - Hay avances significativos.
- Algunos modelos de lenguaje importantes:
 - **GPT-5:** La próxima generación de OpenAI. Se espera que tenga capacidades de razonamiento y generación cercanas a las de un experto humano en diversas tareas.
 - **Claude 3 (Opus, Sonnet, Haiku):** Familia de modelos de Anthropic. La versión más reciente, **Claude Sonnet 4.5** (septiembre de 2025), se destaca como uno de los mejores modelos del mundo para tareas de codificación.
 - **Gemini:** La serie de modelos de Google. Las versiones más recientes como **Gemini 2.5 Pro** y **Flash** (junio de 2025) son multimodales y ofrecen mejoras significativas en rendimiento.
 - **Llama 3.1:** El modelo de código abierto más grande y capaz de Meta (julio de 2024). Incluye una versión de **405 mil millones de parámetros**, compitiendo directamente con los mejores modelos privados.
 - **Modelos Open Source de OpenAI (gpt-oss):** OpenAI ha lanzado dos potentes modelos de código abierto (**gpt-oss-120B** y **gpt-oss-20b** en agosto de 2025) para fomentar la innovación y el acceso a la tecnología.
 - **DeepSeek-Coder V2:** Un modelo de código abierto especializado y de alto rendimiento en tareas relacionadas con la programación, desde la generación hasta la comprensión de código.
 - **Grok 4:** El modelo de xAI (la empresa de Elon Musk), con acceso a información en tiempo real. Su versión **Grok 4 Fast** (septiembre de 2025) ofrece mayor velocidad y eficiencia.
 - **o3-mini:** Un modelo de OpenAI enfocado en el razonamiento, diseñado para abordar tareas complejas que requieren lógica y análisis profundo.


Modelos grandes del lenguaje

¿Qué es un modelo de lenguaje LLM?

LARGE LANGUAGE MODEL





Los LLMs son los autocompletar del celular



¿Cómo funcionan los LLM's?



Reasoning + Test-Time Compute



Non-Reasoning Model VS Reasoning Model

Non-Reasoning Model

What is the value of a?

Please provide the context you are working with. **Abstain**

What is the value of a?


Reasoning Model

8010 Tokens
292s

Hmm... The user might want... If a ... but, Wait... If... Alternatively... Perhaps... Alternatively... But, Maybe... since... Check again... Alternatively... Might... \n However \n\n It is possible... Tricky... Hmm... Read the problem once again... If... In physics... Alternatively... In math... In science... In chemistry... In biology... However... Maybe... If that's the case... Revisit the question again... The common way... must give an answer... then...

The value of a is 2. **MiP-Overthink**

MoE : Mixture of Experts



<https://llamaimodel.com/requirements/>

Algunas herramientas de IA Generativa

IA en la mano de todos...




Gemini



Claude

Grok



perplexity



LMarena

IA generativa con la función de Deep Research



[ChatGPT](#)



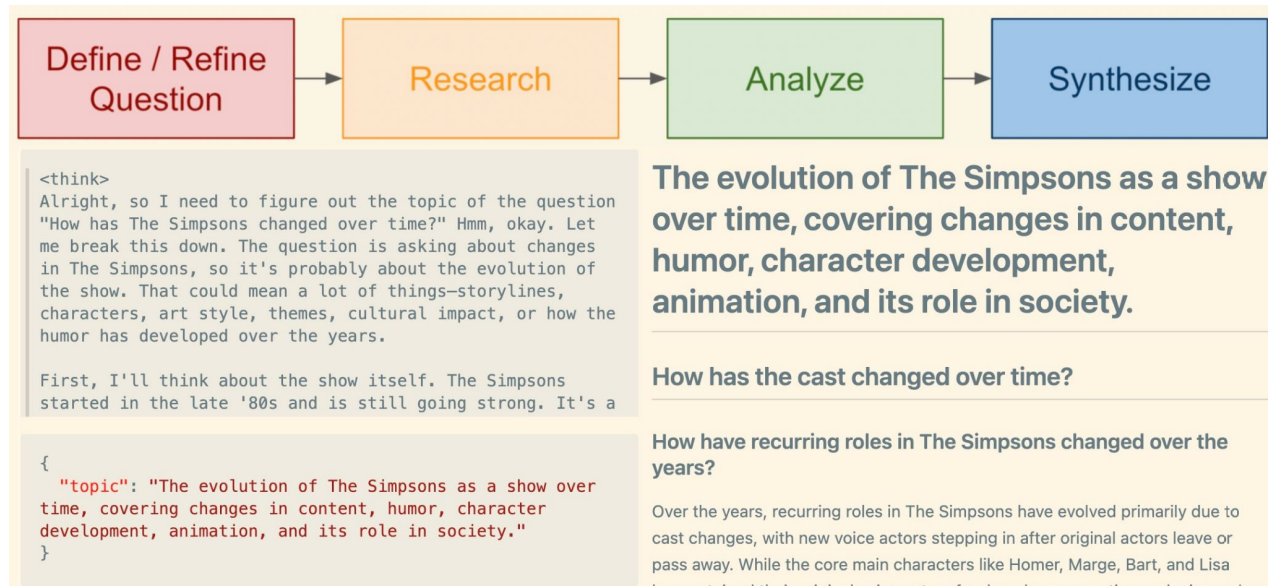

[Gemini](#)



[perplexity](#)



[Grok](#)



Resultados

Prompt: Dame los avances de los últimos 6 meses en IA generativa



[ChatGPT](#)



[perplexity](#)



[Gemini](#)



[Grok](#)

Algunas herramientas para mejorar(nos) con IA



[Elicit](https://www.elicitai.com/)



[Consensus](https://www.consensus.com/)

Algunas herramientas para mejorar(nos) con IA



[Napkin](#)



[notebook](#)




[Lovable](#)




[LMarena](#)

Contextualización de Modelos

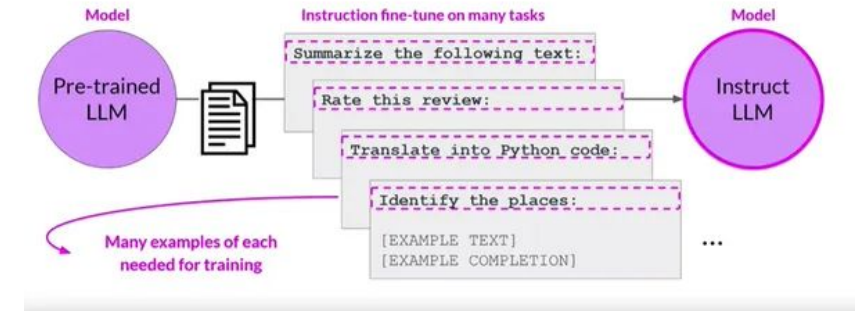
¿Cómo puedo hacer que un LLM no alucine y sepa de mi negocio?



prompting




RAG



Fine
tuning

Fine tuning de modelos de LLMs



Técnica de prompting

¿Cómo sacarle provecho a los modelos del lenguaje?

Elementos de un buen prompt

Actúa como un tutor que desglosa temas complejos en explicaciones fáciles.

Quiero que expliques el proceso de la fotosíntesis a un estudiante de 14 años de edad, para ayudarle con la preparación del examen de biología.

Tu respuesta debe ser de 300 palabras, escrita en un tono amigable y educativo.

Rol: Pídele que asuma un rol

Objetivo: ¿Qué quieres que haga la IA?

Audiencia: Especifica a quién va dirigido

Contexto: ¿Qué necesita saber la herramienta?

Límites: Establece tu propia dirección y limitación

Consejo 1

Dar instrucciones claras

Utiliza comandos que indiquen a la herramienta de IA lo que desea generar, como "explicar", "traducir", "resumir" o "comparar".

Consejo 2

Proporcionar contexto

Agrega contexto e información que pueda ayudar a la herramienta a comprender mejor la tarea. Por ejemplo, menciona el tipo de proyecto, como "relato corto", "informe" o "esquema".

Consejo 3

Iterar y experimentar

Prueba diferentes instrucciones y técnicas si no obtienes los resultados que deseas. La indicación (*prompt*) puede ser como un experimento que puede requerir varias rondas de iteraciones.

Tips para realizar prompts - Anatomía de un buen “prompt”

Rol, Objetivo, Audiencia, Contexto, Límites, Salida (opcional)

Ej. “Explicame la PGU”

Rol: Actúa como un experto en comunicación del IPS en Chile, especializado en lenguaje ciudadano.

Objetivo: Quiero que redactes el borrador de un correo electrónico para explicar de forma sencilla por qué se rechazó una solicitud de PGU.

Audiencia: El destinatario es un adulto mayor de 70 años que no está familiarizado con términos técnicos.

Contexto: El motivo del rechazo es que el postulante no pertenece al 90% más vulnerable de la población de 65 años o más, según el Registro Social de Hogares.

Límites: La respuesta debe tener un máximo de 150 palabras, usar un tono empático y no técnico, y terminar sugiriendo que puede actualizar su RSH si su situación ha cambiado.

Anatomía de un buen prompt para modelos razonadores

La Anatomía de un Prompt o1

Quiero una lista de las mejores caminatas de longitud media a menos de dos horas de San Francisco.

Cada caminata debe ofrecer una aventura genial y única, y ser menos conocida.

Para cada caminata, devuelve el nombre de la caminata tal como lo encontraría en AllTrails, luego proporciona la dirección de inicio de la caminata, la dirección de finalización de la caminata, la distancia, el tiempo de conducción, la duración de la caminata y qué la hace una aventura genial y única.

Devuelve las 3 mejores.

Ten cuidado de asegurarte de que el nombre del sendero sea correcto, que realmente exista y que el tiempo sea correcto.

--

Para el contexto: ¡mi novia y yo caminamos muchísimo! Hemos hecho prácticamente todas las caminatas locales de San Francisco, ya sea en Presidio o en Golden Gate Park. Definitivamente queremos salir de la ciudad; recientemente hicimos Mount Tam por completo, desde el inicio de las escaleras hasta Stinson. Fue muy largo y definitivamente estamos de humor para algo diferente este fin de semana. Las vistas al océano seguirían siendo agradables. Nos encanta la comida deliciosa. Algo que me encantó de la caminata en Mount Tam es que termina con una celebración (¡llegando a la ciudad para desayunar!). Los antiguos silos de misiles y demás cerca de Discovery Point son geniales, pero ya he hecho esa caminata probablemente unas 20 veces en este punto. No nos veremos durante unas semanas (ella tiene que quedarse en Los Ángeles por trabajo), así que la singularidad aquí realmente cuenta.

Meta

Formato de la respuesta

Advertencias

Contexto adicional

Tips para realizar prompts - “zero shot”

Esta es la técnica más común y la que usamos intuitivamente. Simplemente le pedimos a la IA que haga algo sin darle ningún ejemplo previo. Los "Prompts Ideales" como el anterior son, en realidad, prompts zero-shot bien estructurados.

¿Cuándo usarla? Para tareas directas donde la IA ya tiene mucho entrenamiento, como resumir, traducir o redactar.

Ej. “resume el último cambio a la ley del Subsidio Único Familiar.”

Con la técnica: **“Actúa como un analista legal del IPS en Chile. Resume en 3 puntos clave (usando viñetas) los cambios más recientes a la Ley 18.020 sobre el Subsidio Familiar. El resumen es para una circular interna dirigida a los jefes de sucursal.”**

Le muestras a la IA un único ejemplo para que entienda el patrón que debe seguir.

- **¿Cuándo usarla?** Ideal para tareas de clasificación simple o para seguir un formato específico que es difícil de explicar solo con palabras.

Contexto del Ejemplo: Queremos clasificar los correos de los ciudadanos para dirigirlos al departamento correcto.

Prompt Sin la Técnica: "Clasifica este correo: 'Hola, mi nombre es Juan Soto y no he recibido el pago del Aporte Familiar Permanente de este año'."

- *Problema: La IA podría responder "Consulta de pago", pero quizás necesitamos categorías internas específicas.*

Prompt Con la Técnica One-Shot: "Tu tarea es clasificar correos de ciudadanos en una de las siguientes categorías: 'Consulta de Beneficios', 'Problema de Pago', 'Actualización de Datos'."

Ejemplo: Correo: 'Quería saber si me corresponde el Bono de Invierno.' -> Categoría: 'Consulta de Beneficios'.

Ahora, clasifica este: Correo: 'Hola, mi nombre es Juan Soto y no he recibido el pago del Aporte Familiar Permanente de este año.' -> Categoría:

Le proporcionas a la IA varios ejemplos (**shots**) para que aprenda patrones más complejos o matices en la tarea.

- **¿Cuándo usarla?** Para tareas con múltiples variables, extracción de datos específicos de texto no estructurado o cuando la lógica es sutil.

Contexto del Ejemplo: Queremos extraer el RUT y el beneficio específico de una consulta para registrarla rápidamente en un sistema.

Prompt Sin la Técnica: "Extrae el RUT y el beneficio de este texto: 'Buenas tardes, mi RUT es 12.345.678-9 y mi consulta es sobre la PGU de mi madre'."

- *Problema: Puede funcionar, pero fallará con frases más complejas o indirectas.*

Prompt Con la Técnica Few-Shot: "Extrae el RUT de la persona y el Beneficio consultado de los siguientes textos, siguiendo el formato 'RUT: [número], Beneficio: [nombre]'."

Ejemplo 1: Texto: 'Hola, soy Ana del 15.111.222-3, y quería saber del Aporte Familiar.' -> RUT: 15.111.222-3, Beneficio: Aporte Familiar Permanente.

Ejemplo 2: Texto: 'Llamo por mi abuela, RUT 5.888.999-K, para ver si le toca el Bono de Invierno.' -> RUT: 5.888.999-K, Beneficio: Bono de Invierno.

Ejemplo 3: Texto: 'Mi consulta es por el Subsidio de Cesantía, mi cédula es 18.777.666-1.' -> RUT: 18.777.666-1, Beneficio: Subsidio de Cesantía.

Ahora, extrae los datos de este texto: Texto: 'Buenas tardes, mi RUT es 12.345.678-9 y mi consulta es sobre la PGU de mi madre.' ->

Esta técnica se puede combinar con todas las anteriores. Consiste en decirle a la IA exactamente *cómo* estructurar su respuesta. Es increíblemente útil para automatizar la entrada de datos a otros sistemas o para crear material fácil de usar.

Formatos Comunes: Tabla, lista, JSON, viñetas, HTML, etc.

Contexto del Ejemplo: Necesitamos crear una tabla comparativa para una presentación interna sobre dos beneficios.

Prompt Sin la Técnica: "Compara la PGU y el Aporte Familiar Permanente."

- *Problema: Te dará un párrafo largo, difícil de leer y de copiar en una diapositiva.*

Prompt Con la Técnica de Formato Específico: "Actúa como un analista de políticas públicas del IPS. Crea una tabla en formato Markdown que compare los requisitos principales de la Pensión Garantizada Universal (PGU) y el Aporte Familiar Permanente (ex Bono Marzo).

Las columnas deben ser: - Beneficio - Requisito de Edad - Requisito de Focalización (RSH) - Forma de Pago

Asegúrate de que la información esté actualizada a la normativa vigente en Chile."

Cadenas de pensamiento - Precursores de los razonadores

La técnica de **Cadenas de Pensamiento** (Chain-of-Thought o CoT) es una de las más poderosas para mejorar la calidad y la fiabilidad de las respuestas de la IA, especialmente para el trabajo en el sector público, donde la precisión es crucial.

La técnica de Cadena de Pensamiento consiste en instruir al modelo para que desglose un problema complejo en una serie de pasos lógicos intermedios antes de llegar a la conclusión. En lugar de pedirle una respuesta directa, le pedimos que "piense en voz alta".

Ej: "Una usuaria de 66 años, chilena, pensionada con una AFP desde los 65 y con 2 hijos nacidos vivos. ¿Le corresponde el Bono por Hijo?"

"Actúa como un experto previsional del IPS. Analiza *paso a paso*** si a la siguiente usuaria le corresponde el Bono por Hijo. Desglosa tu razonamiento evaluando cada uno de los requisitos principales del beneficio y al final concluye si es elegible o no.**

Datos de la usuaria: - Edad: 66 años. - Nacionalidad: Chilena, con residencia en Chile. - Hijos: 2, ambos nacidos vivos. - Situación previsional: Se pensionó a los 65 años y está afiliada a una AFP."

Cadenas de pensamiento - Ejemplo 2

PROMPT: "¿Qué hace un trabajador si su empleador no le paga la Asignación Familiar?"

Frases Clave para Activar la Cadena de Pensamiento:

Para terminar, usa estas frases "mágicas" que pueden añadir a sus prompts para activar el razonamiento paso a paso:

- **"Piensa paso a paso..."**
- **"Desglosa tu razonamiento..."**
- **"Analiza la situación evaluando primero [Criterio A], luego [Criterio B], y finalmente [Criterio C]."**
- **"Antes de dar la respuesta final, explica la lógica detrás de tu conclusión."**
- **"Genera un plan detallado en orden cronológico..."**

Retrieval Augmented Generation

What is RAG?


Retrieving relevant data and generating accurate, context-aware responses to improve AI outputs.

R Retrieve | Find useful information


A Augment | Add it to the AI's knowledge

G Generate | Create a better response


Flujo de RAG



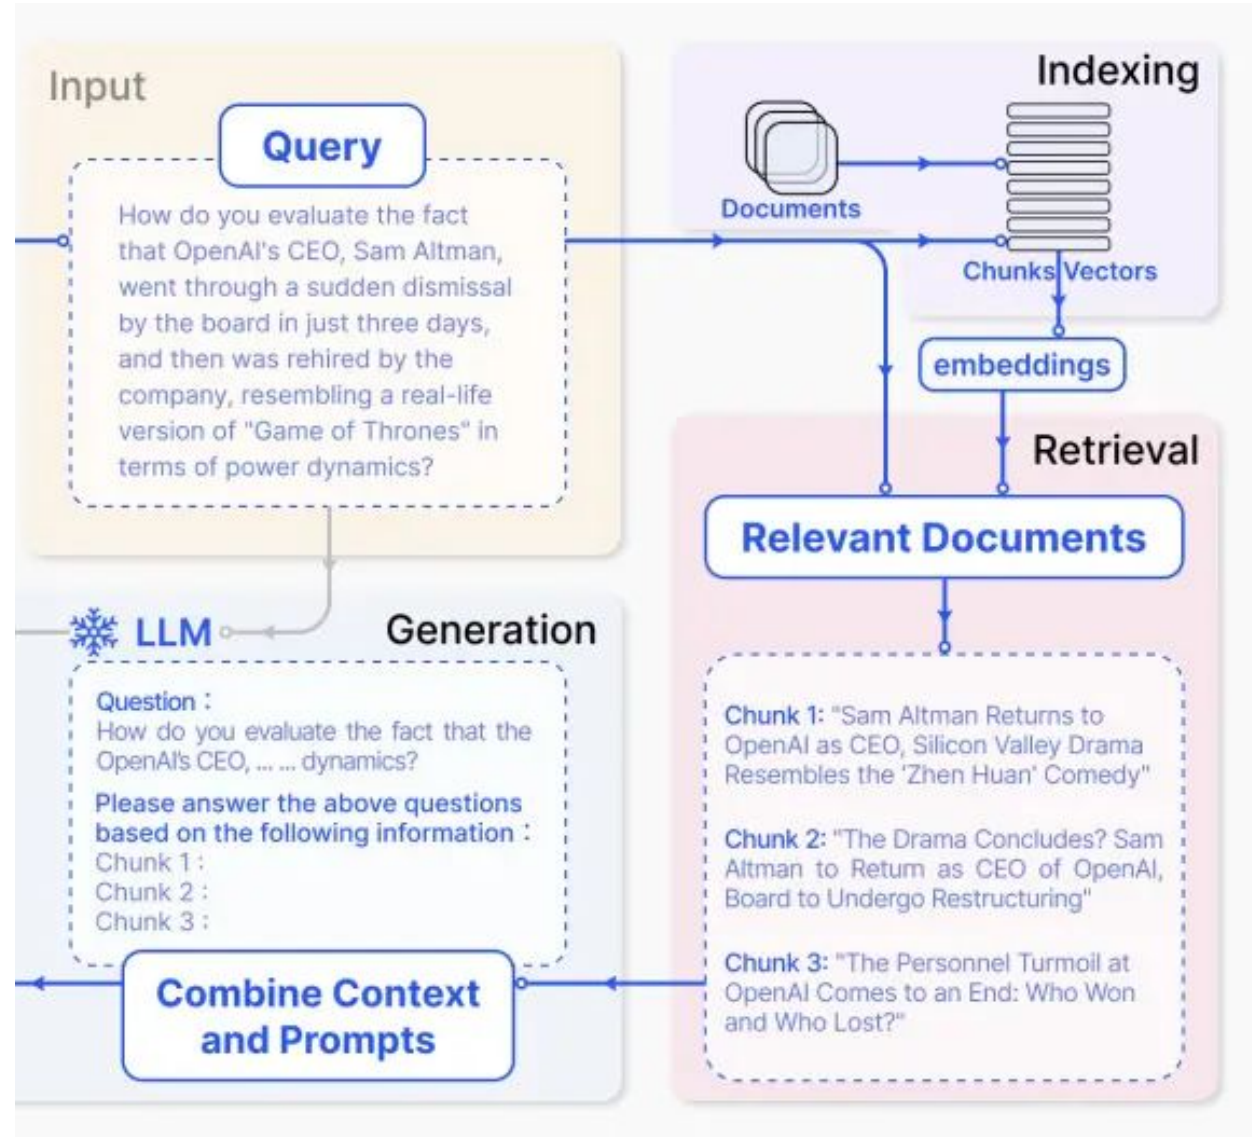
Typical RAG Indexing Pipeline



Retrieval

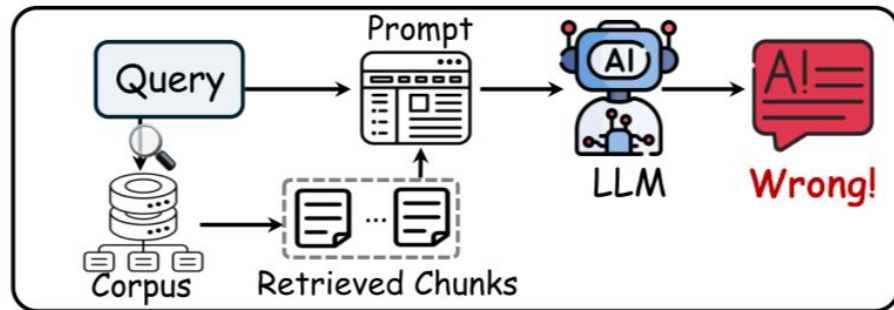


Augmentation & generation

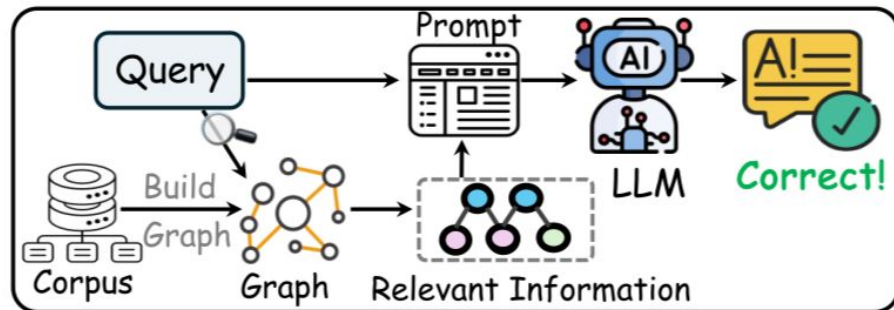


Variaciones de RAG


[Link notebook](#)




Vanilla RAG




Graph-based RAG



Naive RAG



Advanced RAG



Modular RAG

Fine-Tuning para ajuste de modelos

Tamaño de los modelos de lenguaje


Llama 3.1 Requirements: Taming the 405B Frontier Model

The Llama 3.1 family, headlined by its colossal 405B model, was Meta’s entry into the frontier-level AI space. Running the 405B model is a monumental undertaking that is fundamentally a datacenter-scale operation. “Local deployment” for this model means running it on a private, self-managed server cluster. The 8B and 70B variants, however, are far more accessible and offer incredible power for their respective hardware tiers.



Model	Parameters (Active / Total)	Key Architecture	Min. VRAM (Quantized)	Rec. System RAM	Feasibility & Target User
Llama 3.1 405B	405B / 405B	Dense Text-only	250+ GB	512+ GB	Datacenter Only. Needs a cluster of high-end GPUs (e.g., 4x-8x NVIDIA H100s) and specialized frameworks.
Llama 3.1 70B	70.6B / 70.6B	Dense Text-only	48 GB	64 GB	Prosumer / Workstation. The classic high-performance choice for users with professional or dual-GPU setups.
Llama 3.1 8B	8B / 8B	Dense Text-only	12 GB	16 GB	Consumer. A fantastic starting point that runs well on single high-VRAM consumer GPUs like the RTX 3090/4090.

<https://llamaimodel.com/requirements/>


Precisión de los parámetros de los LLM's



“Quantization” de modelos



(a) FP32



(b) INT8


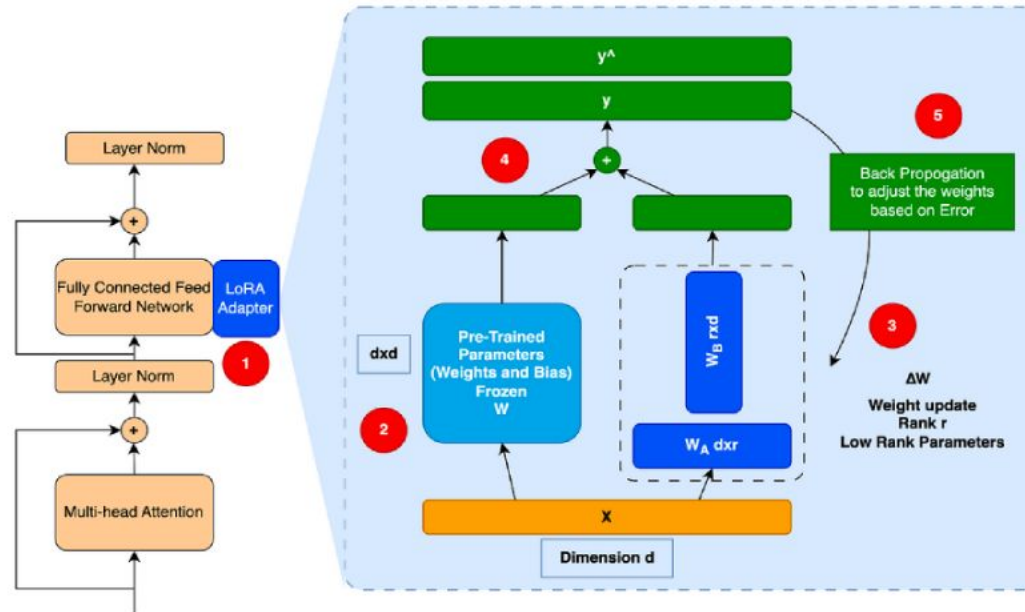
¿Qué necesitamos para ajustar un LLM?

Datasets > Demo > Describe your changes...
 Diff view
Merge changes ...

Search rows... + Create row	kjk48 (snapshot main) ↔ kjk48 (version #9)	Oimou (snapshot main) ↔ Oimou (version #9)
Dataset Studio Logs Evaluate	SYSTEM You're a helpful assistant called Anna working for Chevrolet. You're a helpful assistant called Anna working for Chevrolet. USER Hi Anna, I'm looking for a vehicle with advanced tech features. What Chevrolet models should I consider and how do they compare to others? Hi Anna, I'm looking for a vehicle with advanced tech features. What Chevrolet models should I consider and how do they compare to others? ASSISTANT - Sorry I can't recommend any other brands. + I can't provide any comparisons with other brands, but the Cevrolet Traverse is highly regarded for its comfort and versatility.	

LoRa: Low Rank Adaptation


Embracing Efficiency and Adaptability in LLM Training: The Future of PEFT and LoRA



<https://poloclub.github.io/transformer-explainer/>

QLoRa: Quantized LoRa

Working of QLoRA



Quantize the
Base Model



Add Low-Rank
Adapters




Fine-Tune Only
Adapters




Merge or Keep
Adapters
Separate


LoRA



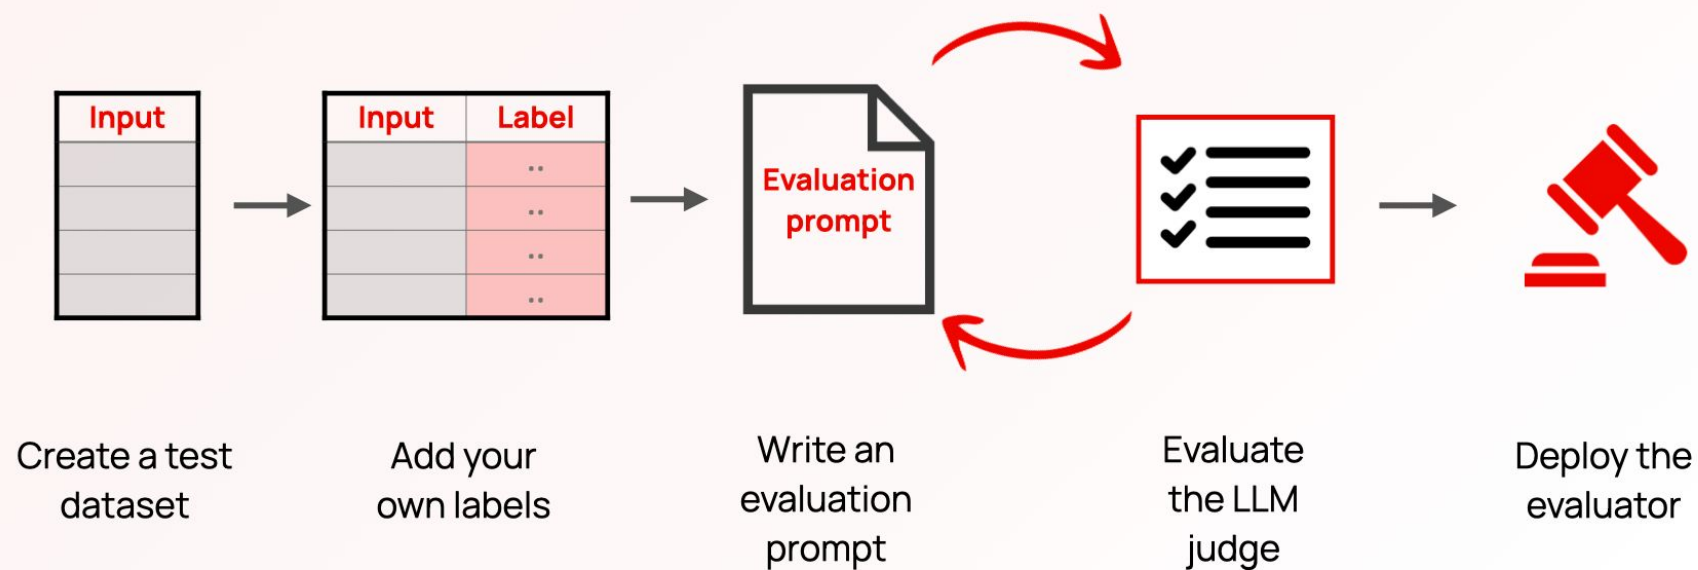
QLoRA



Pasos para hacer un fine tuning




¿Cómo evaluamos que el modelo está bien?




¿Qué diferencias tenemos con RAG?

Fine-Tuning



RAG



Gracias!!!
johan.pina@uai.cl
Reinel.tabares@uai.cl

SMART +
SUSTAINABLE

Liderar la construcción **de un mundo sostenible**


Introducción a Agentes de IA y Automatización Low-Code

Johan Piña – Reinel Tabares Soto


Docentes

Noviembre 2025


Prompt vs Flow vs Agentes



Prompt Vs Workflow vs Agente






IA generativa es el valor agregado de buenos datos y casos de negocio claros.




Agentes de IA

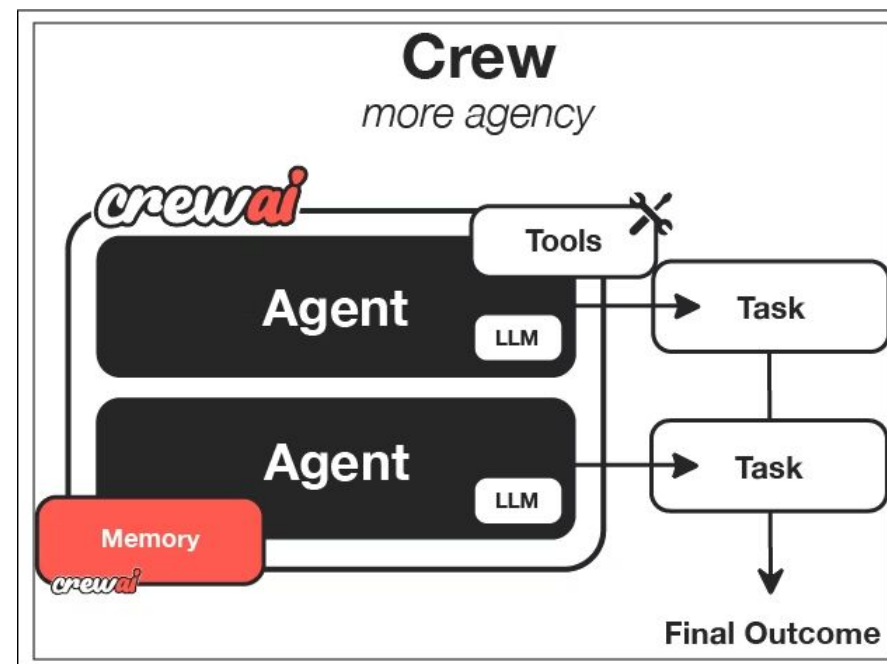
Components of an AI Agent









CrewAI example



Human in the loop




HUMAN-IN-THE-LOOP



MCP


Model Context Protocol

MCP architecture




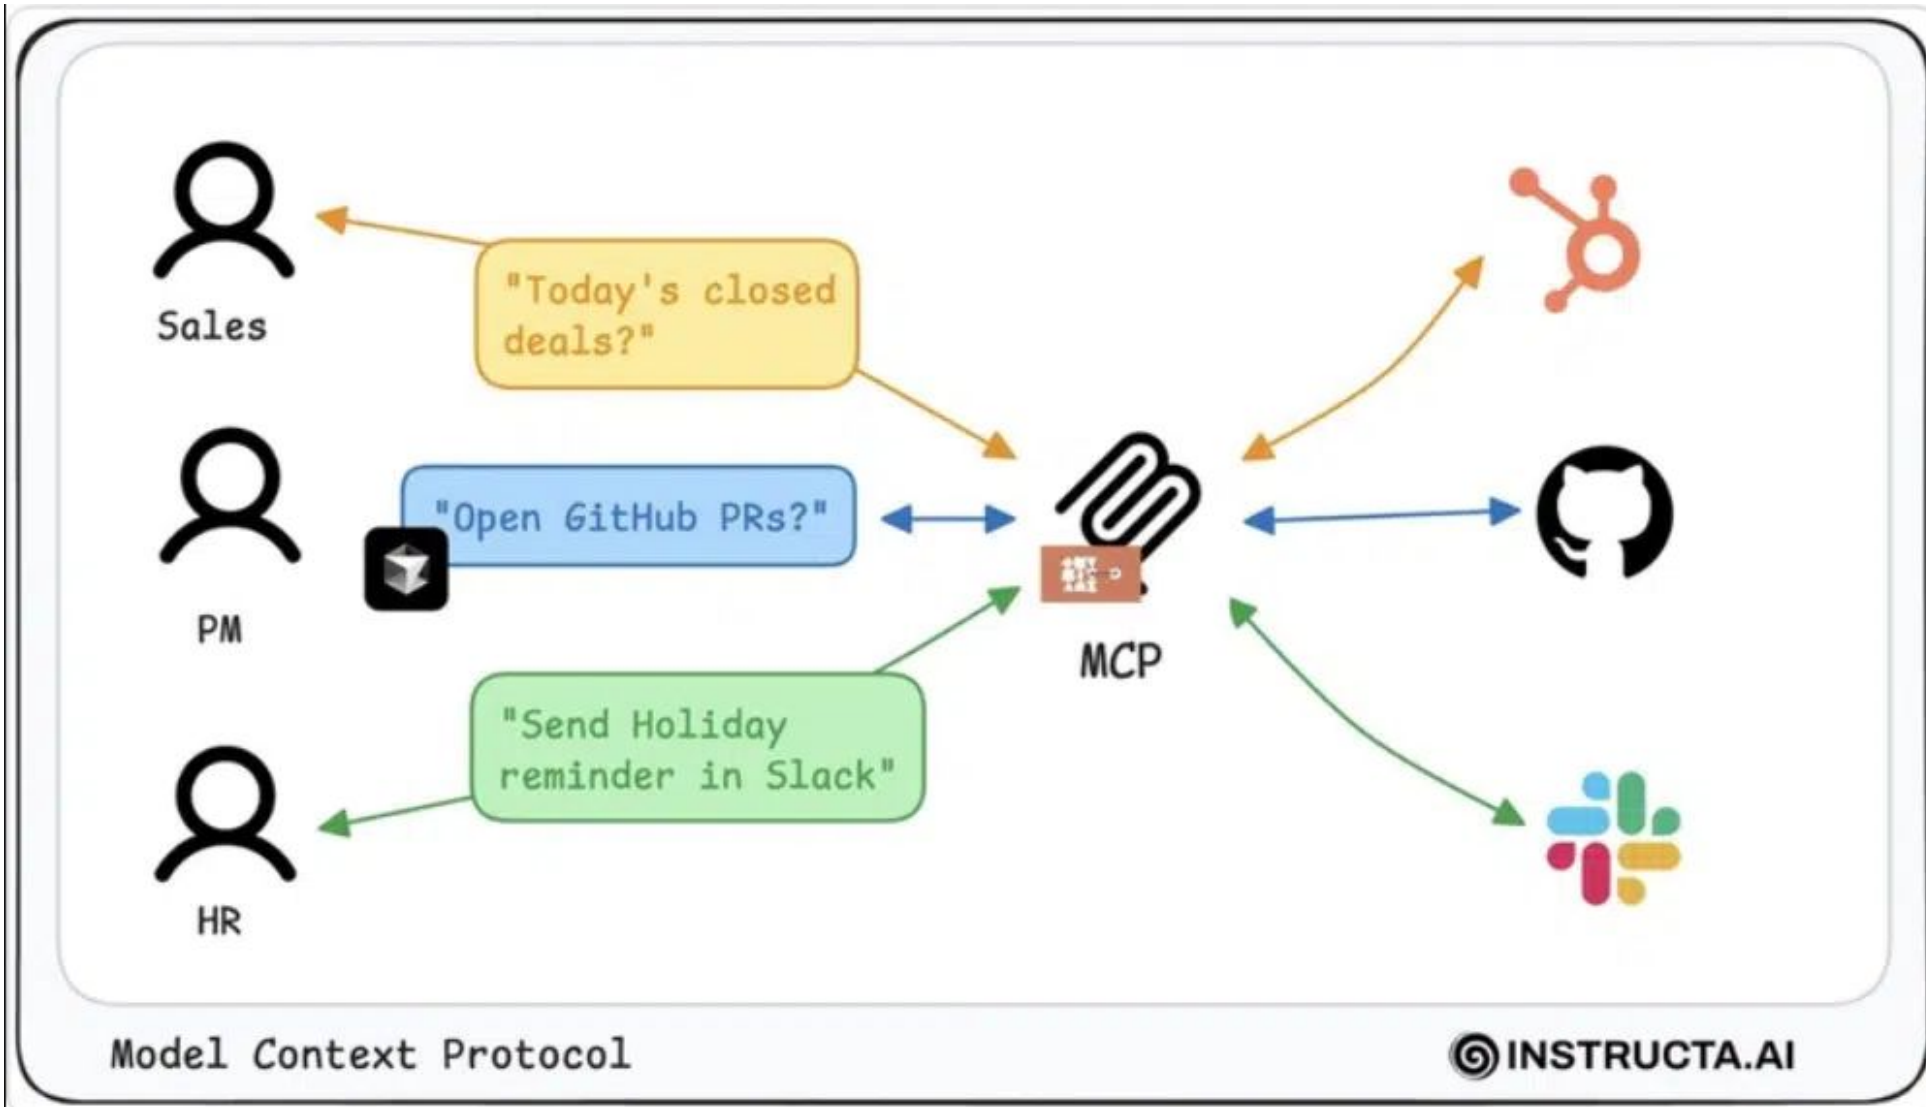
descope

Before MCP




After MCP





Vibe coding: Prototipado y desarrollo de apps a la medida



Lovable

Agentes de Código dentro de nuestro PC : Orquestando nuestros procesos

```
10 # A button to let it snow 🌨️
11 if st.button("Send snow! ❄️"):
12     st.snow()
13
```

PROBLEMS OUTPUT DEBUG CONSOLE **TERMINAL** PORTS

node + - [] []

jackwoth-mac:my-app jackwoth\$ gemini

> GEMINI

Tips for getting started:

1. Ask questions, edit files, or run commands.
2. Be specific for the best results.
3. `/help` for more information.

> Do you want to connect your VS Code editor to Gemini CLI?

If you select Yes, we'll install an extension that allows the CLI to access your open files and display diffs directly in VS Code.

1. Yes
2. No (esc)
3. No, don't ask again

~/dev/gemini-cli-demos/my-app (main*)

no sandbox (see /docs)

gemini-2.5-pro (100% context left)



OpenAI Codex

