

¿por qué usar capas escondidas?
curso
Deep Learning

Prof. M.A.Valle
E-MAIL: mvalle@uft.cl

Importancia de capas escondidas

Para entender por qué son importantes las capas escondidas, utilizaremos como ejemplo un problema de clasificación binario sin capa escondida.

Importancia de capas escondidas

Para entender por qué son importantes las capas escondidas, utilizaremos como ejemplo un problema de clasificación binario sin capa escondida.

Sin capa escondida????'

Qué nombre tiene esto?????

Importancia de capas escondidas

Para entender por qué son importantes las capas escondidas, utilizaremos como ejemplo un problema de clasificación binario sin capa escondida.

Utilizaremos un recurso interactivo de Google:

<http://playground.tensorflow.org/>

Que es una app web en donde podemos crear facilmente una red feedforward y ver los efectos del entrenamiento en tiempo real.

Importancia de capas escondidas

Para entender por qué son importantes las capas escondidas, utilizaremos como ejemplo un problema de clasificación binario sin capa escondida.

Utilizaremos un recurso interactivo de Google:


<http://playground.tensorflow.org/>

Que es una app web en donde podemos crear facilmente una red feedforward y ver los efectos del entrenamiento en tiempo real.

Importancia de capas escondidas

NO HIDDEN LAYER

Primero veamos el caso de sin capa escondida con datos 2,1




Como vemos, sin capa escondida (un perceptron) es capaz de aprender decision boundaries que son lineales.

Importancia de capas escondidas

NO HIDDEN LAYER

Si ahora utilizamos los datos con datos 1,1




Vemos que el perceptron no es capaz de aprender una entorno de decision circular. De hecho podemos ver el missfit de clasificacion de las instancias.

Importancia de capas escondidas

NO HIDDEN LAYER

Con los datos con datos 1,1, vemos que los datos siguen un controno circular, por lo que podríamos pensar en utilizar los valores cuadráticos como atributos para ayudar.




Vemos que en efecto, luego de algo de entrenamiento la neurona a sido capaz de encontrar el entorno de decisión circular.

Importancia de capas escondidas

NO HIDDEN LAYER

Ahora si seleccionamos datos 1,2, por mas que incluyamos las variables al cuadrado, el perceptron no es capaz de recuperar o aprender la separación entre clases.




Dado la distribución del set de datos, ¿qué atributos podríamos agregar para ayudar al perceptron?

Importancia de capas escondidas

NO HIDDEN LAYER

Ahora si seleccionamos datos 1,2,incluyendo $X_1 \cdot X_2$.



En efecto. La distribución de los datos sugiere una función hiperbólica, por eso es que al incluir como atributo $X_1 \cdot X_2$, el perceptron reconoce el espacio de decisión correctamente.

Importancia de capas escondidas

NO HIDDEN LAYER

¿Qué conclusiones podemos obtener?

Importancia de capas escondidas

NO HIDDEN LAYER


¿Qué conclusiones podemos obtener?

1. Al usar un perceptron o una simple neurona sin capa escondida, ésta sólo es capaz de aprender espacios de decisión lineales.
2. Es muy importante el “feature transformations”. Al elevar al cuadrado o multiplicar variables, estamos acercándonos a la verdadera relación entre variables. Sin embargo, con muchas variables, esto puede ser muy difícil de adivinar.

Importancia de capas escondidas

CON HIDDEN LAYER

Seleccionemos datos 1,2. Agregamos una capa escondida con 3 neuronas y sólo los dos atributos originales X_1 y X_2 . De esta forma la red podría aprender 3 decision boundaries.




Una NN con una capa escondida y activación no lineal se considera como un “Universal Function Approximator”, es decir, capaz de aprender cualquier función matemática. Note que ya no tenemos que adivinar features compuestos entre variables.

Importancia de capas escondidas

CON HIDDEN LAYER, regularización (intuición)

Seleccionemos datos 1,2. Agregamos una capa escondida con 8 neuronas y sólo los dos atributos originales X_1 y X_2 . De esta forma la red podría aprender decision boundaries mucho más complejo.



Si hay datos anómalos o ruido, la red va a tratar de aprender la no linealidad introducida por este ruido.

Importancia de capas escondidas

CON HIDDEN LAYER, regularización (intuición)

En el caso anterior, vemos que la espacio de decisión está realmente tratando de acomodarse a las muestras ruidosas para reducir el LOSS.

Pero como se puede ver, esto NO es una buena señal porque está “deforman” el espacio de decisión correcto.

Este fenómeno se denomina **OVERFITTING**.

En tales casos, el error sobre el set de entrenamiento va disminuyendo, pero la red no lo hace bien luego sobre datos de testeo (o no vistos). Aquí nos fijamos porque el Test loss va aumentando (esquina superior derecha).


También se ve que algunos pesos sinápticos se hace muy grandes. Esto se puede rectificar agregando algunas restricciones a los valores de los pesos. Esto se denomina

REGULARIZATION. Consiste en imponer restricciones a los parámetros de la red.

Importancia de capas escondidas

CON HIDDEN LAYER, regularización (intuición)

Seleccionemos datos 1,2. Agregamos una capa escondida con 3 neuronas y sólo los dos atributos originales X_1 y X_2 . Agregamos regularización L2.



En este caso, el espacio de decisión es más suave y no está tan deformado como antes.

¿Qué hace la regularization?

En simple

Consiste agregar un factor de penalty (penalización) a la función de pérdida. El parámetro de regularización es lambda y multiplica (penaliza) todos los parámetros de la red (es decir los pesos) de tal forma que que modelo generalice los datos y no se produzca overfitting.

Si E es la funcio'n de p'erdida, la regularizacio'n L2 consiste en:

$$E_L = E + \lambda \sum_{l=1}^L W_l^2 \quad (1)$$

mientras que una regularizacio'n L1 consiste en:

$$E_L = E + \lambda \sum_{l=1}^L |W_l| \quad (2)$$

La adicio'n del te'rmino L2 o L1 se incluye en el upgrading de los pesos sina'pticos de la red, lo cual resulta en pesos ma's pequenos en todo el modelo.