



Simulaciones Basadas en Agentes



UAI
UNIVERSIDAD ADOLFO IBÁÑEZ

FACULTAD DE INGENIERÍA Y CIENCIAS




NEWS




AI Agents ReAct

Agentes Reactivos: (Simple Reflex Agent)

Los agentes reactivos son la forma más simple de IA, ya que responden de forma inmediata a los estímulos actuales sin basarse en experiencias pasadas. No almacenan información sobre acciones anteriores, por lo tanto, no pueden adaptarse ni aprender con el tiempo. Son ideales para tareas directas y basadas en reglas, como chatbots básicos o sistemas que responden con salidas fijas a comandos específicos.



dailydoseofds.com



Un agente ReAct es un agente de IA que utiliza el marco de razonamiento y acción (ReAct) para combinar el razonamiento en cadena de pensamiento (CdP) con el uso de herramientas externas.



IBM


<https://www.ibm.com › think › topics › react-agent>

¿Qué es un agente ReAct? - IBM

El ejercicio muestra cómo el agente sigue el ciclo **Pensamiento** → **Acción** → **Observación** para resolver una pregunta.

Primero busca el peso promedio de cada raza de perro y luego hace un cálculo sumando ambos valores.

Finalmente entrega la respuesta: el peso combinado de un Border Collie y un Scottish Terrier es **57 lbs**.



ReAct (Reason + Act)

Published as a conference paper at ICLR 2023

REACT: SYNERGIZING REASONING AND ACTING IN LANGUAGE MODELS

Shunyu Yao¹, Jeffrey Zhao², Dian Yu², Nan Du², Izhak Shafran², Karthik Narasimhan¹, Yuan Cao²

¹Department of Computer Science, Princeton University

²Google Research, Brain team


¹{shunyuy, karthikn}@princeton.edu

²{jeffreyzhao, dianyu, dunan, izhak, yuancao}@google.com

<https://arxiv.org/pdf/2210.03629.pdf>

Simple ReAct Agent from Scratch;

Break Down





AI Agents in LangGraph

AI Agents in LangGraph

LangGraph es un framework de código abierto, integrado con LangChain, que permite crear y ejecutar flujos de trabajo complejos de agentes de IA, especialmente aquellos que requieren estado y procesos cíclicos o multitarea. Utiliza una arquitectura basada en grafos con nodos y aristas para definir flujos de trabajo, gestionar la memoria de los agentes y coordinar interacciones entre múltiples LLMs y herramientas, ofreciendo una forma estructurada de construir aplicaciones multiagente más sofisticadas y adaptables. 

Tipos de nodos personalizados

LangGraph te permite crear tipos de nodos personalizados para implementar una lógica de agente compleja. Esto proporciona flexibilidad y control sobre el comportamiento de tu aplicación.

<https://www.datacamp.com/es/tutorial/langgraph-tutorial>

AI Agents in LangGraph

¿Qué es LangGraph y para qué sirve?

- **Framework de grafos para agentes de IA:** LangGraph es un kit de herramientas que permite modelar y ejecutar sistemas de agentes inteligentes. 
- **Gestión de flujos de trabajo complejos:** Facilita la creación de arquitecturas que van más allá de simples cadenas de pasos, permitiendo bucles, ramificaciones condicionales y la coordinación entre varios agentes. 
- **Sistemas con estado:** A diferencia de otros modelos, LangGraph está diseñado para crear sistemas "con estado", lo que significa que cada agente puede mantener y modificar información a lo largo del tiempo, gestionando su memoria y el contexto de la conversación o tarea. 


Beneficios de usar LangGraph

- **Flujos de trabajo estructurados:** Permite definir la lógica de la aplicación como un gráfico, simplificando el diseño y la gestión de sistemas complejos. 
- **Mayor flexibilidad:** Al usar grafos, se pueden manejar interacciones más sofisticadas que las de las cadenas tradicionales, como la capacidad de repetir una tarea si la respuesta no es satisfactoria. 
- **Memoria y contexto:** Facilita la implementación de memoria a largo plazo y la retención de contexto, lo cual es crucial para el funcionamiento de agentes adaptativos y de larga duración. 
- **Escalabilidad:** Ofrece un marco robusto para construir sistemas agentes escalables y eficientes, utilizando las capacidades de los Modelos de Lenguaje Grandes (LLMs) de manera estructurada. 

Componentes principales de LangGraph

- **Nodos:** Representan las acciones o tareas que un agente puede realizar, como realizar una llamada a un LLM o a una API externa. 
- **Aristas (Edges):** Definen el flujo de información y el orden de ejecución entre los nodos. 
- **Estado:** Contiene la información relevante para el proceso, como las preguntas, respuestas, documentos recuperados y la memoria del agente, que puede ser modificada por cada nodo. 

AI Agents in LangGraph



Rastrea y evalúa tus aplicaciones de modelos de lenguaje y agentes inteligentes para ayudarte a pasar del prototipo a la producción.



LangChain

<https://python.langchain.com/docs/introduction/>

Introducción - Python LangChain


Ecosistema

 [LangSmith](#)

 [LangGraph](#)

<https://python.langchain.com/docs/introduction/>

AI Agents in LangGraph



AI Agents in LangGraph

 Hub

LangChain Hub

Explore and contribute prompts to the community hub

Search prompts, prompt tags, models...

Top Favored

Top Viewed

Top Downloaded

Recently Updated

ChatPromptTemplate

Summarization

English

openai:gpt-3.5-turbo



hardkothari/prompt-maker

Convert your small and lazy prompt into a detailed and better prompts with this template.

(x) Prompt • Updated 2 years ago •  282 •  104k •  62.9k •  1

ChatPromptTemplate

QA over documents

English



rlm/rag-prompt

This is a prompt for retrieval-augmented-generation. It is useful for chat, QA, or other applications that rely on passing context to an LLM.

(x) Prompt • Updated a year ago •  244 •  382k •  27.6M •  3

PENDING

Log in

Prompt Tags

financial-reporting

1

Agent simulations

69

Agents

584

anthropic:claude-2

66

anthropic:claude-2.1

39

anthropic:claude-...

20

anthropic:claude-...

28

anthropic:claude-...

23

anthropic:claude-l...

16

anthropic:claude-l...

14

api-test

1

astrodog

9

Autonomous age...

112

baseline

1

blossom

1

bnar

1

bxccccc

1

Chatbots

347

Citation-aware

1

Classification

94

Code understanding

77

Code writing

102

dachshund

3

<https://smith.langchain.com/hub>

AI Agents in LangGraph



Personal

Setup resource tags

DEVELOPER

Personal ID

Get Started

Set up tracing

Run an evaluation

Try out playground

Observability

Tracing Projects 1 Custom Dashboards 0

Name	Most Recent Run (7D)	Feedback (7D)	Run Count (7D)	Error Rate (7D)	P50 Latency (7D)	P99 Latency (7D)
Setup observability Send a trace to LangSmith to create a new tracing project and start monitoring Setup observability						

Showing 5 most active projects.

<https://smith.langchain.com/>

[View all tracing projects →](#)

AI Agents in LangGraph

hwchase17/react Public Prompt Commits

PromptTemplate

Answer the following questions as best you can. You have access to the following tools:

{tools}

Use the following format:

Question: the input question you must answer

Thought: you should always think about what to do

Action: the action to take, should be one of [{tool_names}]

Action Input: the input to the action

Observation: the result of the action

... (this Thought/Action/Action Input/Observation can repeat N times)

Thought: I now know the final answer

Final Answer: the final answer to the original input question

Begin!


Question: {input}

Thought: {agent_scratchpad}


<> Use object in LangChain

Python SDK

<https://smith.langchain.com/hub/hwchase17/react?organizationId=a21a014f-2173-4f27-b7a8-d709914ba249>




<https://app.tavily.com/home>



<https://openai.com/>

AI Agents in LangGraph



LangChain usa **prompts** como instrucciones que guían a un modelo de lenguaje en su respuesta.

Los **Prompt Templates** permiten reutilizar estructuras de prompts, rellenando huecos como `{adjective}` o `{content}`.

También existen prompts ya preparados para **agentes** que se pueden descargar desde un hub público.


En el flujo, el usuario hace una pregunta, el LLM genera una acción, puede llamar a una herramienta y finalmente devuelve la respuesta.

1. **Tavily** es un motor de búsqueda optimizado para integrarse con LangChain, pensado para que los agentes de IA puedan hacer consultas web en tiempo real.
2. Funciona como una “herramienta” que recibe queries estructurados y devuelve resultados que el modelo puede procesar.
3. En este código, el agente creado con `ChatOpenAI` utiliza `TavilySearchResults` para responder preguntas complejas que requieren información actualizada.
4. El ejercicio muestra cómo el agente divide una consulta en varias sub-búsquedas: quién ganó el Super Bowl 2024, en qué estado está la sede del equipo y cuál es el PIB de ese estado.
5. De este modo se ejemplifica el flujo de razonamiento de un **agente de investigación** que hace múltiples llamadas a la herramienta antes de construir la respuesta final.




AI Agentic Search


Why Search Tool



Inside a Search Tool



AI Agentic Search



1. Un **Query** (pregunta) se divide en **Sub-Queries** para mejorar la precisión.
2. El módulo de **Retrieve** busca información en múltiples **Sources** (fuentes de datos).
3. La información recuperada se pasa por un proceso de **Scoring & Filtering** para ordenar y filtrar lo más relevante.
4. Finalmente, se devuelven los **Top-K documentos** más útiles para la consulta.
5. Internamente, cada fuente se divide en **chunks** (trozos de texto) y se seleccionan los **Top-K chunks** más relevantes según el sub-query.

1. Usa **DuckDuckGo** como buscador para encontrar páginas web relacionadas con una consulta (`query`).
2. Toma el **primer resultado** de la búsqueda y guarda la URL.
3. Con esa URL, hace una **petición HTTP** al sitio web y descarga el HTML.
4. Luego analiza el contenido con **BeautifulSoup** para poder extraer la información (por ejemplo, datos del clima).
5. Finalmente imprime la URL del sitio encontrado y los primeros 50.000 caracteres del cuerpo de la página para inspeccionarla.



Multi-Agentic

AI Multi-Agent

Code

Details

200

Response body

```
{
  "trace_id": "92c2ef52-7b90-49f9-bf37-a3f942feff80",
  "query": "¿Quién es más poderoso, Darth Vader o el Emperador Palpatine? Analiza sus habilidades con la Fuerza",
  "final_response": "En el universo de Star Wars, tanto Darth Vader como el Emperador Palpatine son figuras icónicas del lado oscuro de la Fuerza, pero sus habilidades y niveles de poder presentan diferencias significativas. Darth Vader, anteriormente conocido como Anakin Skywalker, es famoso por su destreza en el combate con sables de luz y su capacidad para usar la Fuerza de manera poderosa, incluyendo habilidades como la telequinesis, el estrangulamiento con la Fuerza y la precognición. Sin embargo, su potencial se vio limitado tras su transformación en Darth Vader debido a sus heridas y la pérdida de su conexión completa con la Fuerza. Por otro lado, el Emperador Palpatine, también conocido como Darth Sidious, es considerado uno de los Sith más poderosos de la historia. Su dominio de la Fuerza incluye habilidades avanzadas como el Rayo de la Fuerza, manipulación mental y la capacidad de prever el futuro. Palpatine fue el maestro de Vader y tenía un conocimiento más profundo del lado oscuro, lo que le permitió manipular y controlar a Vader. En términos de poder bruto y habilidades con la Fuerza, el Emperador Palpatine es generalmente considerado más poderoso que Darth Vader.\n\nResumen: El Emperador Palpatine es generalmente considerado más poderoso que Darth Vader debido a su dominio superior del lado oscuro de la Fuerza y sus habilidades avanzadas.",
  "approved": true,
  "quality_score": 0.95,
  "flags": [],
  "agent_traces": [
    {
      "agent_name": "intent_delimiter",
      "status": "success",
      "data": {
        "category": "analysis",
        "sub_intent": "comparar habilidades de personajes de Star Wars",
        "entities": [
          {
            "type": "personaje",
            "value": "Darth Vader"
          }
        ]
      }
    },
    {
      "type": "personaje",
```



Download



UAI
UNIVERSIDAD ADOLFO IBÁÑEZ



Hubs & Tools *Open Gen AI*



¿Qué es Ollama?

Ollama es una herramienta de inteligencia artificial (IA) generativa diseñada para **permitir a los usuarios generar contenido nuevo y realizar análisis avanzados de datos mediante modelos de lenguaje.**

Es parte de la creciente categoría de herramientas de IA que utilizan redes neuronales profundas para entender y producir lenguaje natural, lo que la hace útil en una variedad de aplicaciones, desde la generación automática de textos hasta la creación de scripts personalizados.

Ollama es un software de código abierto que te permite ejecutar modelos de lenguaje grandes (LLM) directamente en tu propio ordenador. Esto te da la posibilidad de usar inteligencia artificial generativa de forma local, gratuita y con total control sobre tu privacidad, sin depender de servicios en la nube de grandes empresas. 

Características clave de Ollama

- **Ejecución local:** Los modelos de IA se ejecutan en tu máquina (Windows, macOS o Linux) y aprovechan tus recursos de hardware, como la CPU y la GPU, para funcionar de manera eficiente.
- **Privacidad:** Al no enviar tus datos a servidores externos, puedes mantener la privacidad total en tus proyectos de IA, lo que es especialmente útil en sectores sensibles como el financiero y el de salud.
- **Flexibilidad:** Puedes descargar, gestionar y ejecutar una variedad de modelos de IA de código abierto, como Llama, Mistral y Gemma.
- **Interfaz de línea de comandos y API:** Ollama proporciona una interfaz de línea de comandos (CLI) para interactuar con los modelos, así



Ollama frente a los servicios en la nube

A diferencia de plataformas como ChatGPT, que se ejecutan en la nube, Ollama procesa la IA localmente. [🔗](#)

- **Ollama:** Ofrece privacidad, control de costes (sin pagos por uso) y la capacidad de trabajar sin conexión a internet. Sin embargo, el rendimiento depende de la potencia de tu máquina. [🔗](#)
- **IA en la nube:** Utiliza hardware de alta gama para ofrecer un rendimiento superior y escalabilidad, pero requiere enviar datos a servidores externos y tiene costes asociados. [🔗](#)

En resumen, Ollama democratiza el acceso a la IA avanzada, ofreciendo una solución poderosa y privada para cualquiera que desee experimentar y desarrollar con modelos de lenguaje de forma local. [🔗](#)





Características principales de Ollama

- **Generación de contenido:** Ollama puede generar texto coherente y relevante a partir de prompts o instrucciones dadas por el usuario, lo que la convierte en una herramienta valiosa para la automatización de tareas como la redacción de informes, la creación de documentación, y la elaboración de respuestas a incidentes de ciberseguridad.
- **Análisis de datos:** Utilizando modelos avanzados de procesamiento de lenguaje natural (NLP), Ollama puede analizar grandes volúmenes de datos para extraer información útil, identificar patrones de comportamiento, y ofrecer insights que facilitan la toma de decisiones.
- **Personalización y adaptabilidad:** Ollama se puede adaptar a diferentes contextos y necesidades, permitiendo a los usuarios ajustar sus salidas según las especificaciones del proyecto o las demandas del entorno de trabajo.
- **Interfaz de usuario amigable:** A pesar de su sofisticación técnica, Ollama está diseñada para ser accesible tanto para expertos en inteligencia artificial como para profesionales en campos no técnicos, facilitando su adopción en diferentes sectores.

<https://dev.to/whoakarsh/how-to-run-mistral-locally-using-ollama-7ck>

Hubs & Tools Open Gen AI

Cloud

Embedding

Vision

Tools

Thinking

Popular

gpt-oss

OpenAI's open-weight models designed for powerful reasoning, agentic tasks, and versatile developer use cases.

tools thinking cloud 20b 120b

↓ 3.2M Pulls ↻ 5 Tags ⌚ Updated 2 weeks ago

deepseek-r1

DeepSeek-R1 is a family of open reasoning models with performance approaching that of leading models, such as O3 and Gemini 2.5 Pro.

tools thinking 1.5b 7b 8b 14b 32b 70b 671b

↓ 64.7M Pulls ↻ 35 Tags ⌚ Updated 3 months ago

gemma3

The current, most capable model that runs on a single GPU.

vision 270m 1b 4b 12b 27b

↓ 19.6M Pulls ↻ 26 Tags ⌚ Updated 1 month ago

embeddinggemma

EmbeddingGemma is a 300M parameter embedding model from Google.

embedding 300m

↓ 58.5K Pulls ↻ 5 Tags ⌚ Updated 3 weeks ago

gpt-oss

ollama run gpt-oss

↓ 3.2M Downloads ⌚ Updated 2 weeks ago

OpenAI's open-weight models designed for powerful reasoning, agentic tasks, and versatile developer use cases.

tools thinking cloud 20b 120b




Models

View all →




Name	Size	Context	Input
gpt-oss:latest	14GB	128K	Text
gpt-oss:20b latest	14GB	128K	Text
gpt-oss:120b	65GB	128K	Text
gpt-oss:20b-cloud	-	128K	Text
gpt-oss:120b-cloud	-	128K	Text

<https://ollama.com/library/gpt-oss>

Hubs & Tools Open Gen AI



Hubs & Tools Open Gen AI



Hubs & Tools Open Gen AI

1 Localiza el ejecutable de Ollama

Como no está en `C:\Program Files\Ollama\`, busquémoslo manualmente.

En PowerShell o en el buscador de Windows, ejecuta:

```
powershell  
  
Get-ChildItem -Path "C:\Users" -Filter "ollama.exe" -Recurse -ErrorAction SilentlyContinue
```

💡 Esto buscará `ollama.exe` en todas las carpetas de usuario.

Tardará un poco, pero al final te mostrará una ruta, por ejemplo:

2 Instálalo

1. Ejecuta `ollamaSetup.exe`
2. Deja que termine la instalación.
3. Cierra y vuelve a abrir PowerShell o CMD (esto es importante para que se actualice el PATH).

5 (Opcional) Usar GPU NVIDIA

Si tu PC tiene GPU NVIDIA:

- Asegúrate de tener instalados los drivers CUDA actualizados.
- Ollama la detectará automáticamente.

3 Verifica la instalación

En una nueva terminal, ejecuta:

```
powershell  
  
ollama --version
```

Si ves algo como:

```
nginx  
  
ollama version 0.3.12
```

✅ ¡Perfecto! Ya está funcionando.

4 Descarga y prueba un modelo

Por ejemplo, prueba Llama 3:

```
powershell  
  
ollama pull llama3  
ollama run llama3
```

Si tienes poca RAM, puedes usar un modelo más pequeño como Mistral:

```
powershell  
  
ollama pull mistral  
ollama run mistral
```


Hubs & Tools Open Gen AI

```
Get-ChildItem "C:\Users\eng-a\AppData\Local\Programs\Ollama\" -Filter "ollama.exe" -Recurse
```

```
$env:Path += ";C:\Users\eng-a\AppData\Local\Programs\Ollama"
```

```
sysdm.cpl
```

🧩 Paso final: agregar Ollama al PATH

1. Presiona Win + R, escribe:

```
sysdm.cpl
```

📋 Copy code

y presiona Enter.

2. Ve a la pestaña **Opciones avanzadas** → **Variables de entorno**.
3. En **Variables del sistema**, busca y selecciona **Path**, luego haz clic en **Editar**.
4. Haz clic en **Nuevo** y agrega esta línea:

UNIVERSIDAD ADOLFO IBÁÑEZ

```
(Mistral) PS C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct> ollama --version
>>
ollama version is 0.12.3
```

Directory: C:\Users\eng-a\AppData\Local\Programs\Ollama

```
Mode                LastWriteTime         Length Name
-----
-a-----          9/26/2025   4:41 AM       32767480 ollama.exe
```

Hubs & Tools Open Gen AI

Traceback (most recent call last):

```
File "C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct\MIA\lib\site-packages\transformers\pipelines\base.py", line 311, in infer_framework_load_model
    model = model_class.from_pretrained(model, **fp32_kwargs)
File "C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct\MIA\lib\site-packages\transformers\modeling_utils.py", line 277, in _wrapper
    return func(*args, **kwargs)
File "C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct\MIA\lib\site-packages\transformers\modeling_utils.py", line 5143, in from_pretrained
    dispatch_model(model, **device_map_kwargs)
File "C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct\MIA\lib\site-packages\accelerate\big_modeling.py", line 504, in dispatch_model
    raise ValueError(
ValueError: You are trying to offload the whole model to the disk. Please use the `disk_offload` function instead.
```

○ (MIA) PS C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct> python .\llama3-hf-demo-mini.py

● `torch\_dtype` is deprecated! Use `dtype` instead!

Loading checkpoint shards: 100% | 4/4 [00:02<00:00, 1.66it/s]

Device set to use cpu

Setting `pad\_token\_id` to `eos\_token\_id`:128001 for open-end generation.

Hubs & Tools Open Gen AI

```
(Mistral) PS C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct> ollama pull mistral
```

```
>>
```

```
pulling manifest
```

```
pulling f5074b1221da: 75%
```

```
pulling manifest
```

```
pulling f5074b1221da: 100%
```

```
pulling 43070e2d4e53: 100%
```

```
pulling 1ff5b64b61b9: 100%
```

```
pulling ed11eda7790d: 100%
```

```
pulling 1064e17101bd: 100%
```

```
verifying sha256 digest "
```

4.4 GB

11 KB

799 B

30 B

487 B

```
(Mistral) PS C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct> ollama run mistral
```

```
>>
```

```
>>> hola
```

```
Hola! ¿Cómo estás?
```

Soy un asistente de redacción que está aquí para ayudarte con tus preguntas. ¿Tienes alguna consulta específica o necesitas información sobre algo en particular? Estoy a tu disposición.

```
>>> Send a message (/? for help)
```

```
^
```

Send a message (/? for help)

Hubs & Tools Open Gen AI

```
(Mistral) PS C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct> ollama list
```

NAME	ID	SIZE	MODIFIED
mistral:latest	6577803aa9a0	4.4 GB	2 minutes ago
gpt-oss:120b-cloud	569662207105	-	15 minutes ago

```
○ (Mistral) PS C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct> |
```

```
~  
○ (Mistral) PS C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct> ollama run gpt-oss:120b-cloud  
Connecting to 'gpt-oss:120b' on 'ollama.com' ⚡  
>>> Send a message (/? for help)
```

```
○ (Mistral) PS C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct> ollama run gpt-oss:120b-cloud
```

```
Connecting to 'gpt-oss:120b' on 'ollama.com' ⚡
```

```
>>> eres un modelo de open ai?
```

```
Thinking...
```

```
We need to respond in Spanish, answer the question. The user asks: "eres un modelo de open ai?" (Are you an OpenAI model?). We can answer: Yes, I'm an AI language model created by OpenAI, based on GPT-4 architecture. Provide brief answer. Should follow policy: no disallowed content. It's fine.
```

```
...done thinking.
```

```
Sí, soy un modelo de lenguaje desarrollado por OpenAI, basado en la arquitectura GPT-4. Estoy aquí para ayudarte con tus preguntas y tareas.
```

```
>>> Send a message (/? for help)
```

Hubs & Tools Open Gen AI

 **Hugging Face**

Search models, datasets, users...

Models Datasets Spaces Community Docs Enterprise Pricing

meta-llama/**Llama-3.1-8B-Instruct** like 4.71k Follow Meta Llama 63.6k

Text Generation Transformers Safetensors PyTorch 8 languages llama facebook meta llama-3 conversational text-generation-inference arxiv:2204.05149 License: llama3.1

Model card Files and versions xet Community 287

Train Deploy Use this model

Edit model card

 You need to agree to share your contact information to access this model

The information you provide will be collected, stored, processed and shared in accordance with the [Meta Privacy Policy](#).

LLAMA 3.1 COMMUNITY LICENSE AGREEMENT

Llama 3.1 Version Release Date: July 23, 2024

"Agreement" means the terms and conditions for use, reproduction, distribution and modification of the Llama Materials set forth herein.

"Documentation" means the specifications, manuals and documentation accompanying Llama 3.1 distributed by Meta at <https://llama.meta.com/doc/overview>.

"Licensee" or "you" means you, or your employer or any other person or entity (if you are entering into this Agreement on such person or...)

Your request to access this repository has been submitted and is awaiting a review from the repository authors. You can check the status of all your access requests in [your settings](#).

If approved, you'll get access to all 17 repositories in the [Meta's Llama 3.1 models & evals](#) Gating Group Collection, including this one.

Downloads last month
6,986,296



 **Safetensors**

Model size 8.03B params Tensor type BF16 Chat template Files info

 **Inference Providers** NEW


 **Fireworks** +5

 Text Generation Examples

Input a message to start chatting with meta-llama/Llama-3.1-8B-Instruct.

<https://huggingface.co/meta-llama/Llama-3.1-8B-Instruct>

Hubs & Tools Open Gen AI



The screenshot shows the Hugging Face interface for the model meta-llama/Llama-3.1-8B-Instruct. The top navigation bar includes the Hugging Face logo, a search bar, and links to Models, Datasets, Spaces, Community, Docs, Enterprise, Pricing, and a user profile. The model page header shows the model name, a like count of 4.71k, a follow count of 63.6k, and a list of tags: Text Generation, Transformers, Safetensors, PyTorch, 8 languages, llama, facebook, meta, llama-3, conversational, text-generation-inference, arxiv:2204.05149, and License: llama3.1. Below the header, there are tabs for Model card, Files and versions, and Community (287). The main content area is divided into two columns. The left column contains a warning about sharing contact information to access the model, followed by the Llama 3.1 Community License Agreement. The right column shows the download count (6,986,296), Safetensors information, Inference Providers (Fireworks), and a chat interface with a text input field and a button to start chatting.

[Access granted] Your request to access model meta-llama/Llama-3.1-8B has been accepted

 **huggingface**
To You

01:39

...



Hi Ahmad amroush,

This is to let you know your request to access model "meta-llama/Llama-3.1-8B" on huggingface.co has been accepted by the repo authors.

You can now access the repo [here](#), or view all your gated repo access requests [in your settings](#).

Cheers,

The Hugging Face team

Hugging Face: The AI community building the future.

5 de agosto de 2025 Liberar Producto

Presentamos gpt-oss

gpt-oss-120b y gpt-oss-20b amplían la frontera de los modelos de razonamiento de peso abierto

Explora en Hugging Face ↗

Leer tarjeta modelo ↗

<https://openai.com/index/introducing-gpt-oss/>

Hubs & Tools Open Gen AI


Aspecto	GPT-OSS / GPT-Neo / Mistral-small / Phi	Llama (Meta)
Arquitectura	Más simple, capas reducidas, a veces sin rotary embeddings ni ALiBi complejos	Más grande, usa atención eficiente + embeddings sofisticados
Tamaño típico	1 B – 3 B parámetros	7 B – 70 B parámetros
Objetivo de diseño	Ligero, fácil de correr en CPU o GPU pequeña	Máxima calidad / benchmark en razonamiento
Context length	2k–8k tokens	8k–128k tokens
Precision típica	4-bit o 8-bit	16-bit o 8-bit

Hubs & Tools Open Gen AI

Modelo	Tamaño	Ideal para	Comentario
meta-llama/Llama-3.2-1B-Instruct	1 B	CPU / notebooks	Nueva generación Llama, rápida
microsoft/phi-3-mini-4k-instruct	3.8 B	CPU / GPU baja	Precisión sorprendente para su tamaño
HuggingFaceH4/smol-1.7b-instruct	1.7 B	Clases / demos	Muy liviano y compatible
mistralai/Mistral-7B-Instruct-v0.3	7 B	GPU media (RTX 3060 +)	Balance entre calidad y peso

Hubs & Tools Open Gen AI

```
!huggingface-cli download meta-llama/Llama-3.1-8B-Instruct --local-dir meta-llama/Llama-3.1-8B-Instruct --local-dir-use-symlinks False
```



```
PROBLEMS 5 OUTPUT TERMINAL DEBUG CONSOLE PORTS JUPYTER
(MIA) PS C:\Users\eng-a\Documents\UAI\2025 Clases\MIA_Topicos\ReAct> huggingface-cli download meta-llama/Llama-3.1-8B-Instruct --local-dir meta-llama/Llama-3.1-8B-Instruct --local-dir-use-symlinks
False
>>
Download complete. Moving file to meta-llama\llama-3.1-8B-Instruct\special_tokens_map.json | 10.5M/4.98G [00:00<05:22, 15.4MB/s]
Downloading 'tokenizer_config.json' to 'meta-llama\llama-3.1-8B-Instruct\.cache\huggingface\download\vzaExFZNBay89bv1Qv-ZcI6BTg=.db88166e2bc4c799fd5d1ae643b75e84d03ee70e.incomplete'
tokenizer_config.json: 100% | 55.4k/55.4k [00:00<00:00, 2.00MB/s]
Download complete. Moving file to meta-llama\llama-3.1-8B-Instruct\tokenizer_config.json | 21.0M/4.98G [00:01<05:30, 15.0MB/s]
tokenizer.model: 100% | 2.18M/2.18M [00:01<00:00, 1.25MB/s]
Download complete. Moving file to meta-llama\llama-3.1-8B-Instruct\original\tokenizer.model | 31.5M/4.98G [00:02<06:46, 12.2MB/s]
tokenizer.json: 100% | 9.09M/9.09M [00:07<00:00, 1.24MB/s]
Download complete. Moving file to meta-llama\llama-3.1-8B-Instruct\tokenizer.json | 83.9M/4.98G [00:07<08:00, 10.2MB/s]
model-00002-of-00004.safetensors: 0% | 10.5M/5.00G [00:06<55:13, 1.51MB/s]
model-00001-of-00004.safetensors: 9% | 461M/4.98G [00:49<09:05, 8.28MB/s]
model-00002-of-00004.safetensors: 1% | 52.4M/5.00G [00:46<1:20:25, 1.03MB/s]
model-00004-of-00004.safetensors: 31% | 357M/1.17G [00:50<01:30, 8.99MB/s]
model-00003-of-00004.safetensors: 6% | 273M/4.92G [00:49<18:31, 4.18MB/s]
consolidated.00.pth: 4% | 661M/16.1G [00:50<21:49, 11.8MB/s]
```

Hubs & Tools Open Gen AI



✦ Visión general creada por IA

Hugging Face es una **plataforma de IA que funciona como un centro para la comunidad de código abierto**, ofreciendo herramientas, modelos y datos de aprendizaje automático para el procesamiento del lenguaje natural (PLN) y otras tareas de IA. Destaca por su biblioteca de Transformers, que permite a los desarrolladores entrenar y utilizar modelos preentrenados, y por su plataforma para compartir y colaborar en modelos, conjuntos de datos y aplicaciones de IA. [🔗](#)



Componentes principales:

- **Transformers:** Una biblioteca de código abierto que proporciona modelos preentrenados de última generación y fáciles de usar para tareas como la generación de texto, el resumen y la extracción de información. 
- **Hub de Hugging Face:** Una plataforma centralizada (similar a GitHub) donde los usuarios pueden encontrar, compartir y colaborar en miles de modelos de aprendizaje automático, conjuntos de datos y aplicaciones de IA. 
- **Spaces:** Una plataforma dentro de Hugging Face que permite a los usuarios implementar y mostrar sus modelos de IA de forma interactiva. 




¿Para qué se utiliza?

- **Desarrollo de IA:** Los desarrolladores y científicos de datos pueden entrenar, refinar e implementar modelos de IA de manera más rápida y eficiente. 
- **Colaboración:** Fomenta la colaboración entre empresas, universidades y la comunidad en general para construir un ecosistema de IA más amplio. 
- **Aplicaciones de PLN:** Permite crear y desplegar aplicaciones que entienden y generan lenguaje humano, como asistentes virtuales o herramientas de análisis de texto. 



UAI
UNIVERSIDAD ADOLFO IBÁÑEZ

Gracias!





Simulaciones Basadas en Agentes



UAI
UNIVERSIDAD ADOLFO IBÁÑEZ

FACULTAD DE INGENIERÍA Y CIENCIAS