

co TOTA

Agente Multi-LLM de Turismo en Colombia

Guía de Instalación y Ejecución — Paso a Paso

Python 3.12

Redis Cloud

OpenAI

Anthropic

MCP

FastAPI



Roadmap de Instalación

8 pasos para tener el agente corriendo

01 Crear entorno virtual Python 3.12

02 Instalar dependencias + configurar .env

03 Verificar servicios e indexar atracciones

04 Cargar variables de entorno (Windows)

05 Ejecutar en modo chat interactivo CLI

06 Ejecutar en modo API REST (FastAPI)

07 Modo desarrollo con auto-reload

08 Debug y resolución de problemas

WINDOWS · CMD /
POWERSHELL

Crear e iniciar el entorno virtual

```
● ● ●  
# Crear el entorno virtual con Python 3.12  
py -3.12 -m venv AgenticAI  
  
# Activar el entorno (Windows)  
AgenticAI\Scripts\activate  
  
# Verificar que está activo (debe aparecer el prefijo)  
(AgenticAI) PS C:\...>
```



Python 3.12

Usa `py -3.12` para seleccionar la versión exacta.
Verifica con: `py -3.12 --version`



Carpeta creada

Se creará `AgenticAI/` con `Scripts/`, `Lib/` y `pyenv.cfg`. El prefijo `(AgenticAI)` confirma activación.



Mac / Linux: `source AgenticAI/bin/activate`

1. Instalar librerías

```
● ● ●  
pip install -r requirements.txt  
  
# Librerías instaladas:  
# openai, anthropic, mcp  
# redis, httpx, fastapi  
# uvicorn, pydantic, rich
```

 **IMPORTANTE:** Nunca pegues tus API keys en un chat o repositorio público. OpenAI las revoca automáticamente al detectar exposición.

2. Configurar .env

```
● ● ●  
cp .env.example .env  
# Editar .env con tus claves:  
  
OPENAI_API_KEY=sk-proj-...  
ANTHROPIC_API_KEY=sk-ant-...  
REDIS_HOST=redis-xxxxx.redislabs.com  
REDIS_PORT=14159  
REDIS_PASSWORD=tu_password
```

 **Redis Cloud:** El host y puerto están en tu consola → Databases → Configuration → Endpoint (formato host:port).

Ejecutar una sola vez para poblar el índice RAG



```
# Primero verifica servicios, luego indexa
python main.py --index

# Output esperado:
# Redis (RAG)           ✓ Online   | 0 docs indexados
# API Colombia (MCP)    ✓ Online   | MCP → api-colombia.com
# OpenAI (GPT-4o)       ✓ Configurado
# Claude (Anthropic)    ✓ Configurado
#
# 📄 Descargando atracciones desde API Colombia...
# → 41 atracciones descargadas
# ✅ 41 atracciones indexadas exitosamente
```

Pipeline de Indexación



API Colombia

GET /TouristicAttraction



Embeddings

text-embedding-3-small



Redis Cloud

tourism:emb:<md5> +
tourism:doc:<md5>

PowerShell — cuando el .env no se carga automáticamente

```
● ● ●  
# Leer .env y exportar al proceso actual  
Get-Content .env | Where-Object { $_ -notmatch '^#' -and  
$_ -match '=' } | ForEach-Object {  
    $parts = $_ -split '=', 2  
    [System.Environment]::SetEnvironmentVariable(  
        $parts[0].Trim(), $parts[1].Trim(), 'Process'  
    )  
}  
  
# Verificar que la key se cargó correctamente  
$env:OPENAI_API_KEY | Select-String "."  
  
# Ahora indexar  
python main.py --index
```

¿Por qué pasa esto?

python-dotenv carga el .env cuando se ejecuta main.py. Si el entorno virtual no hereda las vars del shell, es necesario cargarlas manualmente con el comando de la izquierda.

Verificación rápida

```
● ● ●  
# Últimos 6 chars de tu key  
python -c "  
    from dotenv import  
    load_dotenv  
    load_dotenv()  
    import os  
  
print(os.getenv('OPENAI_API_KEY'  
)[-6:])"
```



```
# Modo chat por defecto
python main.py

# Sin fiscalizador Claude (más rápido)
python main.py --no-fiscalize

# Sin API Colombia en tiempo real
python main.py --no-realtime

# Con debug verbose
python main.py --verbose

# Demo automático con preguntas predefinidas
python main.py --demo
```

Comandos en el chat

/ayuda

Muestra los comandos disponibles

/limpiar

Borra el historial de la sesión en Redis

/salir

Sale del chatbot

Pipeline por mensaje



```
Tu mensaje
→ Redis RAG (KNN k=5)
→ API Colombia (MCP)
→ GPT-4o genera respuesta
→ Claude fiscaliza
→ Respuesta final
```



```
# Levantar servidor API REST
uvicorn main:app --host 0.0.0.0 --port 8080

# Con auto-reload (desarrollo)
uvicorn main:app --host 0.0.0.0 --port 8080 -
-reload

# Puerto personalizado
uvicorn main:app --host 0.0.0.0 --port 3000

# Alternativa via main.py
python main.py --api --port 8080
```

UI: <http://localhost:8080/>

Docs: <http://localhost:8080/docs>

Endpoints disponibles

GET	/	UI de chat web
GET	/docs	Swagger UI (automático)
GET	/status	Estado de servicios
POST	/chat	Enviar mensaje al agente
POST	/index	Indexar atracciones
GET	/history/{id}	Historial de sesión



Estado Online: Redis 41 docs · API Colombia · GPT-4o · Claude

Auto-reload (desarrollo activo)

```
● ● ●  
# Reinicia el servidor en cada cambio de  
archivo  
uvicorn main:app --host 0.0.0.0 --port 8080 -  
-reload  
  
# Output esperado:  
# Will watch for changes in directories:  
[...]  
# Started reloader process [PID]  
# Started server process [PID]  
# Application startup complete.
```

Debug — log level detallado

```
● ● ●  
uvicorn main:app --host 0.0.0.0 \  
--port 8080 --log-level debug  
  
# Ver error 500 en detalle desde PowerShell:  
$body = '{"message":"hola",'\  
$body += '"fiscalize":false,'\  
$body += '"use_realtime":false}'\  
Invoke-RestMethod -Uri \  
http://localhost:8080/chat \  
-Method POST \  
-ContentType application/json \  
-Body $body
```

Errores frecuentes

401 invalid_api_key	Key revocada (expuesta). Generar nueva en platform.openai.com/api-keys
Redis offline	Verificar REDIS_HOST, REDIS_PORT y REDIS_PASSWORD en .env
500 Internal Error	Revisar traceback en terminal. Correr test aislado con <code>python -c</code>
MCP subprocess bloqueado	Windows: agregar MCP_TRANSPORT=direct en .env

CO

¡Tota está lista!

El agente está corriendo en <http://localhost:8080>

UI Web

`localhost:8080/`

Swagger

`localhost:8080/docs`

Status

`localhost:8080/status`

Chat API

`POST /chat`