




Tópicos Avanzados en IA 2

Sesión 1 · Modelos Fundacionales y su Ecosistema Tecnológico (xLMs)

Máster en Inteligencia Artificial



UAI
UNIVERSIDAD ADOLFO IBÁÑEZ

Syllabus de la sesión

SESIÓN 1 · TEMA: MODELOS FUNDACIONALES Y SU ECOSISTEMA TECNOLÓGICO (XLMS)

01	Large Language Models (LLMs) Concepto y ejemplos: GPT, LLaMA, Mistral y Falcon	Acto 3	06	Domain-specific LMs BioLM, CodeLM y FinLM en sectores especializados	Acto 5
02	Causal LLMs Arquitecturas autorregresivas y predicción causal	Acto 3	07	Ajuste fino y adaptación eficiente LoRA, PEFT, in-context learning y RAG	Acto 6
03	Vision-Language Models (VLMs) CLIP, Flamingo, GPT-4V y Kosmos	Acto 4	08	Limitaciones actuales Context length, attention bottlenecks, long-context	Acto 7
04	Masked Language Models (MLMs) BERT y sus variantes como referencia	Acto 3	09	Distribuidas vs. simbólicas Diferencias, ventajas y limitaciones	Acto 1
05	Multimodal LMs Gemini, LLaVA, Kosmos-2 y los MM-LLMs	Acto 4	10	Transición hacia transformers Self-attention y arquitectura encoder-decoder	Acto 2

La clase ordena los diez contenidos como una historia: del significado al Transformer y de ahí al ecosistema.

Objetivos de aprendizaje

SESIÓN 1 · AL TERMINAR LAS CUATRO HORAS


- Explicar** cómo self-attention y la arquitectura encoder-decoder reemplazaron a la recurrencia.
- Distinguir** las familias xLM: causales, enmascaradas, visión-lenguaje, multimodales y de dominio.
- Comparar** representaciones distribuidas y simbólicas, con sus ventajas y limitaciones.
- Elegir** entre in-context learning, RAG, PEFT/LoRA y ajuste fino según la necesidad.
- Diagnosticar** límites de contexto y de atención antes de comprometer una arquitectura.

240 min: apertura 10 · actos 1 a 3: 90 · pausa 15 · actos 4 a 7: 95 · taller y cierre 30

Evaluación y notas

SESIÓN 1 · REGLAS DEL MÓDULO

Nota final = 10% Participación + 15% Taller + 30% Examen + 45% Tarea




Tarea Práctica, sobre distintos tópicos vistos en clases.

Atraso Descuento de 1,5 puntos por cada día, hasta llegar a la nota 1,0.

Aprobación Nota mínima del curso: 4,0.

Nota máxima de una entrega de 7,0 según su atraso



Una entrega con tres días de atraso ya queda bajo la nota de aprobación.

Ruta de la sesión

SESIÓN 1 · CUATRO HORAS, SIETE ACTOS Y UN TALLER



Cada acto abre con una pregunta y cierra volviendo al caso guía.

El ecosistema xLM en ocho siglas

SESIÓN 1 · MAPA DE ENTRADA: OCHO SIGLAS, SEIS EJES

LLM

Large Language Model

Predice el siguiente token a gran escala.

Eje: escala · Acto 3

SLM

Small Language Model

Igual objetivo, pocos parámetros: corre en el borde.

Eje: tamaño · Acto 3

VLM

Vision-Language Model

Une un encoder de visión con un modelo de lenguaje.

Eje: modalidad · Acto 4

MLM

Masked Language Model

Reconstruye tokens ocultos mirando ambos lados.

Eje: objetivo · Acto 3

LCM

Large Concept Model

Predice la siguiente frase en un espacio de conceptos.

Eje: unidad · Acto 7

LAM

Large Action Model

Genera y ejecuta acciones, no solo texto.

Eje: propósito · Cierre

MoE

Mixture of Experts

Activa solo unos pocos expertos por token.

Eje: arquitectura · Acto 3

SAM

Segment Anything Model

Segmenta cualquier objeto a partir de un prompt.

Eje: visión · Acto 4

Son ejes, no categorías excluyentes: un mismo modelo puede ser a la vez SLM, MoE y VLM.

Caso guía: 30.000 reclamos al mes

SESIÓN 1 · EL PROBLEMA QUE ACOMPAÑA TODA LA SESIÓN

Situación

Empresa con 30.000 casos al mes

Consultas de texto y documentos


20% de los casos incluyen imágenes

Las políticas cambian cada semana

Restricciones

Trazabilidad de cada afirmación

Una persona autoriza compensaciones




Pregunta guía: ¿qué xLM resuelve qué parte del caso, y con qué técnica de adaptación?

ACTO 1 DE 7 · 15 MIN

¿Cómo se representa el significado?

Antes de hablar de modelos hay que decidir qué es un concepto para una máquina: un símbolo con reglas o un punto en un espacio.




Dos tradiciones en una línea de tiempo

SESIÓN 1 · ACTO 1 · REPRESENTACIONES

IA simbólica

símbolos, lógica y reglas



Representaciones distribuidas

vectores aprendidos




Compitieron durante décadas; desde 2017 la escala favoreció a los vectores, y hoy se combinan.

Símbolos frente a vectores

SESIÓN 1 · ACTO 1 · REPRESENTACIONES

Representación simbólica


Conceptos discretos, relaciones y reglas explícitas



Si monto > 50.000 Y plazo < 10 días
ENTONCES compensar

Representación distribuida

$\text{rey} - \text{hombre} + \text{mujer} \approx \text{reina}$



Un símbolo significa lo que una regla dice; un vector significa lo que sus vecinos sugieren.

Diferencias, ventajas y limitaciones


SESIÓN 1 · ACTO 1 · REPRESENTACIONES

Aspecto	Simbólica	Distribuida
Unidad de significado	Símbolo discreto y reglas explícitas	Vector denso aprendido de los datos
Cómo generaliza	Solo a lo que alguien codificó	Por similitud, a casos no vistos
Cómo se interpreta	Cada paso es una regla legible	Significado repartido en dimensiones
Cómo razona	Lógica exacta y verificable	Aproximada; falla en cadenas largas
Cómo se mantiene	A mano: MYCIN llegó a unas 500 reglas	Con datos: reentrenar o adaptar
Frente al ruido	Frágil ante lo imprevisto	Tolerante a variaciones del lenguaje

Ninguna gana sola: importa qué parte del problema exige exactitud y cuál tolera aproximación.

Convergencia neuro-simbólica

SESIÓN 1 · ACTO 1 · REPRESENTACIONES



AlphaGeometry (2024)

Un modelo de lenguaje propone construcciones auxiliares y un motor de deducción las verifica: resuelve 25 de 30 problemas de geometría olímpica.

LLM + herramientas

El modelo redacta la llamada; el código, una consulta SQL o una calculadora entregan el resultado exacto y auditable.

Grafos + recuperación

Un grafo de conocimiento aporta entidades y relaciones explícitas; el LLM las sintetiza en lenguaje natural (GraphRAG, 2024).


En el caso: la compensación se calcula con reglas; el reclamo se interpreta con vectores.

La transición a Transformers

ACTO 2 DE 7 · 35 MIN

¿Qué cambió en 2017?


Ocho autores proponen eliminar la recurrencia: toda la secuencia se mira a sí misma en un solo paso.



Antes de 2017: recurrencia

SESIÓN 1 · ACTO 2 · TRANSFORMER

2014 · Atención: el decoder consulta todos los estados del encoder



Secuencial: sin paralelismo al entrenar

Memoria larga difícil: la señal se diluye

Todo pasa por un vector de tamaño fijo

La atención nació como parche del cuello de botella; en 2017 pasa a ser la arquitectura completa.

Attention Is All You Need en cifras

SESIÓN 1 · ACTO 2 · TRANSFORMER

Sin recurrencia ni convoluciones: una arquitectura basada solo en atención.

28,4

BLEU inglés → alemán
(WMT 2014): nuevo
estado del arte

41,8

BLEU inglés → francés
con el modelo big

3,5 días

de entrenamiento del
modelo big en 8 GPU
P100

65M · 213M

parámetros de los
modelos base y big


Modelo base: $N = 6$ capas · $d_{\text{model}} = 512$ · $h = 8$ cabezas · $d_{\text{ff}} = 2.048$

Un modelo que hoy cabe en un teléfono fijó la arquitectura de toda la década.

Self-attention: consultas, claves, valores

SESIÓN 1 · ACTO 2 · TRANSFORMER

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) \cdot V$$



Todas las posiciones se comparan con todas en un solo paso: paralelismo total y costo n^2 .

Un ejemplo: a qué atiende cada palabra

SESIÓN 1 · ACTO 2 · TRANSFORMER

Claves: a quién se mira →

Consultas ↓	El	banco	rechazó	el	reclamo	porque	estaba	incompleto
El								
banco								
rechazó								
el								
reclamo								
porque								
estaba	0,02	0,10	0,05	0,02	0,62	0,04	0,10	0,05
incompleto								

Fila «estaba»

Su mayor peso (0,62) cae en «reclamo»: la atención resuelve a qué se refiere el verbo.

Si la frase terminara en «saturado», el peso se movería hacia «banco».

Cada fila suma 1: es una distribución sobre las claves.


Los pesos de atención ayudan a inspeccionar; por sí solos no explican causalidad.

Pesos ilustrativos contruidos para la clase; no provienen de un modelo real.

Multi-head y codificación posicional

SESIÓN 1 · ACTO 2 · TRANSFORMER


Multi-head: varias miradas en paralelo



Cada cabeza aprende una relación: sintaxis, correferencia, cercanía.

Ocho cabezas de 64 dimensiones cuestan como una de 512, pero miran ocho relaciones distintas.

Codificación posicional: el orden se suma




$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{(2i/d)}}\right)$$

Sin posición, «banco rechaza cliente» y «cliente rechaza banco» serían la misma bolsa de palabras.

Hoy dominan RoPE y ALiBi, que extrapolan mejor.

Arquitectura encoder-decoder

SESIÓN 1 · ACTO 2 · TRANSFORMER



Encoder

Lee toda la entrada a la vez, en ambas direcciones.

Decoder

Genera de izquierda a derecha; la máscara impide mirar el futuro.

Cross-attention

Cada token generado consulta la salida del encoder.

Traducir era la tarea original; el mismo bloque, apilado, sirve para cualquier secuencia.

Por qué escaló: paralelismo


SESIÓN 1 · ACTO 2 · TRANSFORMER

Tipo de capa	Complejidad por capa	Operaciones en serie	Camino máximo
Self-attention	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Recurrente	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Convolutacional	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(\log_k n)$

Recurrencia: 8 tokens, 8 pasos en serie



Self-attention: 1 paso, 28 pares a la vez




El costo cuadrático en n es el precio del paralelismo; volverá como límite en el Acto 7.

Tres familias desde un mismo bloque

SESIÓN 1 · ACTO 2 · TRANSFORMER

Solo encoder




cada token ve toda la frase

Objetivo: predecir tokens ocultos (MLM)

BERT · RoBERTa · DeBERTa

Comprender: clasificar, extraer, generar embeddings

Solo decoder




cada token ve solo el pasado

Objetivo: predecir el siguiente token

GPT · LLaMA · Mistral · Falcon

Generar: conversar, redactar, razonar, programar

Encoder-decoder



entrada completa, salida causal

Objetivo: reconstruir o transformar texto

T5 · BART · Transformer original


Transformar: traducir, resumir

Pregunta a la sala: ¿qué familia clasificaría 30.000 reclamos? ¿Cuál redactaría la respuesta?

ACTO 3 DE 7 · 40 MIN

¿Predecir lo oculto o predecir lo siguiente?

Dos objetivos de preentrenamiento dividen el ecosistema: reconstruir tokens enmascarados o continuar la secuencia. La escala hizo el resto.



Masked Language Models: BERT

SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA



Se selecciona el 15% de los tokens; de ellos:



10% → token aleatorio (azul) · 10% → sin cambio (gris)

BERT-base: 110M parámetros, 12 capas · BERT-large: 340M, 24 capas

Datos: BooksCorpus (800M palabras) + Wikipedia en inglés (2.500M)

Segundo objetivo: predecir si una frase sigue a otra (NSP)

Ver ambos lados del hueco da representaciones ricas, pero impide generar texto de corrido.

BERT y sus variantes



SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA


Modelo	Año	Cambio clave	Dato
BERT	2018	MLM bidireccional + predicción de frase siguiente	110M y 340M parámetros; GLUE 80,5
RoBERTa	2019	Más datos, sin NSP, enmascarado dinámico	Más de 160 GB de texto
DistilBERT	2019	Destilación de conocimiento	40% menor, 60% más rápido, 97% del desempeño
ALBERT	2019	Parámetros compartidos entre capas	Embeddings factorizados
ELECTRA	2020	Detectar tokens reemplazados	Aprende de todos los tokens, no solo del 15%
DeBERTa	2020	Atención desacoplada: contenido y posición	Decodificador de máscara mejorado
ModernBERT	2024	Contexto nativo de 8.192 tokens	Entrenado con 2 billones de tokens (2T)

Siete años después, los encoders siguen siendo la opción eficiente para comprender texto.

Dónde trabajan hoy los encoders

SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA

Un encoder convierte texto en un vector que otras piezas pueden comparar, clasificar u ordenar.



≈ 1.600×

menos parámetros: BERT-base (110M) frente a GPT-3 (175B)

En el caso: clasificar la intención de 30.000 reclamos es trabajo de un encoder o de un SLM.


Causal LLMs: predicción autorregresiva

SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA

$$P(x_1 \dots x_n) = \prod_t P(x_t \mid x_1 \dots x_{t-1})$$

	El	cliente	presentó	un	reclamo	hoy
El						
cliente						
presentó						
un						
reclamo						
hoy						


Máscara triangular: cada posición solo ve el pasado



Un solo objetivo, predecir el siguiente token, basta para aprender gramática, hechos y formato.

Inferencia: prefill, decodificación y caché

SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA



Tokens

La longitud depende del tokenizador, el idioma y la modalidad.

Prefill

Procesa el contexto inicial; domina el tiempo al primer token.

Decodificación

Autorregresiva: una respuesta larga consume más tiempo.


KV cache

Reutiliza claves y valores; crece con contexto y concurrencia.

Distinguir tiempo al primer token, latencia total p95 y tareas resueltas por segundo.

De 117 millones a billones de parámetros

SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA



≈ **24.000×**

en ocho años: de 117M (2018) a 2,8T (2026)

Desde 2024 crecen los parámetros totales con MoE, no los activos por token.

- denso
- Mixture of Experts

Desde GPT-4 los modelos cerrados no publican tamaño; la serie continúa con pesos abiertos.

Leyes de escala: de Kaplan a Chinchilla

SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA

2020 · Kaplan et al.


La pérdida sigue leyes de potencia en parámetros, datos y cómputo.

2022 · Chinchilla

70B parámetros con 1,4T tokens supera a Gopher (280B): a cómputo fijo, datos y parámetros crecen a la par.

Desde 2023

Se sobre-entrenan modelos pequeños: el costo dominante pasa a ser la inferencia.



Más datos por parámetro: modelos pequeños, baratos de servir y aun así competitivos.

GPT, LLaMA, Mistral y Falcon




SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA

Familia	Origen	Hito representativo	Aporte distintivo
GPT	OpenAI	GPT-3 (2020): 175B parámetros, 300B tokens, contexto de 2.048	Few-shot en contexto; desde GPT-4 (2023) el tamaño no se publica
LLaMA	Meta	LLaMA (2023): 7B a 65B con 1,0 a 1,4T tokens de datos públicos	Con 13B supera a GPT-3 en la mayoría de benchmarks; inicia la ola de pesos abiertos
Mistral	Mistral AI	Mistral 7B (2023): GQA y atención de ventana deslizante	Supera a Llama 2 13B; Mixtral 8×7B: MoE abierto con 47B totales y 13B activos
Falcon	TII, Abu Dabi	Falcon-40B (2023): 1T tokens de RefinedWeb; Falcon-180B: 3,5T	Datos web filtrados a gran escala; Falcon-H1 (2025) combina atención y Mamba

Cuatro apuestas distintas: escala, eficiencia de datos, eficiencia de arquitectura y calidad del corpus.

Del preentrenamiento al razonamiento

SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA



Agregar documentos al contexto no equivale a actualizar los pesos.

Modelos densos y Mixture of Experts

SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA

Denso



La memoria se paga por parámetros totales; el cómputo por token, por los activos.

Mixture of Experts (MoE)




Mixtral 8×7B: 47B totales y 13B activos · DeepSeek V4-Pro: 1,6T y 49B · Kimi K3: 2,8T y 104B

Fuentes: Jiang et al. (2024), Mixtral of Experts · model cards de DeepSeek V4-Pro y Kimi K3 (2026)

SLM: capacidad bajo restricciones

SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA



Tres palancas: datos de alta calidad, destilación desde un modelo mayor y cuantización a 4 u 8 bits. Sin umbral universal de tamaño.

Cuándo ensayarlo

Clasificación o extracción acotada

Alto volumen y costo por tarea

Operación local o intermitente

Dominio con ejemplos representativos

Qué puede limitarlo

Generalización fuera del dominio

Instrucciones complejas o ambiguas

Cobertura multilingüe desigual

Herramientas o contexto exigentes

3,8B

Phi-3-mini: entrenado con 3,3T tokens, 69% en MMLU. A 4 bits ocupa cerca de 1,9 GB y corre en un teléfono.

NVIDIA (2025): para las subtarefas repetitivas de un agente, un SLM suele bastar y cuesta menos.

Comparar calidad mínima, memoria, latencia y costo total en el entorno objetivo.

Panorama a septiembre de 2026



SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA


Familia	Modelos más recientes	Contexto	Pesos y licencia
OpenAI	GPT-6 Astra (sep 2026) · GPT-5.6 (jul 2026)	≈ 1M	Cerrado; gpt-oss abierto (Apache 2.0)
Anthropic	Claude Fable 5.1 (sep 2026) · Opus 5 (jul 2026)	1M	Cerrado
Google	Gemini 3.1 Pro (feb 2026) · Gemma 4 (abr 2026)	1M · 256K	Gemini cerrado; Gemma 4 Apache 2.0
Meta	Llama 4 Scout y Maverick (abr 2025) · Muse Spark (abr 2026)	10M (Scout)	Llama 4 abierto; Muse Spark cerrado
Mistral	Medium 3.5 (may 2026): 128B denso · Large 3: 675B / 41B	256K	MIT modificada · Apache 2.0
DeepSeek	V4-Pro (abr 2026): 1,6T totales / 49B activos	1M	Abierto, licencia MIT
Alibaba	Qwen3.8-Max (ago 2026): 2,4T totales / 95B activos	1M (API)	Abierto, licencia propia
Moonshot	Kimi K3 (jul 2026): 2,8T totales / 104B activos	1M	Abierto, licencia propia
TII	Falcon-H1 (2025): híbrido atención + Mamba, hasta 34B	256K	Licencia Falcon TII

Esta tabla envejece en semanas: verificar versión, licencia y disponibilidad antes de decidir.

Economía de la escala

SESIÓN 1 · ACTO 3 · FAMILIAS Y ESCALA

Costo estimado de entrenamiento · escala logarítmica



5× por año

crece el cómputo de entrenamiento de los modelos frontera desde 2020.

> 280×

cayó el precio de inferencia de nivel GPT-3.5: de US\$ 20 a US\$ 0,07 por millón de tokens (nov 2022 a oct 2024).

3,3%


separa al mejor modelo abierto del mejor cerrado (mar 2026); fue 8,0% en ene 2024 y 1,7% en feb 2025.

Entrenar se encarece y usar se abarata: por eso casi nadie preentrena y casi todos adaptan.

Pausa

15 MINUTOS

Al volver: ¿qué parte del caso queda sin resolver si el modelo solo lee texto?




Más allá del texto

ACTO 4 DE 7 · 30 MIN


¿Y si la entrada no es texto?

«Language Is Not All You Need», titulaba Microsoft en 2023: percibir imágenes, documentos y audio pasa a ser parte del modelo de lenguaje.



CLIP: alinear imagen y texto

SESIÓN 1 · ACTO 4 · MULTIMODAL



400M

pares imagen-texto tomados de la web

76,2%


en ImageNet sin usar ninguno de sus 1,28M ejemplos: iguala a ResNet-50

CLIP alinea dos espacios, no genera texto: es el ladrillo visual de casi todos los VLM.

Flamingo: visión sobre un LM congelado

SESIÓN 1 · ACTO 4 · MULTIMODAL

■ congelado ■ entrenado



80B

parámetros; el LM es Chinchilla 70B, congelado

16 tareas

con pocos ejemplos en el prompt es el mejor método few-shot en todas, y supera a modelos ajustados en 6

Idea que perdura: congelar lo caro, visión y lenguaje, y entrenar solo el puente entre ambos.

Kosmos y GPT-4V: percibir y anclar

SESIÓN 1 · ACTO 4 · MULTIMODAL

Kosmos-1 · feb 2023

«Language Is Not All You Need»: un MLLM de unos 1,6B entrenado desde cero con texto e imágenes intercalados.

Kosmos-2 · jun 2023


Grounding: vincula frases con regiones de la imagen. Dataset GrIT: unos 91M de imágenes y 137M de cajas.

Kosmos-2.5 · sep 2023

Modelo «letrado»: lee imágenes con mucho texto y devuelve el texto con su posición, o en markdown.

GPT-4V · sep 2023

Visión en un LLM de frontera, con una system card dedicada a sus riesgos: el despliegue masivo de los VLM.



Grounding: «un **paquete dañado** sobre el mesón» → caja (x_1, y_1, x_2, y_2)

En el caso, la evidencia visual queda ligada a una región de la foto que un analista puede revisar.


La línea de Microsoft continúa en Florence-2 y Phi-4-multimodal (2025).

La descripción debe vincularse a una región o página verificable.

SAM: segmentar a partir de un prompt

SESIÓN 1 · ACTO 4 · MULTIMODAL

Un modelo fundacional de visión con interfaz de prompt: el «prompt» es un punto, una caja o, desde SAM 3, una frase corta.



SAM · abr 2023

Dataset SA-1B: 11M de imágenes y más de 1.000M de máscaras. Transferencia zero-shot a tareas nuevas.

SAM 2 · jul 2024

Imágenes y video con memoria en streaming; en imágenes es 6 veces más rápido que SAM.

SAM 3 · nov 2025


Segmenta por concepto, con una frase corta o un ejemplo. 848M de parámetros; SA-Co reúne 270K conceptos.

En el caso: el VLM describe el daño; SAM delimita la región exacta que el analista puede auditar.

Anatomía de un MM-LLM

SESIÓN 1 · ACTO 4 · MULTIMODAL

Comprensión multimodal



126

MM-LLM catalogados en la taxonomía del survey (2024)


Lo habitual es entrenar solo los proyectores: una fracción mínima de los parámetros, con el encoder y el LLM congelados.

Casi todo MM-LLM es un LLM de texto con adaptadores de entrada y de salida.

Fuente: Zhang et al. (2024), MM-LLMs: Recent Advances in MultiModal Large Language Models

LLaVA: la receta abierta

SESIÓN 1 · ACTO 4 · MULTIMODAL



Datos

158K instrucciones multimodales generadas con GPT-4: 58K de conversación, 23K de descripción detallada y 77K de razonamiento.

Entrenamiento y resultado

Etapas 1: solo el proyector. Etapa 2: proyector y LLM. Alcanza 85,1% de puntaje relativo frente a GPT-4 y 90,92% en ScienceQA. LLaVA-1.5 pasa a un proyector MLP y CLIP a 336 px.


Un proyector lineal y 158K ejemplos sintéticos bastaron para una receta abierta y reproducible.

Gemini y la multimodalidad nativa

SESIÓN 1 · ACTO 4 · MULTIMODAL

Fusión tardía: encoder + proyector

Flamingo · LLaVA · Qwen3-VL · InternVL3.5



Fusión temprana: multimodal nativo

Gemini · GPT-4o · Llama 4 · Qwen3.5



Un solo Transformer entrenado con todas las modalidades

■ texto ■ imagen ■ audio: una misma secuencia

Gemini 1.0 Ultra · dic 2023

90,04% en MMLU: primer modelo sobre el 89,8% de los expertos humanos.

Gemini 1.5 Pro · feb 2024

Arquitectura MoE y contexto de 1M de tokens: una hora de video u once de audio en una sola consulta.

Contrapunto · 2026

Phi-4-reasoning-vision defiende la fusión intermedia por su menor costo en datos y cómputo.

Nativo gana en integración de modalidades; modular gana en costo y reutilización de un LLM existente.

Evaluación multimodal: avances y fallos

SESIÓN 1 · ACTO 4 · MULTIMODAL

MMMU · razonamiento experto con imágenes



Gemini 3.1 Pro, 2026

DocVQA · lectura de documentos



saturado: deja de distinguir modelos

OSWorld · uso de un computador




desde cerca de 12% un año antes

Fallo	Prueba	Respuesta del sistema
Texto pequeño o borroso	Variar resolución y nitidez	Pedir mejor imagen o escalar
Tabla ambigua	Comparar extracción por campo	Validar estructura y unidades
Objeto fuera del encuadre	Casos visuales incompletos	Declarar evidencia insuficiente
Instrucción hostil en la imagen	Prueba adversarial controlada	Tratar el contenido como datos

OCR extrae caracteres. La interpretación y la decisión requieren controles adicionales.

¿Especialista o generalista?

BioLM, CodeLM y FinLM prometen conocer el oficio. La pregunta es cuándo ese conocimiento compensa no usar el mejor modelo general.



Tres rutas hacia un modelo de dominio

SESIÓN 1 · ACTO 5 · DOMINIO

1 · Preentrenar desde cero

Corpus propio desde el primer token:
control total de datos y vocabulario.

BioGPT: 15M de resúmenes de PubMed

BioMedLM: 2,7B, solo PubMed

BloombergGPT: 50B con 363B tokens
financieros y 345B generales

2 · Continuar el preentrenamiento

Un modelo base abierto sigue
aprendiendo con corpus del dominio.

Code Llama: Llama 2 + 500B tokens de
código

SaulLM: Mixtral + corpus legal

Latam-GPT: Llama 3.1 70B + 296,5B
tokens regionales

3 · Ajustar con instrucciones

Pocos datos de alta calidad cambian el
comportamiento, no el conocimiento
base.

Med-PaLM 2: PaLM 2 + ajuste médico

FinGPT: LoRA sobre LLM abiertos

MedGemma: Gemma 3 + encoder
MedSigLIP

más costo, datos y control

menos costo y tiempo

La ruta 3 es hoy el punto de partida; las rutas 1 y 2 exigen justificar datos y cómputo.

BioLM, CodeLM y FinLM



SESIÓN 1 · ACTO 5 · DOMINIO

Dominio	Modelo	Tamaño · año	Dato destacado
Biomedicina	BioGPT	347M · 2022	78,2% en PubMedQA
Biomedicina	Med-PaLM 2	sobre PaLM 2 · 2023	Hasta 86,5% en MedQA, preguntas tipo examen médico
Biomedicina	Med-Gemini	sobre Gemini · 2024	91,1% en MedQA
Biología	ESM3 · Evo 2	98B · 2024 y 40B · 2025	Proteínas nuevas; ADN con contexto de 1M de tokens
Código	Codex	12B · 2021	28,8% pass@1 en HumanEval
Código	Code Llama	7B a 70B · 2023	Llama 2 + 500B tokens de código; entradas de hasta 100K
Código	StarCoder2	3B a 15B · 2024	The Stack v2: 619 lenguajes de programación
Finanzas	BloombergGPT	50B · 2023	363B tokens financieros + 345B generales
Finanzas	FinGPT	LoRA · 2023	Marco abierto sobre LLM de pesos abiertos


Tres dominios, un patrón: corpus especializado, evaluación propia del oficio y tamaños modestos.

Generalistas frente a especialistas

SESIÓN 1 · ACTO 5 · DOMINIO


MedQA · % de aciertos

■ especialista ■ generalista



Finanzas · GPT-4 frente a BloombergGPT

■ GPT-4 ■ BloombergGPT



El generalista de frontera suele ganar en texto; el especialista resiste en nichos como NER.

Cuándo conviene un modelo de dominio

SESIÓN 1 · ACTO 5 · DOMINIO


Modalidad Proteínas, ADN o imagen médica: un generalista de texto no las cubre (ESM3, Evo 2, MedGemma).

Privacidad Datos que deben quedarse en infraestructura propia: un modelo abierto, pequeño y ajustado.

Costo Alto volumen y tarea acotada: decide el costo por tarea aceptada, no el ranking general.

Idioma y cultura Latam-GPT (CENIA, feb 2026): Llama 3.1 70B con 296,5B tokens de la región. ALIA-40b (BSC) en España.

Corpus de Latam-GPT
miles de millones de tokens




70,6B parámetros · 128 GPU H200 · pesos publicados bajo la licencia de Llama 3.1

En el caso: un encoder o SLM ajustado para clasificar; un generalista con RAG para redactar.

ACTO 6 DE 7 · 30 MIN

¿Cómo se adapta un modelo sin reentrenarlo?

Entre escribir un prompt y preentrenar hay una escalera de técnicas. Cada peldaño cuesta más y cambia algo distinto: el contexto, el conocimiento o los pesos.




La escalera de adaptación

SESIÓN 1 · ACTO 6 · ADAPTACIÓN

Subir un peldaño solo cuando el anterior no alcanza el umbral de calidad.


Cada peldaño multiplica costo, datos y tiempo.



En producción dominan los dos primeros peldaños; el ajuste fino es la excepción.

In-context learning

SESIÓN 1 · ACTO 6 · ADAPTACIÓN



GPT-3 · 2020

Zero, one y few-shot sin actualizar pesos; lo típico son 10 a 100 ejemplos en el prompt.

Min et al. · 2022

Cambiar las etiquetas por otras al azar apenas baja el desempeño (0 a 5 puntos): pesan el formato, la distribución de las entradas y el espacio de etiquetas.

Modelos de razonamiento · 2024


En o1-preview, agregar ejemplos few-shot perjudicó el resultado: menos ejemplos y más instrucción.

Adapta en segundos y sin datos de entrenamiento: el primer peldaño, siempre.

RAG: recuperar antes de generar

SESIÓN 1 · ACTO 6 · ADAPTACIÓN

INDEXACIÓN · FUERA DE LÍNEA





Diseño original (2020): recuperador denso DPR + generador BART sobre 21M de pasajes de Wikipedia de 100 palabras.

RAG cambia lo que el modelo sabe en esta consulta; los pesos quedan intactos y las fuentes, citables.

RAG avanzado: dónde falla la respuesta


SESIÓN 1 · ACTO 6 · ADAPTACIÓN



Una respuesta errónea puede originarse antes de la llamada al LLM.

PEFT: mapa de técnicas

SESIÓN 1 · ACTO 6 · ADAPTACIÓN



Biblioteca de referencia: Hugging Face PEFT (versión 0.20, julio de 2026).


La apuesta común: el conocimiento ya está en los pesos; adaptar es moverlos muy poco.

Fuentes: Houlsby (2019) · Li y Liang (2021) · Lester (2021) · Hu (2021) · Liu (2022) · Dettmers (2023) · Liu (2024), DoRA

LoRA por dentro

SESIÓN 1 · ACTO 6 · ADAPTACIÓN

$$h = W \cdot x + B \cdot A \cdot x$$



Solo A y B reciben gradiente.

$$d = k = 4.096 \cdot r = 8$$

W tiene 16,8M de parámetros; A + B suman 65.536: 256 veces menos por matriz.

GPT-3 175B

10.000 veces menos parámetros entrenables y 3 veces menos memoria de GPU que el ajuste completo.

Al desplegar


B·A se suma a W: sin latencia adicional en inferencia.

Un adaptador LoRA pesa megabytes: uno por cliente, tarea o tono sobre la misma base.

QLoRA y la memoria de ajuste

SESIÓN 1 · ACTO 6 · ADAPTACIÓN

Memoria de GPU para ajustar un modelo de 65B



Cómo lo logra

Base cuantizada a 4 bits (NF4), doble cuantización de las constantes y optimizadores paginados; los adaptadores LoRA se entrenan en 16 bits.

Resultado

Guanaco alcanza el 99,3% del nivel de ChatGPT en el benchmark Vicuna con 24 horas de ajuste en una sola GPU.

LoRA Without Regret · 2025

LoRA iguala al ajuste completo si se aplica a todas las capas, incluidas las MLP, y el dataset no excede la capacidad del adaptador. La tasa de aprendizaje óptima es unas 10 veces mayor.


El ajuste fino dejó de ser un proyecto de infraestructura: cabe en una sola GPU.

Qué técnica para qué necesidad

SESIÓN 1 · ACTO 6 · ADAPTACIÓN

Necesidad	Mecanismo	Validación
Instrucción y ejemplo puntual	Prompt e in-context learning	Cumplimiento de formato y tarea
Hechos privados o cambiantes	RAG y herramientas	Recuperación, permisos y soporte
Comportamiento repetible	SFT con LoRA	Mejora y regresión fuera de muestra
Cálculo o acción exacta	Código o API autorizada	Resultado y auditoría


Adopción en empresas · 2024



RAG y fine-tuning pueden coexistir porque resuelven necesidades diferentes.


¿Cuánto contexto es suficiente?

Las ventanas crecieron de 2 mil a 10 millones de tokens. Que un modelo acepte un millón de tokens no significa que los use bien.



El cuello de botella de la atención

SESIÓN 1 · ACTO 7 · LÍMITES



Duplicar el contexto cuadruplica el costo de la atención densa.

De 2K a 1M tokens hay 512 veces más texto y 262.144 veces más pares que comparar.


FlashAttention elimina la memoria cuadrática; el cómputo sigue siendo n^2 .

El costo del Acto 2 vuelve aquí: todas las posiciones contra todas.

Fuentes: Vaswani et al. (2017) · Dao et al. (2022), FlashAttention. Cálculo propio: $(n / 2.048)^2$ frente a $n / 2.048$.

Ventanas de contexto: de 2K a 10M

SESIÓN 1 · ACTO 7 · LÍMITES



≈ **30x**

por año creció la ventana máxima desde mediados de 2023

GPT-6, Claude, Gemini 3.1 y DeepSeek V4 anuncian 1M de tokens.


De 2.048 tokens a 10 millones en cinco años: casi 5.000 veces.

Fuentes: documentación oficial de cada modelo · Stanford AI Index 2026

Lost in the Middle

SESIÓN 1 · ACTO 7 · LÍMITES

Exactitud según la posición del documento con la respuesta



GPT-3.5-Turbo responde sobre 20 documentos; solo uno contiene la respuesta.


Con el documento clave al medio rinde peor que sin documentos: 53,8% frente a 56,1%.

Ordenar el contexto importa: lo esencial va al inicio o al final.

Más contexto puede añadir ruido. Recuperar y resumir exige comprobar qué se pierde.

Contexto anunciado y contexto efectivo

SESIÓN 1 · ACTO 7 · LÍMITES



11 de 13

modelos con ventanas de 128K o más caen bajo el 50% de su línea base a 32K (NoLiMa, 2025).

La mitad

de 17 modelos mantiene un desempeño satisfactorio a 32K (RULER, 2024).

18 modelos

pierden exactitud al crecer la entrada, incluso en tareas triviales (Context Rot, 2025).


La ventana anunciada es un máximo técnico; la efectiva se mide con la tarea propia.

KV cache: la memoria del contexto

SESIÓN 1 · ACTO 7 · LÍMITES

KV por token = $2 \times \text{capas} \times \text{cabezas KV} \times \text{dimensión} \times \text{bytes}$

Llama 3.1 8B en fp16: $2 \times 32 \times 8 \times 128 \times 2 = 131.072$ bytes, unos 128 KiB por token



Una sola secuencia de 128K ocupa 17,2 GB de caché: más que los pesos.

GQA divide la caché por cuatro frente a la atención multi-cabeza clásica.

La concurrencia multiplica: diez usuarios con 128K son 172 GB solo de caché.

Pesos $\approx$ parámetros $\times$ bits / 8: un 8B a 4 bits son 4 GB, antes de caché, activaciones y buffers.

4 GB de pesos no equivalen a 4 GB de memoria total para ejecutar el modelo.

Long-context transformers: herramientas




SESIÓN 1 · ACTO 7 · LÍMITES

Palanca	Técnicas	Efecto
Atención exacta eficiente	FlashAttention (2022) hasta FlashAttention-4 (2026)	Memoria lineal en n ; mismo resultado
Menos KV cache	MQA, GQA y MLA	Menos memoria por token generado
Atención local o dispersa	Longformer, ventana deslizante de Mistral, NSA y DSA de DeepSeek	Costo por debajo de n^2
Posición extrapolable	RoPE, ALiBi y YaRN	Extender el contexto sin reentrenar desde cero
Paralelismo de secuencia	Ring Attention	Repartir millones de tokens entre varias GPU
Arquitecturas híbridas	Mamba, Jamba, Falcon-H1, Granite 4, Qwen3.5 y Kimi K3	Estado de tamaño fijo: costo lineal

En 2026 los modelos abiertos más grandes ya mezclan atención con capas lineales o dispersas.

LCM: predecir conceptos, no tokens

SESIÓN 1 · ACTO 7 · LÍMITES



El mismo párrafo: un paso por token o un paso por frase

LLM · 50 pasos



LCM · 4 pasos



Meta FAIR · dic 2024

Un «concepto» es una frase codificada con SONAR: no depende del idioma ni de la modalidad.

Escala probada

1,6B de parámetros con 1,3T tokens; después, 7B con 2,7T tokens. Código de entrenamiento abierto.


Resultado

Generaliza zero-shot a muchos idiomas mejor que LLM de su tamaño. Sigue siendo una prueba de concepto.

Cambiar la unidad de predicción es otra forma de atacar el límite de contexto: menos pasos, más abstracción.

LAM: del lenguaje a la acción

SESIÓN 1 · CIERRE · DEL MODELO A LA DECISIÓN



La autonomía necesita condición de término, presupuesto y permisos aplicados en código, fuera del prompt.

Qué es

Un LLM entrenado o ajustado para producir acciones ejecutables y comprobar su efecto, no solo texto.

xLAM · Salesforce, 2024

Familia abierta de 1B a 8×22B; primer lugar del Berkeley Function-Calling Leaderboard al publicarse.

Marco de Microsoft · 2024

Cinco etapas: datos, entrenamiento, integración con el entorno, grounding y evaluación, sobre un agente de Windows.

En el caso: consultar el estado es una acción; autorizar el pago sigue siendo decisión de una persona.

Selección de xLM por contrato de tarea




SESIÓN 1 · CIERRE · DEL MODELO A LA DECISIÓN

Contrato	Candidato inicial	Aceptación
Etiquetar la intención en español	Encoder ajustado o SLM	Recall por clase y costo
Sintetizar un expediente ambiguo	LLM causal + RAG	Cobertura y omisiones
Extraer datos de una foto	VLM + reglas	Exactitud por campo crítico
Responder con tono y formato fijos	LLM + LoRA	Regresión fuera de muestra
Resolver una consulta con acciones	LAM o LLM con herramientas	Éxito, permisos y recuperación

La familia inicia la prueba. El conjunto de evaluación decide.

Mapa del ecosistema xLM

SESIÓN 1 · CIERRE · DEL MODELO A LA DECISIÓN



Un mismo bloque, muchas especies: las ocho siglas del inicio ya tienen su lugar en el mapa.

Taller: reclamos multimodales

SESIÓN 1 · TALLER · 15% DE LA NOTA DEL MÓDULO

Situación

Empresa con 30.000 casos al mes

Consultas de texto y documentos

20% de los casos incluyen imágenes

Las políticas cambian cada semana

Objetivo y restricciones

Menos tiempo, sin más reaperturas

Trazabilidad de afirmaciones factuales

Acceso según el perfil del usuario

Una persona autoriza compensaciones

Datos disponibles

Políticas con versión y fecha · 2.000 reclamos anonimizados · imágenes de calidad variable · API de consulta de estado

Caso ficticio. El piloto inicial asiste al analista y registra su decisión.

Entregable y rúbrica del taller



SESIÓN 1 · TALLER · 15% DE LA NOTA DEL MÓDULO

Una página por grupo

- Familia** Qué xLM resuelve cada una de las cinco tareas del caso, y por qué.
- Adaptación** In-context, RAG, LoRA o ajuste completo para cada pieza.
- Límites** Riesgo de contexto, memoria o modalidad, y cómo se mitiga.
- Evidencia** Métrica de aceptación y resultado que refutaría el diseño.

Criterio	Peso
Familia de modelo por tarea	30%
Técnica de adaptación	25%
Evaluación y métricas	25%
Límites y riesgos	10%
Defensa	10%

25 min: análisis 5 · diseño 12 · defensa 8 · Puntaje: 0 ausente · 1 declarado · 2 parcial · 3 sustentado · 4 verificable

Solución de referencia del caso

SESIÓN 1 · TALLER · 15% DE LA NOTA DEL MÓDULO

Decisiones

Un modelo por tarea, no uno para todo

Contexto corto y ordenado

Políticas por RAG, tono por LoRA

Trazas: evidencia, respuesta, decisión



Inicio posible: workflow con herramientas. Añadir agentes si una prueba demuestra su aporte.

Cierre: cinco ideas

SESIÓN 1 · CIERRE

- 1** Un mismo bloque, self-attention, dio origen a todas las familias xLM.
- 2** Los encoders comprenden y los decoders generan: la tarea decide la familia.
- 3** Multimodal y dominio repiten un patrón: codificar, proyectar y adaptar.
- 4** Adaptar es una escalera: contexto, RAG, LoRA y, al final, ajuste completo.
- 5** El contexto anunciado no es el contexto efectivo: medir antes de confiar.

La pregunta guía queda respondida: cada parte del caso tiene su xLM y su técnica de adaptación.

Referencias: fundamentos y familias

SESIÓN 1 · REFERENCIAS

[T] Vaswani et al. (2017). Attention Is All You Need

[B] Devlin et al. (2018). BERT: Pre-training of Deep Bidirectional Transformers

[G3] Brown et al. (2020). Language Models are Few-Shot Learners

[K] Kaplan et al. (2020). Scaling Laws for Neural Language Models

[CH] Hoffmann et al. (2022). Training Compute-Optimal Large Language Models

[LL] Touvron et al. (2023). LLaMA: Open and Efficient Foundation Language Models

[MI] Jiang et al. (2023, 2024). Mistral 7B · Mixtral of Experts

[FM] Bommasani et al. (2021). On the Opportunities and Risks of Foundation Models

[I] Ouyang et al. (2022). Training language models to follow instructions with human feedback

[H] Hinton (1986) · Bengio et al. (2003) · Mikolov et al. (2013) · Sutskever et al. (2014) · Bahdanau et al. (2014) · Trinh et al. (2024)

Fuentes primarias y documentación oficial. Consulta: 19 al 21 de septiembre de 2026.

Referencias: multimodal y dominio

SESIÓN 1 · REFERENCIAS

[CL] Radford et al. (2021). Learning Transferable Visual Models From Natural Language Supervision

[FL] Alayrac et al. (2022). Flamingo: a Visual Language Model for Few-Shot Learning

[KO] Huang et al. (2023). Language Is Not All You Need · Peng et al. (2023). Kosmos-2 · Lv et al. (2023). Kosmos-2.5

[4V] OpenAI (2023). GPT-4V(ision) System Card

[LV] Liu et al. (2023). Visual Instruction Tuning

[GE] Gemini Team (2023, 2024). Gemini · Gemini 1.5

[MM] Zhang et al. (2024). MM-LLMs: Recent Advances in MultiModal Large Language Models

[BIO] Luo et al. (2022). BioGPT · Singhal et al. (2023). Med-PaLM 2 · Saab et al. (2024). Med-Gemini

[COD] Chen et al. (2021). Codex · Rozière et al. (2023). Code Llama · Lozhkov et al. (2024). StarCoder2

[FIN] Wu et al. (2023). BloombergGPT · Yang et al. (2023). FinGPT · Li et al. (2023). EMNLP Industry Track

Fuentes primarias y documentación oficial. Consulta: 19 al 21 de septiembre de 2026.

Referencias: adaptación y límites

SESIÓN 1 · REFERENCIAS

[L] Hu et al. (2021). LoRA · [Q] Dettmers et al. (2023). QLoRA

[PE] Houlsby et al. (2019) · Li y Liang (2021) · Lester et al. (2021) · Liu et al. (2022)

[RA] Lewis et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks

[IC] Min et al. (2022). Rethinking the Role of Demonstrations

[C] Liu et al. (2023). Lost in the Middle · Hsieh et al. (2024). RULER · Modarressi et al. (2025). NoLiMa

[FA] Dao et al. (2022). FlashAttention · Gu y Dao (2023). Mamba · Kwon et al. (2023). PagedAttention

[AI] Stanford HAI (2025, 2026). AI Index Report · Epoch AI (2026). Trends

[MV] Menlo Ventures (2024). The State of Generative AI in the Enterprise

[LA] CENIA (2026). Latam-GPT: reporte técnico · BSC (2026). ALIA-40b

[E] Liang et al. (2022). Holistic Evaluation of Language Models

Fuentes primarias y documentación oficial. Consulta: 19 al 21 de septiembre de 2026.

Referencias: SLM, SAM, LCM y LAM

SESIÓN 1 · REFERENCIAS

[P3] Abdin et al. (2024). Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone

[KD] Hinton, Vinyals y Dean (2015). Distilling the Knowledge in a Neural Network

[SL] Belcak et al., NVIDIA (2025). Small Language Models are the Future of Agentic AI

[SA] Kirillov et al. (2023). Segment Anything · Ravi et al. (2024). SAM 2: Segment Anything in Images and Videos

[S3] Meta (2025). SAM 3: Segment Anything with Concepts

[LC] LCM team, Meta FAIR (2024). Large Concept Models: Language Modeling in a Sentence Representation Space

[SO] Duquenne et al. (2023). SONAR: Sentence-Level Multimodal and Language-Agnostic Representations

[XL] Zhang et al., Salesforce (2024). xLAM: A Family of Large Action Models to Empower AI Agent Systems

[LM] Wang et al., Microsoft (2024). Large Action Models: From Inception to Implementation

[8M] Infografía de divulgación «8 Different Specialized AI Models»: punto de partida del mapa de ocho siglas

Fuentes primarias y documentación oficial. Consulta: 19 al 21 de septiembre de 2026.

EXAMEN

12 de octubre

TAREA

Lanzamiento: 19 de octubre

15 días de trabajo

PRÓXIMA SESIÓN