

# Sistema Inteligente de Recomendación y Simulación Predictiva para Capacity Planning Cloud en Banco BCI

Proyecto CAPSTONE - Magíster de Inteligencia Artificial - UAI

Alumnos: Luis Araya D. - Rodrigo González S. - Hernán Medina M.

LÁMINA 1 DE 11





# Contexto: Banco BCI en Microsoft Azure

## Operaciones críticas con alta variabilidad

Banco BCI opera sistemas críticos en **Microsoft Azure** con alta variabilidad de demanda por:

- Cierres de mes
- Pagos de nómina
- Releases de software
- Pruebas DRP

## El problema actual

Las decisiones de capacity planning dependen de **dashboards complejos, experiencia y heurísticas humanas**, generando:

- Sobrecostos
- Saturación de recursos
- Fallas evitables

# ¿Quién lo usa y qué necesita?



## Platform / Cloud Engineer

Gestiona la infraestructura cloud y necesita visibilidad predictiva sobre el consumo de recursos en Azure.



## DevOps Engineer

Coordina releases y pruebas de carga, requiriendo anticipar el impacto sobre la capacidad disponible.



## Arquitecto de Plataforma

Define configuraciones de infraestructura y necesita simulaciones confiables antes de aplicar cambios.

**JTBD:** "Cuando debo planificar infraestructura para un sistema, necesito estimar la capacidad necesaria, así podría evitar fallas y gastos innecesarios."



# ¿Por qué es un problema crítico?

## **Dashboards complejos sin predicción**

Los ingenieros deben interpretar manualmente métricas de Azure Monitor y Application Insights sin apoyo predictivo, aumentando el margen de error humano.

## **Heurísticas que generan sobrecostos**

Las decisiones basadas en experiencia y reglas empíricas llevan a sobreaprovisionamiento de recursos cloud, incrementando innecesariamente el gasto operacional.

## **Saturación y fallas evitables**

Sin simulación predictiva, los peaks de demanda por cierres de mes o pagos de nómina generan saturación de CPU, memoria y latencia, causando incidentes críticos.

## **Ausencia de validación antes de cambios**

No existe un mecanismo que permita al equipo validar el impacto de una configuración antes de aplicarla en producción, elevando el riesgo operacional.

# Objetivos, Entregables y Alcance

## Objetivo General

Diseñar un **AI Capacity Planning Copilot** con agentes inteligentes que permita a los equipos de plataforma de Banco BCI anticipar, simular y recomendar configuraciones de infraestructura cloud de forma autónoma y validada.

## Hipótesis Central

Agentes inteligentes sobre métricas históricas permitirán **reducir costos cloud y fallas por saturación** frente al enfoque heurístico actual.

## Entregables del Proyecto (PoC)

1. Modelo predictivo de demanda cloud (ML)
2. Motor de simulación de saturación
3. Motor de recomendación de configuraciones
4. Interfaz de validación humana antes de aplicar cambios
5. Dashboard ejecutivo de KPIs
6. Documentación técnica y académica

## Alcance

Sistemas críticos de Banco BCI en **Microsoft Azure**: métricas de CPU, memoria, latencia, throughput, costos e incidentes.

# Pipeline de Agentes Inteligentes



El **AI Capacity Planning Copilot** opera como un sistema de agentes inteligentes encadenados: ingiere métricas en tiempo real desde Azure Monitor y Application Insights, detecta patrones históricos, predice peaks de demanda, simula escenarios de saturación, genera recomendaciones de configuración y —de forma crítica— **permite la validación humana antes de aplicar cualquier cambio** en producción.

# Metodología Híbrida: Discovery + ML



## Fase 1: Discovery

Entrevistas con Platform Engineers, mapeo de JTBD, análisis de dashboards actuales y levantamiento de fuentes de datos Azure.



## Fase 2: Ingesta y EDA

Extracción de Azure Monitor, Application Insights, logs de incidentes y pruebas de carga. Análisis exploratorio descriptivo.



## Fase 3: Modelado ML

Entrenamiento de modelos predictivos de demanda (series de tiempo, regresión, detección de anomalías) sobre métricas históricas.



## Fase 4: Simulación y Validación

Motor de simulación de saturación, generación de recomendaciones y ciclo de validación humana con feedback loop.

- ❏ La metodología híbrida combina **Design Thinking (Discovery)** para entender el problema desde el usuario, con **Machine Learning aplicado** sobre datos reales de Azure para construir la solución predictiva.

# Fuentes de Datos y Análisis Descriptivo

## Fuentes de Datos

|                                                                        |                                                                  |
|------------------------------------------------------------------------|------------------------------------------------------------------|
| <b>Azure Monitor</b><br>CPU, Memoria, Latencia, Throughput             | <b>Application Insights</b><br>Trazas, excepciones, dependencias |
| <b>Costos &amp; Incidentes</b><br>Billing Azure, tickets de incidentes | <b>Pruebas de Carga</b><br>Resultados de pruebas<br>DRP y stress |

## Variables Clave del Análisis

| Variable               | Tipo       | Relevancia          |
|------------------------|------------|---------------------|
| CPU Usage (%)          | Continua   | Predictor principal |
| Memoria (GB)           | Continua   | Saturación de nodos |
| Latencia (ms)          | Continua   | SLA crítico         |
| Throughput (req/s)     | Continua   | Demanda real        |
| Costo (USD/h)          | Continua   | KPI financiero      |
| Evento (cierre/nómina) | Categórica | Estacionalidad      |



# Benchmark: Soluciones Actuales vs. AI Copilot

| Capacidad                | Dashboards Actuales | Azure Advisor | Herramientas AIOps | AI Copilot BCI |
|--------------------------|---------------------|---------------|--------------------|----------------|
| Predicción de peaks      | ✗ No                | ⚠ Parcial     | ✓ Sí               | ✓ Sí           |
| Simulación de saturación | ✗ No                | ✗ No          | ⚠ Limitada         | ✓ Sí           |
| Recomendación automática | ✗ No                | ✓ Sí          | ✓ Sí               | ✓ Sí           |
| Validación humana        | ✓ Manual            | ✗ No          | ⚠ Parcial          | ✓ Sí           |
| Contexto BCI (eventos)   | ⚠ Parcial           | ✗ No          | ✗ No               | ✓ Sí           |
| Integración Azure nativa | ✓ Sí                | ✓ Sí          | ⚠ Variable         | ✓ Sí           |

El **AI Capacity Planning Copilot** es la única solución que combina predicción de peaks, simulación de saturación, recomendación automática y **validación humana con contexto específico de Banco BCI**.

# Bibliografía y Planificación Gantt

## Referencias Bibliográficas

Weyns, D. (2021). *An Introduction to Self-Adaptive Systems*. Wiley.

Lim, H. et al. (2022). *Predictive Autoscaling in Cloud Environments*. IEEE Cloud Computing.

Microsoft Azure. (2023). *Azure Monitor & Application Insights Documentation*.

Ulrich, K. & Eppinger, S. (2015). *Product Design and Development*. McGraw-Hill.

Hyndman, R. & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. OTexts.

## Planificación del Proyecto (Gantt Simplificado)

| Fase                    | Mes 1       | Mes 2       | Mes 3       | Mes 4                   |
|-------------------------|-------------|-------------|-------------|-------------------------|
| Discovery & Entrevistas | <div></div> |             |             |                         |
| Ingesta de Datos & EDA  | <div></div> | <div></div> |             |                         |
| Modelado ML             |             | <div></div> | <div></div> |                         |
| Motor de Simulación     |             |             | <div></div> |                         |
| Validación & Feedback   |             |             | <div></div> | <div></div>             |
| Documentación & Entrega |             |             |             | <div></div> <div></div> |



# Hipótesis Crítica y Próximos Pasos

**Hipótesis:** Agentes inteligentes sobre métricas históricas permitirán reducir costos cloud y fallas por saturación frente al enfoque heurístico actual.

↓30%

## Reducción de costos

Estimado por eliminación de sobreaprovisionamiento

↓50%

## Fallas por saturación

Incidentes evitables con predicción anticipada

100%

## Validación humana

Toda recomendación validada antes de aplicar

01

### Acceso a datos Azure de Banco BCI

Formalizar acuerdo de datos con el equipo de plataforma para iniciar la fase de ingesta y EDA.

02

### Prototipo del motor predictivo

Desarrollar el primer modelo ML sobre métricas históricas de CPU, memoria y latencia.

03

### Validación con usuarios reales

Iterar el copilot con Platform Engineers y Arquitectos de Plataforma en sesiones de feedback estructuradas.