

FACULTAD DE
INGENIERÍA Y CIENCIAS



UAI
UNIVERSIDAD ADOLFO IBÁÑEZ

INTRODUCCIÓN A PYTHON

PANDAS Y GRÁFICOS

Miguel Carrasco
miguel.carrasco@uai.cl



- ▶ Introducción a Pandas
 - Operaciones básicas de datos
 - Agrupaciones de datos
 - Pivot table
 - CrossTab
 - Gráfica matplotlib
 - Gráfica Plotly



```
self.FidValue = OrderedDict(sorted(self.FidValue.items(), key=lambda item: item[0]))
#Read item in dictionary
for key, value in item.FidValue.items():
    typeOfFID = mapFidType[key]
    if (typeOfFID == "DATE"):
        d = datetime.datetime.strptime(str(value), "%Y-%m-%d")
        dataCal = datetime.date.strptime(str(d), "%Y-%m-%d")
        FidAndValue = FidAndValue + value
    else: FidAndValue = FidAndValue + value
```

```
try:
    start = date(int(self.start_year.get()),
                 self.months.index(self.start_month.get()),
                 int(self.start_day.get()))

    end = date(int(self.end_year.get()),
               self.months.index(self.end_month.get()),
               int(self.end_day.get()))
```



Combinar dos o más atributos en un único atributo o objeto


Reducción de datos Reducir el número de atributos o objetos

Cambio de escala Emplear una escala mayor para reducir el número de posibles salidas

Estabilizar datos Agregar datos tiene a disminuir la variabilidad



Combinar dos o más atributos en un único atributo o objeto



```
import pandas as pd
df = pd.read_csv('simple_data.csv')
grupos = df.groupby('Edad')
print(grupos.describe())
```

groupby() nos permite crear agrupaciones por un campo

con el commando describe() Podemos ver un resumen estadístico de los valores agrupados según su agrupación

Altura								
	count	mean	std	min	25%	50%	75%	max
Edad								
2.0	1.0	6.000000	NaN	6.0	6.00	6.0	6.0	6.0
12.0	1.0	13.000000	NaN	13.0	13.00	13.0	13.0	13.0
23.0	4.0	16.550000	19.349677	3.0	5.25	9.1	20.4	45.0
24.0	1.0	23.000000	NaN	23.0	23.00	23.0	23.0	23.0
32.0	1.0	3.000000	NaN	3.0	3.00	3.0	3.0	3.0
45.0	3.0	37.666667	16.502525	24.0	28.50	33.0	44.5	56.0
67.0	1.0	4.000000	NaN	4.0	4.00	4.0	4.0	4.0

df

	Nombre	Altura	Edad
0	Pedro	12.2	23.0
1	Juan	13.0	12.0
2	Diego	45.0	23.0
3	Arturo	24.0	45.0
4	Felipe	23.0	24.0
5	Andrés	56.0	45.0
6	Juan	6.0	2.0
7	Sofía	23.0	NaN
8	Antonia	6.0	23.0
9	Bernardita	4.0	67.0
10	Camila	3.0	32.0
11	Pedro	3.0	23.0
12	Alvaro	34.0	NaN
13	Magnolia	33.0	45.0

```
import pandas as pd
df = pd.read_csv('simple_data.csv')
grupos = df.groupby('Edad')

print('datos separados por grupos: \n')
for key, item in grupos:
    print(grupos.get_group(key), "\n\n")
```

df

	Nombre	Altura	Edad
0	Pedro	12.2	23.0
1	Juan	13.0	12.0
2	Diego	45.0	23.0
3	Arturo	24.0	45.0
4	Felipe	23.0	24.0
5	Andrés	56.0	45.0
6	Juan	6.0	2.0
7	Sofía	23.0	NaN
8	Antonia	6.0	23.0
9	Bernardita	4.0	67.0
10	Camila	3.0	32.0
11	Pedro	3.0	23.0
12	Alvaro	34.0	NaN
13	Magnolia	33.0	45.0

datos separados por grupos:

	Nombre	Altura	Edad
6	Juan	6.0	2
12	Alvaro	NaN	2

	Nombre	Altura	Edad
1	Juan	13.0	12

	Nombre	Altura	Edad
0	Pedro	12.0	23
2	Diego	45.0	23
8	Antonia	6.0	23
11	Pedro	3.0	23

	Nombre	Altura	Edad
4	Felipe	23.0	24

	Nombre	Altura	Edad
10	Camila	3.0	32

	Nombre	Altura	Edad
7	Sofía	NaN	34

	Nombre	Altura	Edad
3	Arturo	24.0	45
5	Andrés	56.0	45
13	Magnolia	33.0	45

	Nombre	Altura	Edad
9	Bernardita	4.0	67



Para aprender Pandas de forma más práctica, iremos paso a paso usando datos de las crisis bancarias que han sufrido países del continente Africano a lo largo de los años 1860 a 2014. Una copia de los datos se encuentra en webcursos para que los bajen



- ▶ Lo que haremos es:
 - Cargar los datos
 - Analizar un dataframe
 - Acceder a datos
 - Realizar filtros
 - Obtener estadísticas


```
import pandas as pd
df = pd.read_csv('african_crises.csv')

grupos = df.groupby('country')

agg_df = grupos[['inflation_crises', 'currency_crises']].agg(['mean'])

print(agg_df)
```

groupby () nos permite crear agrupaciones por un campo

Y sobre esos grupos podemos sacar estadísticas de ciertos campos, en este caso de inflation_crisis con el comando .agg

	inflation_crises mean	currency_crises mean
country		
Algeria	0.164706	0.105882
Angola	0.337662	0.285714
Central African Republic	0.034483	0.034483
Egypt	0.070968	0.051613
Ivory Coast	0.063492	0.015873
Kenya	0.059701	0.134328
Mauritius	0.088235	0.073529
Morocco	0.133333	0.106667
Nigeria	0.200000	0.166667
South Africa	0.008772	0.140351
Tunisia	0.106667	0.133333
Zambia	0.277778	0.263889
Zimbabwe	0.223529	0.233333

```
import pandas as pd  
df = pd.read_csv('african_crises.csv')
```

```
grupos = df.groupby('country')
```

groupby () nos permite crear agrupaciones por un campo

```
estadisticas = grupos['inflation_crises'].agg(['std', 'mean'])
```

```
print(estadisticas)
```

Y sobre esos grupos podemos sacar estadísticas de ciertos campos, en este caso de inflation_crisis con el comando .agg

	std	mean
country		
Algeria	0.373116	0.164706
Angola	0.476014	0.337662
Central African Republic	0.184059	0.034483
Egypt	0.257603	0.070968
Ivory Coast	0.245805	0.063492
Kenya	0.238721	0.059701
Mauritius	0.285746	0.088235
Morocco	0.342224	0.133333
Nigeria	0.403376	0.200000
South Africa	0.093659	0.008772
Tunisia	0.310768	0.106667
Zambia	0.451046	0.277778
Zimbabwe	0.419083	0.223529



*min, max, mean,
sum, std, sorted,
lambda*



Tiempo : 10 minutos

1. Determine el valor promedio y la desviación estándar del índice de precios del consumidor CPI (`inflation_annual_cpi`) de los países en toda su historia
2. Ahora realice la comparación anterior, pero solamente los bancos en los momentos de tiempo que NO han estado en crisis (`banking_crisis`)

Recuerde que tiene los siguientes campos:

- `inflation_annual_cpi` (valores numéricos)
- `banking_crisis` (crisis o no_crisis)



Tiempo : 10 minutos

```
import pandas as pd
df = pd.read_csv('african_crises.csv')

#pregunta 1
group_1 = df.groupby('country')

#determinamos variables estadísticas para cada país
stats_1 = group_1['inflation_annual_cpi'].agg(['std', 'mean'])
print(stats_1)

#pregunta 2
group_2 = df[df['banking_crisis']=='no_crisis'].groupby('country')

#determinamos variables estadísticas para cada país con restricciones
stats_2 = group_2['inflation_annual_cpi'].agg(['std', 'mean'])
print(stats_2)
```



Tiempo : 10 minutos

Determine el número de crisis por país, y luego indique el mayor de todos ellos. Recuerde primero agrupar los datos por país.

Utilice la siguiente columna para conocer si tuvo o no crisis

- `banking_crisis` (crisis o no_crisis)



Tiempo : 10 minutos

```
import pandas as pd
import numpy as np

df = pd.read_csv('data/african_crises.csv')

# agrupamos por país
grp = df.groupby(['country'])

#determinamos aquellos valores por país con crisis
tbl = grp['banking_crisis'].agg([('cont', lambda col: np.sum(col=='crisis'))])

print(f'Número de crisis por país {tbl}')
```



empleamos una función específica en este ejemplo

```
#buscamos el mayor de toda la tabla
id = pd.Series.argmax(tbl['cont'])

# mostramos los resultados
no_crisis = tbl.iloc[id].cont
print(f'{tbl.iloc[id].name} tiene un máximo de {no_crisis} crisis ')
```

- ▶ Introducción a Pandas
 - Operaciones básicas de datos
 - Agrupaciones de datos
 - Pivot table
 - CrossTab
 - Gráfica matplotlib
 - Gráfica Plotly



```
self.FidValue = OrderedDict(sorted(self.FidValue.items(), key=lambda item: item[0]))
#Read item in dictionary
for key, value in item.FidValue.items():
    typeOfFID = mapFidType[key]
    if (typeOfFID == "DATE"):
        d = datetime.datetime.strptime(str(value), "%Y-%m-%d")
        dataCal = datetime.date.strptime(str(d), "%Y-%m-%d")
        FidAndValue = FidAndValue + value
    else: FidAndValue = FidAndValue + value
```

```
try:
    start = date(int(self.start_year.get()),
                 self.months.index(self.start_month.get()),
                 int(self.start_day.get()))

    end = date(int(self.end_year.get()),
               self.months.index(self.end_month.get()),
               int(self.end_day.get()))
```



En muchas ocasiones deseamos organizar los datos de una tabla de modo de extraer información significativa de los datos a través de operaciones entre las columnas y sus datos. Esto es lo que conocemos como tabla pivote (muy empleado en excel)

Data

	A	B	C	D	E	F
1	Order ID	Product	Category	Amount	Date	Country
2	1	Carrots	Vegetables	\$4'270	06-01-16	United States
3	2	Broccoli	Vegetables	\$8'239	07-01-16	United Kingdom
4	3	Banana	Fruit	\$617	08-01-16	United States
5	4	Banana	Fruit	\$8'384	10-01-16	Canada
6	5	Beans	Vegetables	\$2'626	10-01-16	Germany
7	6	Orange	Fruit	\$3'610	11-01-16	United States
8	7	Broccoli	Vegetables	\$9'062	11-01-16	Australia
9	8	Banana	Fruit	\$6'906	16-01-16	New Zealand
10	9	Apple	Fruit	\$2'417	16-01-16	France
11	10	Apple	Fruit	\$7'431	16-01-16	Canada
12	11	Banana	Fruit	\$8'250	16-01-16	Germany
13	12	Broccoli	Vegetables	\$7'012	18-01-16	United States
14	13	Carrots	Vegetables	\$1'903	20-01-16	Germany
15	14	Broccoli	Vegetables	\$2'824	22-01-16	Canada
16	15	Apple	Fruit	\$6'946	24-01-16	France
17	16	Banana	Fruit	\$2'320	27-01-16	United Kingdom
18	17	Banana	Fruit	\$2'116	28-01-16	United States
19	18	Banana	Fruit	\$1'135	30-01-16	United Kingdom
20	19	Broccoli	Vegetables	\$3'595	30-01-16	United Kingdom
21	20	Apple	Fruit	\$1'161	02-02-16	United States
22	21	Orange	Fruit	\$2'256	04-02-16	France
23	22	Banana	Fruit	\$1'004	11-02-16	New Zealand
24	23	Banana	Fruit	\$3'642	14-02-16	Canada

Preguntas

- ¿Qué país vende más plátanos?
- ¿Cuál es el monto promedio de ventas de naranjas?
- ¿Cuál es el monto total de ventas de los vegetales?
- ¿Cuántos productos han sido vendidos?
- ¿Qué país ha vendido menos vegetales?



En muchas ocasiones deseamos organizar los datos de una tabla de modo de extraer información significativa de los datos a través de operaciones entre las columnas y sus datos. Esto es lo que conocemos como tabla pivote (muy empleado en excel)

Data

	A	B	C	D	E	F
1	Order ID	Product	Category	Amount	Date	Country
2	1	Carrots	Vegetables	\$4'270	06-01-16	United States
3	2	Broccoli	Vegetables	\$8'239	07-01-16	United Kingdom
4	3	Banana	Fruit	\$617	08-01-16	United States
5	4	Banana	Fruit	\$8'384	10-01-16	Canada
6	5	Beans	Vegetables	\$2'626	10-01-16	Germany
7	6	Orange	Fruit	\$3'610	11-01-16	United States
8	7	Broccoli	Vegetables	\$9'062	11-01-16	Australia
9	8	Banana	Fruit	\$6'906	16-01-16	New Zealand
10	9	Apple	Fruit	\$2'417	16-01-16	France
11	10	Apple	Fruit	\$7'431	16-01-16	Canada
12	11	Banana	Fruit	\$8'250	16-01-16	Germany
13	12	Broccoli	Vegetables	\$7'012	18-01-16	United States
14	13	Carrots	Vegetables	\$1'903	20-01-16	Germany
15	14	Broccoli	Vegetables	\$2'824	22-01-16	Canada
16	15	Apple	Fruit	\$6'946	24-01-16	France
17	16	Banana	Fruit	\$2'320	27-01-16	United Kingdom
18	17	Banana	Fruit	\$2'116	28-01-16	United States
19	18	Banana	Fruit	\$1'135	30-01-16	United Kingdom
20	19	Broccoli	Vegetables	\$3'595	30-01-16	United Kingdom
21	20	Apple	Fruit	\$1'161	02-02-16	United States
22	21	Orange	Fruit	\$2'256	04-02-16	France
23	22	Banana	Fruit	\$1'004	11-02-16	New Zealand
24	23	Banana	Fruit	\$3'642	14-02-16	Canada

Tabla Pivote

- ¿Cuántos productos han sido vendidos?

	A	B
3	Etiquetas de fila	Suma de Amount
4	Apple	191257
5	Banana	340295
6	Beans	57281
7	Broccoli	142439
8	Carrots	136945
9	Mango	57079
10	Orange	104438
11	Total general	1029734

```
import pandas as pd
df = pd.read_excel('pivot-tables.xlsx', sheet_name='Sheet1')
```

pivot-tables.xlsx

	A	B	C	D	E	F
1	Order ID	Product	Category	Amount	Date	Country
2	1	Carrots	Vegetables	\$4'270	06-01-16	United States
3	2	Broccoli	Vegetables	\$8'239	07-01-16	United Kingdom
4	3	Banana	Fruit	\$617	08-01-16	United States
5	4	Banana	Fruit	\$8'384	10-01-16	Canada
6	5	Beans	Vegetables	\$2'626	10-01-16	Germany
7	6	Orange	Fruit	\$3'610	11-01-16	United States
8	7	Broccoli	Vegetables	\$9'062	11-01-16	Australia
9	8	Banana	Fruit	\$6'906	16-01-16	New Zealand
10	9	Apple	Fruit	\$2'417	16-01-16	France
11	10	Apple	Fruit	\$7'431	16-01-16	Canada
12	11	Banana	Fruit	\$8'250	16-01-16	Germany
13	12	Broccoli	Vegetables	\$7'012	18-01-16	United States
14	13	Carrots	Vegetables	\$1'903	20-01-16	Germany
15	14	Broccoli	Vegetables	\$2'824	22-01-16	Canada
16	15	Apple	Fruit	\$6'946	24-01-16	France
17	16	Banana	Fruit	\$2'320	27-01-16	United Kingdom
18	17	Banana	Fruit	\$2'116	28-01-16	United States
19	18	Banana	Fruit	\$1'135	30-01-16	United Kingdom
20	19	Broccoli	Vegetables	\$3'595	30-01-16	United Kingdom
21	20	Apple	Fruit	\$1'161	02-02-16	United States
22	21	Orange	Fruit	\$2'256	04-02-16	France
23	22	Banana	Fruit	\$1'004	11-02-16	New Zealand
24	23	Banana	Fruit	\$3'642	14-02-16	Canada

Vamos a leer un archivo excel
con los datos en la hoja "Sheet1"

```
import pandas as pd
```

```
df = pd.read_excel('pivot-tables.xlsx', sheet_name='Sheet1')
```

```
pt = pd.pivot_table(df, index='Product')  
print(pt)
```

con la opción **index** indicamos la (o las) columna (s) sobre la cual vamos a agrupar las filas.

	A	B	C	D	E	F
1	Order ID	Product	Category	Amount	Date	Country
2	1	Carrots	Vegetables	\$4'270	06-01-16	United States
3	2	Broccoli	Vegetables	\$8'239	07-01-16	United Kingdom
4	3	Banana	Fruit	\$617	08-01-16	United States
5	4	Banana	Fruit	\$8'384	10-01-16	Canada
6	5	Beans	Vegetables	\$2'626	10-01-16	Germany
7	6	Orange	Fruit	\$3'610	11-01-16	United States
8	7	Broccoli	Vegetables	\$9'062	11-01-16	Australia
9	8	Banana	Fruit	\$6'906	16-01-16	New Zealand
10	9	Apple	Fruit	\$2'417	16-01-16	France
11	10	Apple	Fruit	\$7'431	16-01-16	Canada
12	11	Banana	Fruit	\$8'250	16-01-16	Germany
13	12	Broccoli	Vegetables	\$7'012	18-01-16	United States
14	13	Carrots	Vegetables	\$1'903	20-01-16	Germany
15	14	Broccoli	Vegetables	\$2'824	22-01-16	Canada
16	15	Apple	Fruit	\$6'946	24-01-16	France
17	16	Banana	Fruit	\$2'320	27-01-16	United Kingdom
18	17	Banana	Fruit	\$2'116	28-01-16	United States
19	18	Banana	Fruit	\$1'135	30-01-16	United Kingdom
20	19	Broccoli	Vegetables	\$3'595	30-01-16	United Kingdom
21	20	Apple	Fruit	\$1'161	02-02-16	United States
22	21	Orange	Fruit	\$2'256	04-02-16	France
23	22	Banana	Fruit	\$1'004	11-02-16	New Zealand
24	23	Banana	Fruit	\$3'642	14-02-16	Canada

index

Product
Apple
Banana
Beans
Broccoli
Carrots
Mango
Orange

Amount

191257
340295
57281
142439
136945
57079
104438

Order ID

4306
7648
1381
2579
3174
918
2785

Como observamos, las filas quedan **agrupados** los productos, y las **columnas** son los resultados del pivote (en este caso son sumas por defecto)

```
import pandas as pd
df = pd.read_excel('pivot-tables.xlsx', sheet_name='Sheet1')

pt = pd.pivot_table(df, index='Product', values='Amount')
print(pt)
```

	A	B	C	D	E	F
1	Order ID	Product	Category	Amount	Date	Country
2	1	Carrots	Vegetables	\$4'270	06-01-16	United States
3	2	Broccoli	Vegetables	\$8'239	07-01-16	United Kingdom
4	3	Banana	Fruit	\$617	08-01-16	United States
5	4	Banana	Fruit	\$8'384	10-01-16	Canada
6	5	Beans	Vegetables	\$2'626	10-01-16	Germany
7	6	Orange	Fruit	\$3'610	11-01-16	United States
8	7	Broccoli	Vegetables	\$9'062	11-01-16	Australia
9	8	Banana	Fruit	\$6'906	16-01-16	New Zealand
10	9	Apple	Fruit	\$2'417	16-01-16	France
11	10	Apple	Fruit	\$7'431	16-01-16	Canada
12	11	Banana	Fruit	\$8'250	16-01-16	Germany
13	12	Broccoli	Vegetables	\$7'012	18-01-16	United States
14	13	Carrots	Vegetables	\$1'903	20-01-16	Germany
15	14	Broccoli	Vegetables	\$2'824	22-01-16	Canada
16	15	Apple	Fruit	\$6'946	24-01-16	France
17	16	Banana	Fruit	\$2'320	27-01-16	United Kingdom
18	17	Banana	Fruit	\$2'116	28-01-16	United States
19	18	Banana	Fruit	\$1'135	30-01-16	United Kingdom
20	19	Broccoli	Vegetables	\$3'595	30-01-16	United Kingdom
21	20	Apple	Fruit	\$1'161	02-02-16	United States
22	21	Orange	Fruit	\$2'256	04-02-16	France
23	22	Banana	Fruit	\$1'004	11-02-16	New Zealand
24	23	Banana	Fruit	\$3'642	14-02-16	Canada

index

Product

Apple
Banana
Beans
Broccoli
Carrots
Mango
Orange

Amount

191257
340295
57281
142439
136945
57079
104438

Los valores expresados en la columna son sumas (por defecto)

con la opción **values** indicamos la (o las) columna(s) que deseamos utilizar para el cálculo del pivote


```
import pandas as pd
df = pd.read_excel('pivot-tables.xlsx', sheet_name='Sheet1')

pt = pd.pivot_table(df, index='Product',
                    values='Amount',
                    aggfunc=['max', 'min', 'mean'])

print(pt)
```

Diagram illustrating the pivot table structure and the role of the `aggfunc` parameter:

- The `index` parameter points to the **Product** column.
- The `aggfunc` parameter points to the **max Amount**, **min Amount**, and **mean Amount** columns.

	max Amount	min Amount	mean Amount
Product			
Apple	8892	330	4781.425000
Banana	9543	107	4792.887324
Beans	8416	680	4406.230769
Broccoli	9630	277	5275.518519
Carrots	9127	339	5072.037037
Mango	9333	1641	5189.000000
Orange	9990	220	4351.583333

con la opción **aggfunc** indicamos la (o las) los calculos estadísticos sobre una determinada columna

```
import pandas as pd
df = pd.read_excel('pivot-tables.xlsx', sheet_name='Sheet1')

pt = pd.pivot_table(df, index='Country',
                    values='Amount',
                    columns='Product').round(2)

print(pt)
```

con la opción **columns** seleccionamos la columna sobre la cual vamos a mostrar los resultados

index →

Country	Apple	Banana	Beans	Broccoli	Carrots	Mango	Orange
Australia	5158.5	5272.1	4811.0	8976.5	2702.0	4593.0	2893.33
Canada	4144.5	4825.0		4135.67		3767.0	6643.0
France	5012.06	5156.29	680.0	5341.0	9104.0	7388.0	2256.0
Germany	4541.0	4409.56	4984.17	4649.62	3606.0	8775.0	8887.0
New Zealand	5166.0	5006.25		4390.0			4003.33
United Kingdom	4383.5	6129.71	2550.0	4804.5	5973.57	5600.0	4348.8
United States	4769.17	4133.09	7163.0	6678.75	5628.4	4472.6	3866.5



Utilice variables categóricas para las filas(index) y columnas

```
import pandas as pd
df = pd.read_excel('pivot-tables.xlsx', sheet_name='Sheet1')

pt = pd.pivot_table(df, index='Country',
                    values='Amount',
                    columns='Product',
                    fill_value=0).round(2)

print(pt)
```

con la opción **fill_value** definimos un determinado valor para aquellas celdas faltantes

		columns						celdas faltante
index	Country	Apple	Banana	Beans	Broccoli	Carrots	Mango	Orange
	Australia	5158.5	5272.1	4811.0	8976.5	2702.0	4593.0	2893.33
	Canada	4144.5	4825.0	0.0	4135.67	0.0	3767.0	6643.0
	France	5012.06	5156.29	680.0	5341.0	9104.0	7388.0	2256.0
	Germany	4541.0	4409.56	4984.17	4649.62	3606.0	8775.0	8887.0
	New Zealand	5166.0	5006.25	0.0	4390.0	0.0	0.0	4003.33
	United Kingdom	4383.5	6129.71	2550.0	4804.5	5973.57	5600.0	4348.8
	United States	4769.17	4133.09	7163.0	6678.75	5628.4	4472.6	3866.5

```
import pandas as pd
import matplotlib.pyplot as plt
df = pd.read_excel('pivot-tables.xlsx', sheet_name='Sheet1')


pt = pd.pivot_table(df, index='Country',
                    values='Amount',
                    columns='Product',
                    fill_value=0).round(2)
```

```
pt.plot.bar(figsize=(12,8))
```

```
plt.title('Promedio de productos por país')
plt.xticks(rotation=0)
plt.ylabel('Valor promedio')
plt.grid(alpha=0.2)
plt.legend(loc='upper left', bbox_to_anchor=(1, 1))
plt.show()
```

vamos a generar un gráfico de barras a partir de los datos de la tabla pivote

Opciones para los gráficos



es difícil visualizar este tipo de gráfico

index

Country	Apple	Banana	Beans	Broccoli	Carrots	Mango	Orange
Australia	5158.5	5272.1	4811.0	8976.5	2702.0	4593.0	2893.33
Canada	4144.5	4825.0	0.0	4135.67	0.0	3767.0	6643.0
France	5012.06	5156.29	680.0	5341.0	9104.0	7388.0	2256.0
Germany	4541.0	4409.56	4984.17	4649.62	3606.0	8775.0	8887.0
New Zealand	5166.0	5006.25	0.0	4390.0	0.0	0.0	4003.33
United Kingdom	4383.5	6129.71	2550.0	4804.5	5973.57	5600.0	4348.8
United States	4769.17	4133.09	7163.0	6678.75	5628.4	4472.6	3866.5

```
import pandas as pd
import matplotlib.pyplot as plt
df = pd.read_excel('data/pivot-tables.xlsx', sheet_name='Sheet1')


pt = pd.pivot_table(df, index='Country',
                    values='Amount',
                    columns='Product',
                    fill_value=0).round(2)
```

```
pt.plot.box(figsize=(12,8))
```

```
plt.title('Promedio de productos por país')
plt.xticks(rotation=0)
plt.ylabel('Valor promedio')
plt.grid(alpha=0.2)
plt.legend(loc='upper left', bbox_to_anchor=(1, 1))
plt.show()
```

vamos a generar un gráfico de dispersión tipo boxplot de la tabla pivote

Opciones para los gráficos



index	Country	Apple	Banana	Beans	Broccoli	Carrots	Mango	Orange
	Australia	5158.5	5272.1	4811.0	8976.5	2702.0	4593.0	2893.33
	Canada	4144.5	4825.0	0.0	4135.67	0.0	3767.0	6643.0
	France	5012.06	5156.29	680.0	5341.0	9104.0	7388.0	2256.0
	Germany	4541.0	4409.56	4984.17	4649.62	3606.0	8775.0	8887.0
	New Zealand	5166.0	5006.25	0.0	4390.0	0.0	0.0	4003.33
	United Kingdom	4383.5	6129.71	2550.0	4804.5	5973.57	5600.0	4348.8
	United States	4769.17	4133.09	7163.0	6678.75	5628.4	4472.6	3866.5



```
import pandas as pd
import matplotlib.pyplot as plt
df = pd.read_excel('data/pivot-tables.xlsx', sheet_name='Sheet1')
```

```
pt = pd.pivot_table(df, index='Country',
                    values='Amount',
                    columns='Product',
                    fill_value=0,
                    margins=True).round(2)
```

Agrega una columna
y fila adicional con
los totales

```
pt.plot.bar(figsize=(12,8))
plt.title('Promedio de productos por país')
plt.xticks(rotation=0)
plt.ylabel('Valor promedio')
plt.grid(alpha=0.2)
plt.legend(loc='upper left', bbox_to_anchor=(1, 1))
plt.show()
```

Opciones para los
gráficos



index

Country	Apple	Banana	Beans	Broccoli	Carrots	Mango	Orange	All
Australia	5158.5	5272.1	4811.0	8976.5	2702.0	4593.0	2893.33	4878.26
Canada	4144.5	4825.0	0.0	4135.67	0.0	3767.0	6643.0	4737.25
France	5012.06	5156.29	680.0	5341.0	9104.0	7388.0	2256.0	5037.71
Germany	4541.0	4409.56	4984.17	4649.62	3606.0	8775.0	8887.0	4702.06
New Zealand	5166.0	5006.25	0.0	4390.0	0.0	0.0	4003.33	4770.14
United Kingdom	4383.5	6129.71	2550.0	4804.5	5973.57	5600.0	4348.8	5092.26
United States	4769.17	4133.09	7163.0	6678.75	5628.4	4472.6	3866.5	4686.54
All	4781.42	4792.89	4406.23	5275.52	5072.04	5189.0	4351.58	4834.43

- ▶ Introducción a Pandas
 - Operaciones básicas de datos
 - Agrupaciones de datos
 - Pivot table
 - CrossTab



```
self.FidValue = OrderedDict(sorted(self.FidValue.items(), key=lambda item: item[0]))  
#Read item in dictionary  
for key, value in item.FidValue.items():  
    typeOfFID = mapFidType[key]  
    if (typeOfFID == "DATE"):  
        d = datetime.datetime.strptime(str(value), "%Y-%m-%d")  
        dataCal = datetime.date.strptime(str(value), "%Y-%m-%d")  
        FidAndValue = FidAndValue + value  
    else: FidAndValue = FidAndValue + value
```

```
try:  
    start = date(int(self.start_year.get()),  
                self.months.index(self.start_month.get()),  
                int(self.start_day.get()))  
  
    end = date(int(self.end_year.get()),  
              self.months.index(self.end_month.get()),  
              int(self.end_day.get()))
```



En algunas ocasiones deseamos realizar una tabla cruzada. Una tabla cruzada muestra la relación entre dos variables (factores). Cada casilla representa la frecuencia de aparición entre las dos variables

Data

	A	B	C	D	E	F
1	Order ID	Product	Category	Amount	Date	Country
2	1	Carrots	Vegetables	\$4'270	06-01-16	United States
3	2	Broccoli	Vegetables	\$8'239	07-01-16	United Kingdom
4	3	Banana	Fruit	\$617	08-01-16	United States
5	4	Banana	Fruit	\$8'384	10-01-16	Canada
6	5	Beans	Vegetables	\$2'626	10-01-16	Germany
7	6	Orange	Fruit	\$3'610	11-01-16	United States
8	7	Broccoli	Vegetables	\$9'062	11-01-16	Australia
9	8	Banana	Fruit	\$6'906	16-01-16	New Zealand
10	9	Apple	Fruit	\$2'417	16-01-16	France
11	10	Apple	Fruit	\$7'431	16-01-16	Canada
12	11	Banana	Fruit	\$8'250	16-01-16	Germany
13	12	Broccoli	Vegetables	\$7'012	18-01-16	United States
14	13	Carrots	Vegetables	\$1'903	20-01-16	Germany
15	14	Broccoli	Vegetables	\$2'824	22-01-16	Canada
16	15	Apple	Fruit	\$6'946	24-01-16	France
17	16	Banana	Fruit	\$2'320	27-01-16	United Kingdom
18	17	Banana	Fruit	\$2'116	28-01-16	United States
19	18	Banana	Fruit	\$1'135	30-01-16	United Kingdom
20	19	Broccoli	Vegetables	\$3'595	30-01-16	United Kingdom
21	20	Apple	Fruit	\$1'161	02-02-16	United States
22	21	Orange	Fruit	\$2'256	04-02-16	France
23	22	Banana	Fruit	\$1'004	11-02-16	New Zealand
24	23	Banana	Fruit	\$3'642	14-02-16	Canada

Preguntas

- ¿Cuántos productos por país han sido vendidos?
- ¿Cuantos productos en total han sido vendidos en United States?
- ¿Cuántas manzanas han sido vendidas en Alemania?

```
import pandas as pd
df = pd.read_excel('data/pivot-tables.xlsx', sheet_name='Sheet1')
```

pivot-tables.xlsx

	A	B	C	D	E	F
1	Order ID	Product	Category	Amount	Date	Country
2	1	Carrots	Vegetables	\$4'270	06-01-16	United States
3	2	Broccoli	Vegetables	\$8'239	07-01-16	United Kingdom
4	3	Banana	Fruit	\$617	08-01-16	United States
5	4	Banana	Fruit	\$8'384	10-01-16	Canada
6	5	Beans	Vegetables	\$2'626	10-01-16	Germany
7	6	Orange	Fruit	\$3'610	11-01-16	United States
8	7	Broccoli	Vegetables	\$9'062	11-01-16	Australia
9	8	Banana	Fruit	\$6'906	16-01-16	New Zealand
10	9	Apple	Fruit	\$2'417	16-01-16	France
11	10	Apple	Fruit	\$7'431	16-01-16	Canada
12	11	Banana	Fruit	\$8'250	16-01-16	Germany
13	12	Broccoli	Vegetables	\$7'012	18-01-16	United States
14	13	Carrots	Vegetables	\$1'903	20-01-16	Germany
15	14	Broccoli	Vegetables	\$2'824	22-01-16	Canada
16	15	Apple	Fruit	\$6'946	24-01-16	France
17	16	Banana	Fruit	\$2'320	27-01-16	United Kingdom
18	17	Banana	Fruit	\$2'116	28-01-16	United States
19	18	Banana	Fruit	\$1'135	30-01-16	United Kingdom
20	19	Broccoli	Vegetables	\$3'595	30-01-16	United Kingdom
21	20	Apple	Fruit	\$1'161	02-02-16	United States
22	21	Orange	Fruit	\$2'256	04-02-16	France
23	22	Banana	Fruit	\$1'004	11-02-16	New Zealand
24	23	Banana	Fruit	\$3'642	14-02-16	Canada

Vamos a leer un archivo excel
con los datos en la hoja "Sheet1"

```
import pandas as pd
df = pd.read_excel('data/pivot-tables.xlsx', sheet_name='Sheet1')

pt = pd.crosstab(df['Country'], df['Product'])

print(pt)
```

Variable 1 Variable

		Product						
Country	Country	Apple	Banana	Beans	Broccoli	Carrots	Mango	Orange
	Australia	4	10	3	2	3	2	3
	Canada	6	7	0	3	0	1	3
	France	16	7	1	1	1	1	1
	Germany	2	9	6	8	6	1	1
	New Zealand	2	8	0	1	0	0	3
	United Kingdom	4	7	2	8	7	1	5
	United States	6	23	1	4	10	5	8

```
import pandas as pd
df = pd.read_excel('data/pivot-tables.xlsx', sheet_name='Sheet1')

pt = pd.crosstab(df['Country'], df['Product'], margins=True)

print(pt)
```

Agrega una columna
y fila adicional con
los totales

		Product							
Country	Country	Apple	Banana	Beans	Broccoli	Carrots	Mango	Orange	All
	Australia	4	10	3	2	3	2	3	27
	Canada	6	7	0	3	0	1	3	20
	France	16	7	1	1	1	1	1	28
	Germany	2	9	6	8	6	1	1	33
	New Zealand	2	8	0	1	0	0	3	14
	United Kingdom	4	7	2	8	7	1	5	34
	United States	6	23	1	4	10	5	8	57
	All	40	71	13	27	27	11	24	213



Tiempo : 5 minutos

Determine el porcentaje de Bananas vendido por cada país según la tabla crosstab. Utilice como base el siguiente código

```
import pandas as pd
df = pd.read_excel('pivot-tables.xlsx', sheet_name='Sheet1')
pt = pd.crosstab(df['Country'], df['Product'], margins=True)
```