




PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE



IA Lab


Algoritmos de Optimización y Learning Rate

Francisca Cattan
fpcattan@uc.cl


Diplomado Inteligencia Artificial
Pontificia Universidad Católica de Chile

12 de Mayo 2022


Motivación



Motivación



Motivación




Objetivos de Machine Learning

- Tenemos un modelo
- Cómo adaptamos los pesos del modelo para que se adapten a los datos que tenemos?
 - ¿Cuál es el objetivo del entrenamiento?
 - ¿Cómo realizamos el entrenamiento?
 - ¿Cómo sabemos en qué dirección debemos mover los pesos?
 - ¿Cómo sabemos cuando parar nuestro entrenamiento?
- No existe una forma directa de obtener los parametros optimos para la tarea

Optimización

- El objetivo de un algoritmo de optimización es modificar los pesos del modelo, para minimizar la función de pérdida
- Estos algoritmos son iterativos
 - Dan pasos que lo acercan a un óptimo en cada iteración



Agenda

- Algoritmo Gradiente Descendente
 - ¿Qué es el gradiente?
 - ¿Pasos pequeños o pasos más grandes?
- Algoritmo SGD
 - Momentum
 - Nesterov
 - Learning Rate
- Alternativas a SGD
 - AdaGrad
 - Adam
- Adaptar el Learning Rate durante el entrenamiento
 - Scheduler
 - Early Stopping

Optimización


- Tenemos una función que queremos optimizar

$$L(W) = \mathcal{L}(f(x), y; W) + \alpha\Omega(W)$$

- La derivada nos entrega la pendiente de una función
- El gradiente nos indica la dirección en la cual tenemos que mover los pesos para acercarnos a un óptimo

$$w_i^{new} = w_i^{old} - \eta \frac{\partial L}{\partial w_i}$$

Optimización




Gradiente Descendente

- Encontramos el valor de la función de pérdida
 - Considerando todos los elementos de nuestro set de entrenamiento


$$L(W) = \sum_n \mathcal{L}(f(x_n), y_n; W) + \alpha \Omega(W)$$

$$w_i^{new} = w_i^{old} - \eta \frac{\partial L}{\partial w_i}$$



SGD

- Si el dataset que tenemos es muy grande, GD puede ser muy lento
 - Por cada iteración debemos pasar por todo el dataset
 - Hacemos muchos cálculos por cada iteración
- Stochastic Gradient Descent crea subconjuntos de datos
 - Cada subconjunto lo llamaremos batch




SGD

- SGD nos permite acelerar el proceso de convergencia
 - Actualizamos más veces en menos tiempo

$$L(W) = \sum_n \mathcal{L}(f(x_n), y_n; W) + \alpha \Omega(W)$$
$$w_i^{new} = w_i^{old} - \eta \frac{\partial L}{\partial w_i}$$

SGD




SGD - Problemas

Saddle Points


Batches con
diferentes objetivos

Tamaño de los
pasos

SGD



SGD



SGD - Momentum

- Momentum agrega la idea de mantener la dirección del gradiente
 - Agregamos historia de cómo se ha movido el gradiente en el pasado.

$$v_{t+1} = \rho v_t + \nabla f(x_t)$$

$$w_{t+1} = w_t - \eta v_{t+1}$$

- Suavizamos el valor del gradiente con los valores pasados
 - Similar al momentum físico
 - Se acumula velocidad en dirección consistente

SGD - Momentum

Ejemplo de una sola dimensión

$$v_{t+1} = \rho v_t + \nabla f(x_t)$$


$$w_{t+1} = w_t - \eta v_{t+1}$$

$$\rho = 0.1$$

Batch	Gradiente	v_{t+1}
Batch 1	-2	-2
Batch 2	-4	-4.2
Batch 3	-3	-3.42
Batch 4	2	1.658

SGD - Momentum

- Una solución al problema de que los gradientes dependen de solo un batch
 - Distintos grupos de datos puede tener diferentes gradientes



SGD - Nesterov

- Una forma alternativa de ver el momentum es utilizando Nesterov Accelerated Gradient (NAG)
 - Buscamos hacer la corrección del momentum antes de encontrar el gradiente
 - Seguimos la dirección dado el momentum que tenemos

$$w_t = w_t - \rho v_t$$
$$v_{t+1} = \rho v_t - \alpha \frac{\partial L(x)}{\partial w_t}$$
$$w_{t+1} = w_t + v_{t+1}$$

SGD - Nesterov

- Es una vision a futuro, donde la velocidad (momentum) nos va a llevar

$$\rho v_t$$

- Agregamos una tasa de corrección, que es el gradiente


$$\alpha \frac{\partial L(x)}{\partial w_t}$$

- Luego nos movemos con la suma


$$w_{t+1} = w_t + v_{t+1}$$

SGD - Nesterov

Momentum




Nesterov



Learning Rate

- Que tan grande debe ser el paso que damos?
 - Pasos grandes o pasos pequeños?


$$w_i^{new} = w_i^{old} - \eta \frac{\partial L}{\partial w_i}$$




Learning Rate

- Que tan grande debe ser el paso que damos?
 - Pasos grandes o pasos pequeños?


$$w_i^{new} = w_i^{old} - \eta \frac{\partial L}{\partial w_i}$$



Learning Rate



Alternativas a SGD



Adaptive Gradient (AdaGrad)

- Cada peso tiene su propio learning rate, que se comporta diferente en el tiempo
 - Dependiendo del batch
- La idea de AdaGrad es ir actualizando el learning rate de cada peso del modelo según su historia

$$w_t^i = w_{t-1}^i - \eta_{w^i} \frac{\partial L(x)}{\partial w^i}$$

$$\eta_{w^i} = \frac{\eta}{\sqrt{\sum_i^t (G_i)^2}}$$

Adaptive Gradient (AdaGrad)

- Es una especie de normalización de los gradientes
 - Gradientes muy pronunciados son reducidos
 - Gradientes muy bajos son acelerados
- ¿Qué pasa con el valor del learning rate en el tiempo?
 - Tiende a cero
- El problema es que tiende a reducir muy rápidamente el learning rate

Adaptive moments (Adam)

- Se utiliza la idea de estimadores de momento
 - Primer y segundo orden
- El n-esimo momento de m:

$$m_n = E(x^n)$$

- Donde el primer momento es la media y el segundo la varianza

$$r_t = (1 - \gamma_1)G_i^t + \gamma_1 r_{t-1}$$

$$v_t = (1 - \gamma_2)(G_i^t)^2 + \gamma_2 v_{t-1}$$

Adaptive moments (Adam)

- Se realiza una corrección a ambos momentos, para arreglar que ambos estimadores parten de cero


$$r_t = \frac{(1 - \gamma_1)G_i^t + \gamma_1 r_{t-1}}{1 - \gamma_1^t}$$

$$v_t = \frac{(1 - \gamma_2)(G_i^t)^2 + \gamma_2 v_{t-1}}{1 - \gamma_2^t}$$

$$w_i^t = w_i^{t-1} - \eta \frac{r_t}{\sqrt{v_t} + \epsilon}$$

Adaptive moments (Adam)

- Es una combinación entre SGD con momentum y AdaGrad (escalamiento)


$$w_i^t = w_i^{t-1} - \eta \frac{r_t}{\sqrt{v_t} + \epsilon}$$


The diagram shows the Adam update rule with two red circles highlighting specific parts. The first circle is around the term r_t , with an arrow pointing to the label "Momentum". The second circle is around the denominator $\sqrt{v_t} + \epsilon$, with an arrow pointing to the label "Escalamiento del momentum".

Adaptar el Learning Rate


- Cómo podemos definir el learning rate que necesitamos?
 - Quizás necesitamos diferentes valores en diferentes etapas del entrenamiento
- Decaimiento del learning rate
 - En base a la cantidad de épocas
 - En base al valor de la función de pérdida del set de validación

Adaptar el Learning Rate



Adaptar el Learning Rate


- Entrenamiento de una ResNet, multiplicando por 0.1 el Learning Rate cada 30 épocas



Adaptar el Learning Rate

- En base al número de épocas
 - Cada cierta cantidad de épocas, reducir el valor del learning rate por un factor
- Utilizando el conjunto de validación
 - Verificar si el valor de la función de pérdida no baja en n épocas, reducir el valor del learning rate
- Otras opciones que pueden depender del problema


Adaptar el Learning Rate



Adaptar el Learning Rate

- Early Stopping

- Si durante el entrenamiento vemos que el conjunto de validación está empeorando, podemos detener el entrenamiento




Preguntas





PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE



IA Lab

Algoritmos de Optimización y Learning Rate

Francisca Cattan
fpcattan@uc.cl

Diplomado Inteligencia Artificial
Pontificia Universidad Católica de Chile

Socrative

- Vamos a hacer un pequeño Quiz
- Ingresen a:
 - <https://b.socrative.com/login/student/>
 - Room Name: DIPLOMADOIA