

Performance Intelligence Copilot

Sistema híbrido y explicable para apoyar decisiones en pruebas de rendimiento



POC funcional · Motor experto + Machine Learning

Versión 1.6.0 · Agosto 2026

Grupo 8

Luis Araya · Rodrigo González · Hernán Medina

Profesor guía: Ahmad Armoush · Agosto 2026

01 · CONTEXTO Y EVOLUCIÓN DEL PROYECTO

Del negocio bancario a una decisión de rendimiento explicable

NEGOCIO BANCARIO

Personas y empresas

Acceden a productos y servicios financieros a través de canales que deben responder de forma continua y estable.

WEB

Canales digitales

APP

Operaciones

API

Servicios integrados

CAPACIDAD HABILITANTE

Pruebas de rendimiento

Permiten medir tiempos de respuesta, errores y capacidad antes de liberar cambios.

CAMBIO DE ENFOQUE

PRIMERA PRESENTACIÓN

Predicción de capacidad e infraestructura cloud

El planteamiento era más amplio que los datos y capacidades demostrables del proyecto.



PROYECTO REAL

Copilot para analizar pruebas Gatling

Integra configuración, resultados e historial para entregar una recomendación explicable.

EVIDENCIA REAL

Configuración → métricas → análisis → recomendación → validación humana

Así llegamos al problema: la prueba puede ejecutarse, pero preparar la evidencia, interpretarla y acordar la siguiente acción sigue requiriendo tiempo y criterio especializado.

El cuello de botella no es ejecutar la prueba: es preparar, interpretar y aprobar

3-48 h

desarrollo de la prueba según complejidad

Una **prueba de rendimiento** somete un sistema a carga controlada para medir tiempos de respuesta, errores y capacidad antes de liberar un cambio.

Línea base por medir

preparación analítica e interpretación de resultados

1-35 h

revisión y aprobación QA

12/mes

6 tareas por sprint

7.003

atenciones anuales del servicio

\$1.569 MM

costo anual informado

≈ \$224 mil

costo promedio ponderado por atención

Impacto para el proyecto: reducir el tiempo dedicado a consolidar evidencia y entregar una recomendación técnica trazable antes de aprobar la siguiente prueba.

Acelerar la decisión técnica: de horas a minutos

Automatizar el análisis de configuraciones, resultados e historial para generar en minutos una recomendación explicable sobre la siguiente prueba de estrés.

01 Entrada
YAML, JSON e historial

02 Entregable
recomendación + explicación

03 KPI técnico
Macro-F1 y balanced accuracy

04 KPI operativo
Preparación analítica y recomendación: línea base por medir → meta en minutos

ALCANCE POC

Termina en Maintain · Review · Evolve. No modifica ni ejecuta pruebas sin validación humana.

04 · METODOLOGÍA Y ARQUITECTURA

Un flujo híbrido desde la evidencia hasta la recomendación



La POC termina hoy en una recomendación y artefactos trazables. API e interfaz se muestran como evolución, no como capacidades ya implementadas.

6.444 ejecuciones permiten evaluar el problema con un holdout independiente

INPUT REAL

6.444

ejecuciones utilizables de 6.445 filas
Fuente: resultadoPruebasGatling.txt

VARIABLE OBJETIVO · APLICABILIDAD DE LA CONFIGURACIÓN

not_applies  **3.781 · 58,7 %**

applies  **2.663 · 41,3 %**

El desbalance es moderado; se priorizan F1 y recall de not_applies, no solo accuracy.

ENTRENAMIENTO

5.114

408 Build_Id

HOLDOUT

1.330

136 Build_Id

FUGA ENTRE GRUPOS

0

Build_Id compartidos

Relaciones observadas

RPS mediana: 0,18 not_applies frente a 0,63 applies

24,0 % de not_applies registra errores; applies 0 %

p95 mediana: 1.334 ms frente a 1.231 ms

El pipeline evita fugas y convierte resultados Gatling en evidencia auditable

Etapa ETL			Tratamiento aplicado	Resultado
Ingesta			Lectura del TXT de ancho fijo y normalización de nombres, tipos y categorías	6.444 registros utilizables
Control de calidad			Se descartan campos vacíos o no numéricos y filas sin etiqueta reproducible	apdex y rating fuera del modelo
Prevención de fuga			Variables posteriores que revelan directamente la etiqueta no ingresan como predictoras	features disponibles antes de decidir
Partición y trazabilidad			Holdout agrupado por Build_Id; modelo, reglas, métricas y recomendaciones se exportan	0 grupos compartidos

Flujo auditable

TXT real → ETL validado → split por Build_Id → artefactos

Variables operacionales

Concurrency

Iterations

ResponseTime

carga

volumen

objetivo

Resultado: las entradas, transformaciones y decisiones quedan reproducibles; una métrica inválida no se convierte silenciosamente en señal predictiva.

Random Forest logra el mejor equilibrio para detectar configuraciones que no aplican

Solución	Accuracy test	F1 not_applies	Recall not_applies
Baseline mayoritario	0,5677	0,7242*	1,0000*
Árbol de decisión	0,6579	0,6486	0,5563
Regresión logística	0,6895	0,7165	0,6914
Random Forest	0,7256	0,7446	0,7046

MODELO SELECCIONADO

Random Forest

Maximiza F1 de not_applies entre los modelos entrenados; recall desempata.


+3,6 pp

accuracy frente a regresión logística

Decisión: Random Forest ofrece el mejor compromiso global sin ocultar la clase operativamente riesgosa.

La brecha train-test exige control: el desempeño es útil, pero no perfecto

RANDOM FOREST · TRAIN VS TEST



LECTURA

Brecha de ≈ 11 puntos

Existe sobreajuste moderado; por eso se agregó validación cruzada agrupada por Build_Id.

5-fold agrupado

F1 medio 0,8049 · rango 0,7682-0,8363


Límite

Etiquetas derivadas de evidencia, aún sin validación experta independiente

Conclusión: el modelo es apto para apoyar una revisión humana, no para cambiar configuraciones de forma autónoma.

09 · PIPELINE DE DECISIÓN POR CAPAS

El modelo recomienda; Gatling y el especialista validan el cambio

**0 cambios automáticos ante review**

Downgrade queda como decisión humana posterior al diagnóstico.

100 % de upgrades requieren aprobación

Valor: el modelo no entrega solo una clase; la traduce en una acción, una configuración candidata y un contrato de validación.

Ante la duda, revisar cuesta menos que aprobar una configuración incorrecta

Real \ Predicho	not_applies	applies
not_applies	665 · revisión correcta	90 · riesgo de aprobación
applies	230 · revisión adicional	345 · aprobación correcta

COSTO ASIMÉTRICO

**Falso “applies” > falso
“not_applies”**

Aprobar una configuración que no aplica puede ocultar una falla real.
Enviar un caso válido a review agrega tiempo, pero conserva el control.

Política

incertidumbre, falla o evidencia insuficiente → **review**

Cut-off seleccionado: 0,35

Recall 0,8808 · F1 0,8061 · 90 falsos applies. Costos supuestos: falso applies 10, falso not_applies 2 y review 1.

Recomendación: minimiza 2.255 unidades de costo esperado; los costos monetarios reales se recalibrarán con el piloto.

11 · RECOMENDACIÓN ÓPTIMA Y EVALUACIÓN ECONÓMICA

El cut-off operativo protege la decisión y habilita un beneficio medible

SITUACIÓN ACTUAL

3-48 h + 1-35 h

Desarrollo y revisión QA; la preparación analítica aún debe medirse por separado.



RECOMENDACIÓN ÓPTIMA

Cut-off 0,35

Reduce falsos applies de 221 a 90, a cambio de más revisiones humanas controladas.

BASE HISTÓRICA

\$1.569 MM ÷ 7.003

≈ \$224 mil por atención

ALCANCE INICIAL

144 atenciones/año

12 atenciones mensuales × 12 meses · ≈ \$32,3 MM

ESCENARIO PRELIMINAR

50 % cobertura × 75 % reducción

Supuestos de adopción y eficiencia · ≈ \$12,1 MM potencial/año

Evaluación económica: ≈ \$12,1 MM es beneficio bruto potencial, no ahorro demostrado. El piloto debe medir tiempo antes/después, cobertura real, reejecuciones y costo de falsos "applies".

La recomendación solo se aprueba después de una nueva ejecución Gatling

CONTRATO DE VALIDACIÓN ONLINE

- 1 Aprobar propuesta upgrade
- 2 Ejecutar nueva prueba Gatling
- 3 Comparar errores, p95, RPS, éxitos y Estado
- 4 Aprobar cuadrante o retornar a review

ESTADO ACTUAL

pending_new_execution

La configuración candidata todavía es una recomendación, no evidencia experimental.

ÉXITO

0 errores + estado exitoso + sin regresión

Estado de validación

Offline + 5-fold agrupado: completado

Métricas por pilar/componente: completadas

Etiquetas expertas: pendientes

Muestra upgrade en Gatling: pendiente

Principio: si la nueva ejecución falla o es irregular, la propuesta vuelve a review; nunca hay downgrade automático.

13 · CONCLUSIONES

La POC cumple el objetivo y deja una ruta verificable hacia producción

OBJETIVO CUMPLIDO

La POC transforma **6.444 resultados Gatling** en una recomendación explicable, parámetros candidatos y un proceso de validación controlado.

Entregables verificados

- Comparación de 3 modelos + baseline
- Pipeline de decisión en cuatro capas
- Cuadrante y parámetros recomendados
- Cut-off optimizado y 5-fold agrupado
- Validación Gatling pendiente y auditable

El valor económico y la configuración óptima se confirmarán en el piloto, no antes.