

Performance Intelligence Copilot

Sistema híbrido y explicable para apoyar decisiones en pruebas de rendimiento



POC funcional · Motor experto + Machine Learning

Versión 1.4.6 · Agosto 2026

Grupo 8

Luis Araya · Rodrigo González · Hernán Medina

Profesor guía: Ahmad Armoush · Agosto 2026

01 · CONTEXTO Y EVOLUCIÓN DEL PROYECTO

Del negocio bancario a una decisión de rendimiento explicable

NEGOCIO BANCARIO

Personas y empresas

Acceden a productos y servicios financieros a través de canales que deben responder de forma continua y estable.

WEB

Canales digitales

APP

Operaciones

API

Servicios integrados

CAPACIDAD HABILITANTE

Pruebas de rendimiento

Permiten medir tiempos de respuesta, errores y capacidad antes de liberar cambios.

CAMBIO DE ENFOQUE

PRIMERA PRESENTACIÓN

Predicción de capacidad e infraestructura cloud

El planteamiento era más amplio que los datos y capacidades demostrables del proyecto.



PROYECTO REAL

Copilot para analizar pruebas Gatling

Integra configuración, resultados e historial para entregar una recomendación explicable.

EVIDENCIA REAL

Configuración → métricas → análisis → recomendación → validación humana

Así llegamos al problema: la prueba puede ejecutarse, pero preparar la evidencia, interpretarla y acordar la siguiente acción sigue requiriendo tiempo y criterio especializado.

El cuello de botella no es ejecutar la prueba: es preparar, interpretar y aprobar

3-48 h

desarrollo de la prueba según complejidad

Una **prueba de rendimiento** somete un sistema a carga controlada para medir tiempos de respuesta, errores y capacidad antes de liberar un cambio.

Línea base por medir

preparación analítica e interpretación de resultados

1-35 h

revisión y aprobación QA

12/mes

6 tareas por sprint

7.003

atenciones anuales del servicio

\$1.569 MM

costo anual informado

≈ \$224 mil

costo promedio ponderado por atención

Impacto para el proyecto: reducir el tiempo dedicado a consolidar evidencia y entregar una recomendación técnica trazable antes de aprobar la siguiente prueba.

Acelerar la decisión técnica: de horas a minutos

Automatizar el análisis de configuraciones, resultados e historial para generar en minutos una recomendación explicable sobre la siguiente prueba de estrés.

01 Entrada
YAML, JSON e historial

02 Entregable
recomendación + explicación

03 KPI técnico
Macro-F1 y balanced accuracy

04 KPI operativo
Preparación analítica y recomendación: línea base por medir → meta en minutos

ALCANCE POC

Termina en Maintain · Review · Evolve. No modifica ni ejecuta pruebas sin validación humana.


04 · METODOLOGÍA Y ARQUITECTURA

Un flujo híbrido desde la evidencia hasta la recomendación



La POC termina hoy en una recomendación y artefactos trazables. API e interfaz se muestran como evolución, no como capacidades ya implementadas.

Composición y calidad del dataset disponible



59

detectadas → 29 completas → 28

finales · 20 maintain / 8 review

VARIABLE	DESCRIPCIÓN OPERACIONAL	ROL
error_rate_percent	Porcentaje de solicitudes fallidas	Predictora
p95_response_time_ms	Tiempo bajo el cual finaliza el 95 % de las solicitudes	Predictora
sla_margin_ms	Diferencia entre p95 observado y SLA; positivo = incumplimiento	Derivada
assertions_failed	Cantidad de criterios técnicos incumplidos	Predictora
warning_count	Advertencias generadas durante el análisis	Posible proxy
recommendation_action	Decisión maintain o review generada por H6	Objetivo

COMPOSICIÓN FINAL

20 maintain frente a 8 review

La muestra final contiene 28 casos y presenta desbalance entre las dos clases disponibles.

ALCANCE DEL ANÁLISIS

Evidencia exploratoria

El desbalance 71,4 % / 28,6 % justificó usar Macro-F1 y balanced accuracy.

Universo evaluado: carga/concurrencia, TPS, volumen de solicitudes e historial comparable también se probaron como predictoras, pero no aportaron señal al árbol (importancia 0,00). El diccionario destaca las variables con importancia o relevancia metodológica.

ETL e ingeniería de atributos para construir variables auditables

Etapas de ETL		
Etapas ETL	Tratamiento aplicado	Resultado
Ingesta	59 carpetas de ejecución detectadas; se exigieron configuración, parámetros y resultados Gatling legibles	29 ejecuciones completas formaron el dataset inicial de 29 × 27
Validación de filas	Cada fila debía representar una ejecución terminada, cumplir el esquema, tener tipos válidos y una recomendación reproducible	1 ejecución abortada excluida; quedaron 28 registros validados y 0 duplicados
Nulos y atípicos	1 columna excluida: p90_response_time_ms, con 28 de 28 valores nulos; las demás variables utilizadas quedaron sin nulos	0 % de filas eliminado por outliers: los extremos se conservaron como posibles señales de degradación
Ingeniería de atributos	Se crean: cumplimiento de SLA, assertions fallidas, margen respecto del SLA e historial comparable	Predictoras derivadas con sentido técnico y de negocio

Embudo

59 detectadas → 29 completas → 28 válidas

Nulos por columna

p90_response_time_ms

Variables utilizadas

28/280/28

Validación final: 59 detectadas → 29 completas → 28 válidas. Los nulos de p90 eliminaron una columna, no registros; los outliers se conservaron como evidencia técnica.

Panorama de señales evaluadas y límites de la muestra

MAPA DE VARIABLES CANDIDATAS

Carga aplicada

Concurrencia · TPS · volumen de solicitudes

Contexto de ejecución

Respuesta del sistema

Tasa de error · p95 · margen respecto del SLA

Desempeño observado

Criterios derivados

Assertions fallidas · warning_count

Posible dependencia de H6

Memoria histórica

Historial comparable y comportamiento previo

Contexto temporal

Todas se evaluaron como predictoras. En esta muestra, carga, TPS, volumen e historial no agregaron separación al árbol entrenado; esto no permite concluir que sean irrelevantes en otros datos.

COMPOSICIÓN DE LA MUESTRA

20  maintain · 71,4 %

8  review · 28,6 %

El desbalance justifica Macro-F1 y balanced accuracy; no autoriza extrapolar el patrón a nuevos servicios.

HALLAZGO DE ESTA MUESTRA

Las etiquetas coinciden con criterios derivados del mismo motor que las generó.

assertions_failed fue la señal utilizada por este árbol y warning_count puede actuar como proxy. Se reporta como dependencia potencial, no como variable universalmente decisiva.

Próxima validación: excluir conjuntamente variables de assertions y warnings, y separar entrenamiento/prueba por microservicio.

Qué aporta hoy el árbol y qué deberá aprender después

Evidencia	Qué permite afirmar	Qué no permite afirmar
Baseline mayoritario	Referencia mínima frente al desbalance de clases	No evalúa señales
10 holdouts estratificados	Estabilidad interna en particiones de 21 train / 7 test	No reemplaza datos externos
Árbol de decisión	Reproduce las etiquetas históricas de H6 en la muestra disponible	No prueba generalización

Alcance: el experimento confirma reproducibilidad interna y revela dependencia de la fuente de etiquetas. El valor futuro del ML debe probarse con señales independientes y casos que las reglas actuales no resuelvan por sí solas.

APORTE DEL MACHINE LEARNING · CONVERGENCIA CON H6, NO SUSTITUCIÓN

HOY · POC

Auditar la relación entre señales y decisiones históricas

El árbol hace explícitas dependencias y posibles fugas de información.

CON MÁS HISTÓRICO

Detectar combinaciones que las reglas actuales no capturan

Requiere etiquetas expertas independientes, más servicios y validación temporal.

El árbol reproduce H6, pero aún no demuestra generalización

CONCLUSIÓN DEL EXPERIMENTO

La evaluación mide fidelidad a H6 dentro de una muestra pequeña

El desempeño observado es consistente en las particiones evaluadas, pero las etiquetas y algunas variables comparten la misma fuente de verdad.

DATOS EVALUADOS

28 ejecuciones

20 maintain · 8 review

RESULTADO OBSERVADO

Macro-F1 1,0000

DE 0,0000 · solo en esta muestra

PROTOCOLO

10 semillas

holdout estratificado · 21/7

BASELINE MAYORITARIO

0,4167

Macro-F1 · siempre predice maintain

SÍ DEMUESTRA

Fidelidad interna

Reproduce de forma estable las decisiones históricas generadas por H6.

NO DEMUESTRA TODAVÍA

Generalización

No hay etiquetas expertas independientes, servicios externos ni ablación libre de proxies.

Próximo experimento decisivo: ablación conjunta de assertions y warnings, partición agrupada por microservicio y etiquetas expertas independientes. Solo entonces podrá evaluarse si el modelo aporta generalización adicional a las reglas.

La falla actual prevalece sobre un buen historial



Una validación fallida activa la **revisión de configuración**. La estabilidad histórica nunca puede elevar la carga cuando la ejecución actual presenta incumplimientos.

11 · IMPACTO OPERACIONAL ESPERADO

Impacto operacional y evaluación económica preliminar

ESCENARIO A · ACTUAL

3-48 h + 1-35 h

Desarrollo de la prueba y posterior revisión QA. El tiempo específico de preparación analítica se medirá en el piloto.



ESCENARIO B · CON COPILOT

Minutos + validación humana

La preparación analítica y la recomendación se automatizan; QA recibe evidencia explicable para revisar y aprobar con mayor rapidez.

BASE HISTÓRICA

\$1.569 MM ÷ 7.003

≈ \$224 mil por atención

ALCANCE INICIAL

144 atenciones/año

12 atenciones mensuales × 12 meses · ≈ \$32,3 MM


ESCENARIO PRELIMINAR

50 % cobertura × 75 % reducción

Supuestos de adopción y eficiencia · ≈ \$12,1 MM potencial/año

Supuestos: 144 atenciones = 12 mensuales × 12 meses; 50 % es cobertura inicial estimada y 75 % es una meta preliminar de reducción del esfuerzo abordado. Deben validarse en un piloto antes de considerar ahorro efectivo.

De la POC a una capacidad productiva y controlada



Siguiente validación: medir en un piloto el tiempo de análisis y las reejecuciones antes y después de incorporar el Copilot.

Una base explicable para decisiones de rendimiento más consistentes

CONTRIBUCIÓN

La POC transforma resultados Gatling en datos estructurados y entrena un primer modelo capaz de **reproducir las recomendaciones del motor de reglas** sobre la muestra disponible.

Siguiente validación

- Validar las recomendaciones con especialistas
- Ampliar el histórico con nuevos casos etiquetados
- Medir tiempo de análisis y reejecuciones en un piloto

La generalización deberá validarse con nuevos datos y revisión experta.